


Náročné chování žáků v době AI

Kazuistiky z praxe a jazykové modely
v pedagogickém výzkumu



Habilitační práce
(monografie)

Brno 2026 Jan Nehyba

MASARYKOVA UNIVERZITA

Pedagogická fakulta

Náročné chování žáků v době AI

Kazuistiky z praxe a jazykové modely v pedagogickém
výzkumu

Habilitační práce

Obor řízení: Pedagogika

Brno 2026

Jan Nehyba

Obsah

Prohlášení	1
Prohlášení o využití umělé inteligence	3
Abstrakt	5
Abstract	7
Poděkování	9
Poznámka k publikacím	11
1. Úvod	13
1.1 Problém	13
1.2 Projekt Edustories a data knihy	14
1.3 Cíl a výzkumné otázky	15
1.4 Struktura knihy	15
1.5 Dřívější výstupy a dostupnost dat	16
Východiska	17
2. Teoretická východiska	19
2.1 Náročné chování žáků: vymezení a český kontext	19
Vymezení pojmu	19
Kázeň v české pedagogické tradici	20
Náročné chování jako profesní problém	21
Řízení třídy jako výzkumný rámec	21
Kazuistika jako pramen	22
2.2 Přístupy k řešení náročného chování	23
Pozitivní behaviorální intervence a podpora (PBIS)	24
Sociálně-emoční učení (SEL)	25
Nenásilná komunikace (NVC)	27
Restorativní praxe	28
Srovnání a vztah ke knize	29
2.3 Repertoáry učitelů a učňovství pozorováním	30
Repertoár jako jednotka popisu	30

Učňovství pozorováním	31
Repertoár nejmenšího odporu	31
Osy popisu řešení	32
2.4 Velké jazykové modely v pedagogickém výzkumu	33
Od tématu k nástroji	33
Model v roli anotátora	33
Model v roli posuzovatele a generátora	34
Jazyková a doménová mezera přenosu	35
Český kontext	35
2.5 Průsečík obou linií a výzkumná mezera	36
3. Projekt Edustories: kontext vzniku dat	39
3.1 Východisko: proč sbírat kazuistiky náročného chování	39
3.2 Projekt Edustories	40
3.3 Sběr kazuistik: zrcadlová šablona	41
3.4 Od textů ke korpusu: extrakce, anonymizace, publikace	43
3.5 Tři anotační etapy	44
4. Metodologie	47
4.1 Korpus jako časová řada řezů	47
4.2 Tři anotační etapy a jejich zaučování	48
Třetí etapa	48
4.3 Od textu k datům	49
4.4 Kódovací schémata a řezy dat	49
4.5 Multiplicita anotací	51
4.6 Známa omezení dat	51
4.7 Etika	52
4.8 Reprodukovatelnost	52
Empirické studie	55
5. Studie 1: Korpus a jeho obsah	57
5.1 Rozsah a růst korpusu	57
5.2 Základní charakteristiky kazuistik	59
5.3 Co kazuistiky zachycují: chování, řešení, dopady	61
5.4 Jak se řešení pojí s chováním	64
5.5 Dopad podle typu řešení	66
5.6 Shrnutí	68
6. Studie 2: Jazykový model jako anotátor	69
6.1 Východiska	69
6.2 Metoda	70
Kódovací schéma a lidské kódování	70

Modelové kódování a srovnávací vzorek	70
Míry shody	71
6.3 Shoda mezi lidskými anotátorkami	71
6.4 Shoda jazykového modelu s lidmi	73
Dodatečná kontrola překryvu příkladů	73
Shoda po kategoriích	74
Anatomie záměn	74
6.5 Kvalitativní pohled: tři neshody zblízka	76
6.6 Shrnutí	77
7. Studie 3: Řešení generovaná umělou inteligencí versus řešení učitelů	79
7.1 Východiska	79
7.2 Metoda	80
Materiál	80
Hodnocení	80
Analýza	81
7.3 Spolehlivost hodnocení	82
7.4 Výsledky	83
Deskriptivní obraz	83
Primární modely	85
Rozpoznávání rámců	85
Citlivostní analýza	86
7.5 Shrnutí	88
8. Studie 4: Kvalita kazuistik, spolehlivost jejího posouzení a predikce úspěchu řešení	91
8.1 Východiska	91
8.2 Metoda	92
Materiál a anotátorky	92
Nástroje	93
Průběh etapy a rekalibrace	93
Uzavření etapy a adjudikace	94
Analýza	94
8.3 Co anotátorky v kazuistikách viděly	95
8.4 Spolehlivost posouzení	97
Kvalita	98
Dopad	98
Vhodnost	99
Rozdíly mezi částmi etapy kolem rekalibrace	99
Shoda napříč etapami a opakované posouzení dopadu	101
8.5 Co se pojí s úspěchem řešení	102
8.6 Umí jazykový model předvídat úspěch řešení?	104
8.7 Shrnutí	107

Integrace	109
9. Diskuse	111
9.1 Oblouk čtyř studií	111
9.2 Repertoár nejmenšího odporu	113
9.3 Co lze jazykovému modelu svěřit	114
9.4 Spolehlivost jako proměnná, ne konstanta	116
9.5 Omezení	117
9.6 Důsledky	118
Pro přípravu učitelů a školní praxi	118
Pro platformu Edustories	119
Pro jazykové modely v pedagogickém výzkumu	119
9.7 Další výzkum	119
9.8 Shrnutí	120
10. Závěr	121
10.1 Odpovědi na výzkumné otázky	121
10.2 Přínos knihy	122
10.3 Směrování	123
Literatura	125
Přílohy	133
Příloha A. Kódovací manuály	133
A.1 První etapa: kódovací kniha obsahového kódování	133
A.2 Druhá etapa: manuál hodnocení kvality řešení	141
A.3 Třetí etapa: operacionalizace kvality kazuistik	144
Příloha B. Prompty jazykových modelů	147
B.1 Extrakce a strukturace kazuistik	148
B.2 Anonymizace v promptu	150
B.3 Klasifikace řešení jazykovým modelem (model v roli anotátora)	150
B.4 Generace srovnávacího řešení pro druhou etapu	153
B.5 Rámcovaná řešení platformy Edustories	155
B.6 Predikce dopadu řešení (model v roli prediktora)	156
Příloha C. Doplnkové tabulky	159
C.1 Registr anotačních událostí	159
C.2 Přehled velikostí datových řezů	161
C.3 Přehled měř shody	162
Příloha D. Etické náležitosti	165
D.1 Informované prohlášení přispěvatele	165

D.2 Anonymizační protokol	168
Schválení etickou komisí	169
Výběrové ověření anonymizace	171

Prohlášení

Prohlašuji, že jsem habilitační práci vypracoval samostatně s využitím pouze citované literatury, informací a zdrojů a že tato práce nebyla předložena k udělení žádného předchozího titulu.

V Brně dne

.....

vlastnoruční podpis autora

Prohlášení o využití umělé inteligence

Při přípravě této práce autor využíval nástroje umělé inteligence (Claude, Anthropic) k organizaci pracovních podkladů, ke kontrole pravopisu, typografie a formátování textu a příloh, k práci s verzovaným repozitářem (Git/GitHub), k propojování a kontrole konzistence částí rukopisu s analytickými výstupy a k jazykovým úpravám a zapracování oprav podle autorových pokynů. Použití jazykových modelů jako předmětu i nástroje výzkumu je popsáno v metodologii. Po použití těchto nástrojů autor veškerý obsah zkontroloval a upravil a nese za něj plnou odpovědnost.

Abstrakt

Zvládání náročného chování žáků patří k nejtěžším stránkám učitelské profese a zároveň k oblastem, kde příprava učitelů naráží na mezeru mezi obecnými principy a jednáním v konkrétní situaci. Tato monografie na tuto mezeru odpovídá dvojím způsobem. Pedagogicky: na korpusu projektu Edustories, který čítá přes tři tisíce autentických kazuistik psaných studujícími učitelství a učiteli, popisuje, jaké typy náročného chování, řešení a dopadů česká školní praxe zaznamenává; v repertoáru řešení dominuje rozhovor a další snadno dostupné, na incident reagující postupy. Metodologicky: kriticky prověřuje velké jazykové modely jako výzkumný nástroj pro analýzu takového korpusu. Kniha dokládá, že model kóduje typy řešení ve shodě s vyškolenými anotátorkami na úrovni Cohenova $\kappa = 0,64$, . Po dodatečném vyloučení překryvů s příklady činí $\kappa = 0,61$; nejde o nový nezávislý test. V zaslepeném experimentu na 324 dvojicích řešení ukazuje, že řešení generovaná modelem hodnotily anotátorky jako vhodnější a proaktivnější než autentická řešení učitelů, jež byla reaktivnější a behaviorálnější. Čtvrtá studie na dvojité posouzeném překryvu 693 kazuistik ukazuje, že posouzení použitelnosti kazuistiky má vysokou vzájemnou shodu ($\kappa = 0,77$), posouzení dopadu řešení spolehlivé ($\kappa = 0,69$) a posouzení vhodnosti shodné jen středně. Opakované posouzení dopadu týchž textů jednou pozdější anotátorkou se shoduje s dřívějšími kódy ($\kappa = 0,59$) a vztahová a kolektivní řešení se v korpusu pojí s vyšším podílem dlouhodobého úspěchu než řešení represivní. Historické kategorie však částečně zahrnují normativní úsudek, a nejsou nezávislým měřením účinnosti. Úspěšnost řešení dokáže jazykový model z textu kazuistiky předvídat jen slabě (vyvážená přesnost 60 % proti 80 % u shody dvou posuzovatelek, které popis výsledku četly). Jde o jinou úlohu, nikoli o lidský strop predikce. Hlavní statistické analýzy jsou reprodukovatelné: kód, podkladové tabulky a hotové reporty

Abstrakt

zpřístupňuje doprovodný repozitář. Kniha tak přináší trojí příspěvek: empirický obraz repertoárů řešení náročného chování, metodologicky ukázněný postup pro nasazení jazykových modelů v pedagogickém výzkumu a otevřeně dokumentovaný postup, který obojí umožňuje ověřit.

Klíčová slova: náročné chování žáků, kazuistiky, řízení třídy, velké jazykové modely, model v roli anotátora, spolehlivost anotací, reprodukovatelnost, učitelské vzdělávání.

Abstract

Managing challenging student behaviour is among the hardest parts of teaching, and teacher education struggles to bridge the gap between general principles and situated action. This monograph answers in two registers. Pedagogically, drawing on the Edustories corpus of more than three thousand authentic case studies written by pre-service and in-service teachers, it maps the types of challenging behaviour, responses, and outcomes recorded in Czech school practice; the response repertoire is dominated by conversation and other readily available, incident-driven strategies. Methodologically, it puts large language models under critical scrutiny as research instruments for such a corpus. The book shows that a model codes response types in agreement with trained human annotators at Cohen's $\kappa = 0.64$, . After retrospectively excluding detected overlaps with prompt examples, κ is 0.61; this is not a new independent test. In a blinded experiment on 324 solution pairs it demonstrates that model-generated solutions were rated as more appropriate and more proactive than teachers' authentic solutions, which were more reactive and behaviourally oriented. On a doubly rated overlap of 693 case studies, the fourth study shows high inter-rater agreement in judging case usability ($\kappa = 0.77$), judging the outcome of a solution is reliable ($\kappa = 0.69$) and judging its appropriateness reaches only moderate agreement. Earlier outcome codes agree with one later annotator reading the same texts ($\kappa = 0.59$), and relational and class-level solutions are associated with a higher share of long-term success than punitive ones. Historical categories partly incorporate normative judgments and do not independently measure effectiveness. A language model predicts the success of a solution from the case text only weakly (balanced accuracy 60 % against 80 % for the agreement of two human raters who read the reported outcome). This is a different task, not a human prediction ceiling. The main statistical analyses

Abstract

are reproducible: the companion repository provides the code, source tables and rendered analysis reports. The contribution is threefold: an empirical picture of teachers' response repertoires, a disciplined methodology for deploying language models in educational research, and an openly documented procedure that allows both to be verified.

Keywords: challenging student behaviour, case studies, classroom management, large language models, LLM-as-annotator, annotation reliability, reproducibility, teacher education.

Poděkování

Kniha vznikla v rámci projektu TA ČR TQ01000030. Děkuji anotátorkám výzkumného týmu Edustories, jejichž pečlivá práce tvoří páteř všech tří anotačních etap (v knize vystupují pod pseudonymy, protože anonymizaci uplatňujeme důsledně i tam, kde by poděkování bylo zaslouženě jmenovité), Michalu Štefánikovi za dlouholetou spolupráci na výpočetní straně projektu a všem studujícím učitelství, kteří své zkušenosti proměnili v kazuistiky.

Poznámka k publikacím

Tato monografie je původní vědeckou prací napsanou pro toto habilitační řízení: uceleným a samostatným zpracováním nad daty projektu Edustories, nikoli souborem převzatých článků. Není totožná s žádnou disertační ani jinou kvalifikační prací, kterou autor dříve předložil k získání akademického titulu, a žádnou takovou nereprodukuje. Přehled dřívějších publikovaných výstupů autora, s nimiž práce tematicky souvisí, uvádí dokumentace habilitačního řízení.

1. Úvod

1.1 Problém

Zvládání náročného chování žáků je jednou z nejobtížnějších a nejméně uchopených stránek učitelské profese. Pro začínající učitele bývá nejčastěji uváděným problémem a spoluvtváří známý „šok z reality“ při vstupu do praxe (Veenman, 1984). Novější česká studie popisuje, jaké situace novicové řeší, jak na ně reagují a s jakým dopadem na chování žáků (Karasová a Nehyba, 2025). Kniha vychází z předpokladu, rozvinutého v kapitole 2, že příprava učitelů zprostředkuje obecné principy snáze než to, co zkušení praktici získávají léty: konkrétní, situačně ukotvený repertoár řešení. Obecná znalost přístupů k náročnému chování ještě nikomu nepomohla ve chvíli, kdy se dvě děti ve třetí lavici začnou prát. Tato mezera mezi obecným poznáním a jednáním v konkrétní situaci je jádrem problému, jemuž se kniha věnuje.

Problém není specificky český, má však v českém prostředí konkrétní podobu. Náročné chování se v domácím odborném jazyce ustálilo jako zastřešující pojem teprve nedávno, především zásluhou metodického doporučení školní inspekce (Felcmanová et al., 2021). Domácí výzkum se dosud opírá hlavně o pozorování praxí studentů učitelství, o analýzy výukové komunikace a o malé kvalitativní vzorky začínajících učitelů (podrobně kapitola 2). Chybí popisná evidence velkého rozsahu: systematický obraz toho, jaké situace čeští učitelé a studenti učitelství za náročné považují, jak je řeší a jak jejich řešení dopadají. Bez ní se diskuse o přípravě učitelů v této oblasti opírá o dojmy a jednotlivé případy.

1. Úvod

Osvědčeným prostředkem, jak mezeru mezi principem a situací překlenout, jsou kazuistiky, tedy autentické případové popisy z praxe. Aby mohly sloužit výzkumu i přípravě učitelů ve velkém, je jich potřeba mnoho, je třeba je sbírat systematicky a umět je analyzovat. Právě zde vstupuje druhá rovina problému. Rozsáhlý korpus nestrukturovaného pedagogického textu naráží na kapacitní hranice tradiční kvalitativní analýzy: ruční kódování tisíců narážů je práce na roky a lidská shoda v něm má vlastní, nepřekročitelné limity. Velké jazykové modely nabízejí možnost tuto hranici posunout. Do českých škol mezitím vstoupily masově: s nástroji umělé inteligence (AI) experimentovala už krátce po nástupu ChatGPT značná část učitelů (Kopecký et al., 2023) a používá je nadpoloviční většina žáků (Kopecký a Voráč, 2024). Role modelů ve výzkumu však není samozřejmá. Musí být doložena jejich shoda s lidským úsudkem a vymezeno, co ještě unesou a co už ne. Kniha proto s jazykovým modelem zachází jako s nástrojem, který je třeba nejprve kriticky prověřit, a teprve potom mu svěřit výzkumnou práci.

1.2 Projekt Edustories a data knihy

Empirickým základem knihy je projekt Edustories, který sbírá a zpřístupňuje kazuistiky náročného chování psané studujícími učitelství a učiteli. Z projektu pochází rostoucí korpus, jehož zveřejněný řez čítá přes tři tisíce kazuistik, a tři anotační etapy, které nad korpusem proběhly: první přinesla lidské kódování obsahu, druhá zaslepené hodnocení učitelských a generovaných řešení a třetí posouzení kvality kazuistik, dopadu a vhodnosti řešení (kapitola 8). Projekt má dvojí tvář, kterou kniha důsledně rozlišuje: veřejnou platformu, jež slouží praxi a přípravě učitelů, a výzkumný korpus s kurátorovaným zveřejněným výběrem, jenž slouží vědě. Projekt, jeho institucionální zázemí i vznik dat podrobně představuje kapitola 3. Kniha stojí výhradně na těchto datech; jak jsou analýzy dokumentovány a jak si je lze ověřit, popisuje kapitola 4 a oddíl 1.5.

1.3 Cíl a výzkumné otázky

Cílem knihy je na datech projektu Edustories propojit obě roviny problému: popsat, co kazuistiky vypovídají o zvládání náročného chování, a zároveň prověřit velké jazykové modely jako nástroj jejich výzkumu. Tomuto dvojímu cíli odpovídají čtyři výzkumné otázky, z nichž každá je rozpracována v jedné empirické studii:

- **VO1:** Jak lze vybudovat a popsat rozsáhlý korpus autentických kazuistik a jaké typy náročného chování, řešení a dopadů zachycuje? (Studie 1, kap. 5)
- **VO2:** Nakolik se velký jazykový model shodne s vyškolenými lidskými anotátory při deduktivní klasifikaci obsahu kazuistik? (Studie 2, kap. 6)
- **VO3:** Jak se liší řešení generovaná jazykovým modelem od autentických řešení učitelů v jejich vhodnosti a orientaci? (Studie 3, kap. 7)
- **VO4:** Jakou kvalitu mají kazuistiky, jak spolehlivě ji lze posoudit a nakolik dokáže jazykový model předvídat úspěšnost řešení? (Studie 4, kap. 8)

Pořadí otázek není nahodilé. VO1 ustavuje materiál a jeho pedagogický obsah, VO2 prověřuje model v roli anotátora proti lidskému kódování z téhož materiálu, VO3 obrací role a nechává lidi zaslepeně hodnotit výstupy modelu a VO4 zkoumá hranice, na nichž spolehlivost lidí i modelu končí. Pedagogická a metodologická linie se tak střídají; odpovědi na ně však vycházejí z jednoho korpusu a drží pohromadě.

1.4 Struktura knihy

Knihy postupuje od teorie přes metodologii ke čtyřem empirickým studiím a jejich syntéze. Kapitola 2 klade teoretické základy obou linií: náročného chování, přístupů k jeho řešení a repertoárů učitelů na straně jedné a využití jazykových modelů v pedagogickém výzkumu na straně druhé. Kapitola 3 představuje projekt Edustories a vznik dat. Kapitola 4 popisuje metodologii vcelku: časovou osu korpusu, tři anotační etapy, zpracování textů, kódovací schémata, etiku a zásady reprodukovatelnosti. Kapitoly 5 až 8 přinášejí čtyři empirické studie

1. Úvod

odpovídající výzkumným otázkám. Kapitola 9 obě linie propojuje v diskusi a pojmenovává limity; kapitola 10 shrnuje přínos a naznačuje další směřování. Přílohy dokládají kódovací manuály, prompty, doplňkové tabulky a etické náležitosti.

1.5 Dřívější výstupy a dostupnost dat

Z projektu Edustories byly dosud publikovány dva rané výstupy: stručná zpráva pro českou pedagogickou výzkumnou obec ve sborníku konference ČAPV (Nehyba, Karasová, Škarková, et al., 2024) a kurátorovaný anotovaný výběr korpusu zveřejněný jako datová sada Edustories-en (Nehyba, Karasová a Štefánek, 2024). Metodologicky knize předchází také starší práce autorského týmu s hlubokými jazykovými modely nad reflektivními texty (Nehyba a Štefánek, 2023), která stojí na jiných datech. Kniha z těchto výstupů vychází a rozšiřuje je: všechny analýzy provádí nově, v širším rozsahu a na novějším řezu korpusu; vše ostatní je zde publikováno poprvé.

Druhou zásadou knihy je dohledatelnost. Všechny analýzy jsou skriptované a každé číslo v textu lze dohledat ve výstupu příslušné analýzy; postup popisuje kapitola 4. Anonymizované datové řezy, skripty, analytické notebooky a hotové reporty jsou dostupné v [doprovodném repozitáři](#) , na nějž kniha odkazuje z poznámek pod obrázky a tabulkami, spolu s návodem, jak si čísla ověřit bez programátorských znalostí. Empirické studie jsou z těchto veřejných dat přepočitatelné bez textů kazuistik (anotátorky vystupují pod pseudonymy); úplná data Studie 3 včetně textů jsou v balíčku na platformě OSF (odkaz bude zveřejněn s publikací souvisejícího článku, do té doby na vyžádání). Texty kazuistik zůstávají neveřejné: korpus zahrnuje i nezveřejněné případy a je dostupný přes platformu projektu. Kde zveřejnění brání ochrana přispěvatelů, kniha to u příslušného souboru výslovně uvádí, včetně důvodu.

Východiska

2. Teoretická východiska

Kniha stojí na průsečíku dvou linií. První je pedagogická: náročné chování žáků, přístupy k jeho řešení a postupy, jimiž na ně učitelé skutečně reagují. Druhá je metodologická: velké jazykové modely jako nástroj pedagogického výzkumu. Kapitola u obou vymezuje pojmy, s nimiž kniha dále pracuje, třídí stav poznání, ukotvuje je v českém kontextu a pojmenovává mezeru, kterou zaplňují empirické kapitoly. Postupuje od vymezení náročného chování (2.1) přes čtyři přístupy k jeho řešení (2.2) a pojem učitelského repertoáru (2.3) k jazykovým modelům ve výzkumu (2.4); závěrečný oddíl (2.5) obě linie spojuje.

2.1 Náročné chování žáků: vymezení a český kontext

Vymezení pojmu

Kniha pracuje s pojmem náročné chování (challenging behaviour) jako se zastřešujícím označením pro chování žáků, které se výrazně odlišuje od chování očekávaného v daném věku a které negativně ovlivňuje učení, vztahy nebo bezpečí ve škole. Opírá se přitom o české metodické doporučení, které pojem do domácího prostředí systematicky zavedlo (Felmanová et al., 2021). Pojem je záměrně širší než tradiční „nekázeň“: zahrnuje projevy od nepozornosti přes verbální a fyzickou agresi až po záškoláctví a šikanu, aniž by předjímal jejich příčinu. Zároveň je přiznaně perspektivní. Co je náročné, se ustavuje v pohledu pedagoga, který s chováním pracuje, a stejné jednání může být v různých kontextech čteno různě

2. Teoretická východiska

(Felcmanová et al., 2021). Právě to je pro knihu důležité, protože jejím materiálem jsou kazuistiky psané z pohledu vyučujících: korpus nezachycuje chování žáků „o sobě“, ale chování tak, jak je viděli, rámovali a řešili konkrétní aktéři.

Kázeň v české pedagogické tradici

Česká pedagogika o tomtéž jevu dlouho mluvila jazykem kázně. Kázeň patřila ke klasickým, normativně pojatým tématům oboru a nekázeň se vymezovala jako porušování stanovených školních norem; v polistopadové literatuře toto pojetí soustavně rozpracovaly Bendlovy monografie o školní kázni a kázeňských problémech (Bendl, 2001; Bendl, 2011). Takové vymezení má výhodu jasného kritéria, nese však dvě omezení. Normativní ukotvení činí z chování především přestupek a odvádí pozornost od jeho funkce. A soustředění na porušení pravidel z definice vylučuje projevy, které žádnou explicitní normu neporušují, a přesto výuku rozkládají nebo signalizují žákovu nouzi. Slovník oboru se proto v posledních dvou desetiletích posouval: od nekázně k problémovému a rizikovému chování, s nímž pracuje školní prevence (Ministerstvo školství, mládeže a tělovýchovy [MŠMT], 2010). Inkluzivní novela školského zákona (zákon č. 82/2015 Sb.) spolu s navazující vyhláškou (vyhláška č. 27/2016 Sb.) uložila školám podpůrná opatření pro žáky se speciálními vzdělávacími potřebami. Pojem náročné chování následně používá doporučení školní inspekce (Felcmanová et al., 2021). Novější domácí diskurz rámuje náročné chování funkcionálně: jako reakci na stres, jako důsledek dosud nerozvinutých sociálních a emočních dovedností, případně jako prostředek naplňování potřeb, které žák neumí naplnit jinak (Kubíčková a Felcmanová, 2021). Toto čtení, opřené mimo jiné o poznatky o nepříznivých zkušenostech v dětství, má přímý důsledek pro hodnocení reakcí učitele: represivní zásah může incident krátkodobě ukončit, ale má jeho funkci. Kniha mezi oběma rámci nevolí. Podržuje si funkcionální perspektivu jako interpretační pozadí, protože lépe odpovídá tomu, jak jsou kazuistiky v korpusu psány, včetně částí věnovaných anamnéze a dlouhodobému výsledku řešení. Stopa starší terminologie přitom v knize zůstává viditelná: kódovací kniha první anotační etapy (příloha A) ještě mluví o problémovém chování a některé její kategorie nesou normativní logiku porušení pravidel.

Náročné chování jako profesní problém

Zvládání chování žáků patří dlouhodobě k nejčastěji uváděným problémům začínajících učitelů. Kanonický přehled studií o vnímaných problémech noviců řadí kázeň ve třídě na první místo, před motivování žáků a práci s individuálními rozdíly, a přechod z přípravy do praxe popisuje jako „šok z reality“ (Veenman, 1984). Na tuto linii navazuje soudobý výzkum reakcí učitele zaměřených na žáka (Karasová a Nehyba, 2023) i studie z českého prostředí, která popisuje, jakým kázeňským situacím začínající učitelé čelí, jak na ně reagují a jaký má jejich reakce bezprostřední dopad na chování žáků (Karasová a Nehyba, 2025). Význam tématu nespočívá jen v subjektivní zátěži: zvládání třídy je opakovaně identifikováno jako podmínka učení i jako faktor setrvání v profesi. Náročné chování je tak téma, u něhož poptávka praxe po použitelné opoře výrazně převyšuje nabídku; a začínající učitelé a studenti učitelství, kteří tvoří podstatnou část přispěvatelů korpusu, jsou skupinou, pro kterou je tato opora nejnaléhavější.

Řízení třídy jako výzkumný rámec

Zastřešujícím polem, v němž se reakce na náročné chování zkoumají, je řízení třídy (classroom management), v části české literatury označované také jako vedení třídy. Přehledová studie, která pojem do českého diskurzu systematicky uvedla, třídí pole třemi dichotomiemi: behavioristické versus humanistické přístupy, behaviorální versus instrukční management a proaktivní versus reaktivní strategie učitele (Lukas a Lojdová, 2018). Dvě z těchto dichotomií kniha později používá jako osy popisu řešení v korpusu (reaktivní–proaktivní a humanistická–behaviorální, oddíl 2.3). Metaanalýzy ukazují malé, ale stabilní účinky: strategie a programy řízení třídy zlepšují v průměru akademické, behaviorální i sociálně-emoční výsledky žáků, přičemž k nejúčinnějším patří programy cílící na sociálně-emoční rozvoj (Korpershoek et al., 2016). Systematické přehledy zároveň identifikují okruh konkrétních praktik s dostatečnou empirickou oporou, od jasné struktury a nacvičených rutin přes aktivní výuku po posilování vhodného chování a odstupňované reakce na chování nevhodné

2. Teoretická východiska

(Simonsen et al., 2008). Evidence tedy existuje. Otázkou, k níž se kniha vrací ve Studii 1, je, nakolik se tento poznatkový fond propisuje do každodenních reakcí učitelů.

Domácí pedagogický výzkum nabízí k tématu tři relevantní proudy. První proud zkoumá řízení třídy přímo: rozsáhlá empirická monografie brněnského týmu popisuje na kombinaci pozorování, rozhovorů a dotazníků reaktivní i proaktivní strategie studentů učitelství na dlouhodobé praxi a jejich provázejících učitelů (Vlčková et al., 2020). Druhý proud se věnuje výukové komunikaci: dlouhodobá pozorování a analýzy videozáznamů ukázaly, jak učitelské otázky, zpětná vazba a mocenské vztahy spoluutvářejí vztahy mezi učitelem a žáky, a formulovaly ideál dialogického vyučování (Šedřová et al., 2012). Třetí proud sleduje začínající učitele: kvalitativní studie dokumentuje posun jejich percepce nekázně od jevu „na straně žáka“ k chápání nekázně jako projevu žákovy diskomfortu (Ševčíková et al., 2023). Vedle akademického výzkumu vstoupil do domácího diskurzu i resort: metodické doporučení České školní inspekce shrnulo přístupy k náročnému chování pro školy a školská zařízení (Felcmanová et al., 2021). Co v českém kontextu chybí, je systematický popis toho, jak učitelé náročné chování skutečně řeší, opřený o velký soubor autentických situací namísto sebevýpovědí v dotaznících nebo malých kvalitativních vzorků. Přesně tento typ evidence poskytuje korpus Edustories.

Kazuistika jako pramen

Volba kazuistiky jako datového pramene si zaslouží teoretické zdůvodnění, protože nese specifické silné i slabé stránky. Silnou stránkou je situovanost: pisatel popisuje konkrétní situaci, kterou zažil nebo bezprostředně pozoroval, včetně kontextu, průběhu řešení a jeho výsledku. Výsledný text tak zachycuje jednání v celém situačním oblouku, ne izolovanou odpověď na položku dotazníku. Strukturovaná šablona sběru (popis situace, anamnéza, řešení, výsledek; kapitola 3) tento oblouk dále zvýrazňuje. Slabou stránkou je dvojí zprostředkování: kazuistika je retrospektivní rekonstrukce, v níž se jednání již jednou interpretovalo, a je psána z jedné perspektivy, takže podléhá výběrové paměti i sebeprezentaci. Kniha s tímto omezením zachází otevřeně. Korpus nechte jako záznam toho, co se ve třídách „objektivně“ děje,

ale jako záznam toho, jak učitelé a studenti učitelství náročné situace vnímají, rámuji a jaká řešení považují za hodná zaznamenání. Pro studium repertoárů je právě tato vrstva podstatná, protože repertoár se reprodukuje skrze to, co si aktéři ze situací odnášejí a co si o nich vyprávějí.

2.2 Přístupy k řešení náročného chování

V mezinárodní literatuře se ustálilo několik pojmenovaných přístupů k náročnému chování, které nabízejí ucelený rámec: teorii toho, proč náročné chování vzniká, principy práce s ním a zpravidla i strukturovaný program zavedení. Kniha pracuje se čtyřmi z nich: s pozitivní behaviorální intervencí a podporou (PBIS), se sociálně-emočním učním (SEL), s nenásilnou komunikací (NVC) a s restorativní praxí. Důvod výběru je pragmatický a kniha ho nezastírá. Právě v těchto čtyřech rámcích generuje platforma Edustories ke kazuistikám alternativní řešení (spolu s perspektivou proaktivní a reaktivní, která odpovídá první ose popisu řešení z oddílu 2.3), a ve Studii 3 tytéž čtyři rámce slouží jako štítky, jimiž anotátorky posuzovaly, zda hodnocené řešení některý z nich nese. Do platformy se dostaly proto, že byly v době jejího návrhu mezinárodně dobře dokumentované, vzájemně odlišné a formulovatelné jako instrukce pro generování řešení. Čtveřice není vyčerpávající taxonomií: mimo ni stojí například trauma-informovaný přístup, který domácí literatura doporučuje kombinovat s celoškolskou pozitivní podporou (Kubíčková a Felcmanová, 2021), i celá tradice individuálních funkcionálních analýz chování.

Pro čtení výsledků je podstatné, že žádný ze čtyř přístupů není v českých školách zavedeným systémem. PBIS a SEL vzešly ze severoamerické intervenční tradice; nejbližším domácím příbuzným SEL je osobnostní a sociální výchova (OSV), v rámcovém vzdělávacím programu pro základní vzdělávání dlouho vedená jako průřezové téma (MŠMT, 2023) a v jeho revizi z roku 2025 přetvořená ve vzdělávací obor (MŠMT, 2025). Její česká didaktika se od počátku hlásila k inspiraci britskou personal and social education (Valenta, 2006). PBIS vstupuje do České republiky teprve v posledních letech, mimo jiné prostřednictvím organizace Society

2. Teoretická východiska

for All (SOFA), která jej školám představuje jako pozitivní podporu chování (Felcmanová et al., 2023), a domácí odborné literatury (Kubičková a Felcmanová, 2021). Nenásilná komunikace žije v českém prostředí v kurzech dalšího vzdělávání a v překladové literatuře, restorativní praxe v programech neziskových organizací; recenzovaná domácí evidence u obou chybí. Čtveřice tedy v knize vystupuje jako vnější normativní horizont, ne jako popis domácí praxe. Že učitelská řešení v korpusu tyto rámce zřídka nesou (Studie 1 a 3), proto zčásti odráží jejich slabou domácí přítomnost, ne nutně nedostatek jednotlivých učitelů.

Čtyři přístupy se liší tím, na jaké úrovni zasahují, i tím, jak silně jsou doloženy. PBIS intervenuje na úrovni školy jako systému, SEL na úrovni kurikula a kompetencí žáka, nenásilná komunikace na úrovni komunikace jednotlivého učitele a restorativní praxe na úrovni vztahů a společenství třídy. PBIS a SEL mají oporu v metaanalýzách, nenásilná komunikace a restorativní praxe vyrostly z praxe a normativní teorie a experimentální ověřování je dohánění až dodatečně. Oba rozdílů, úroveň zásahu a síla evidence, se v empirických kapitolách vracejí jako otázka, zda se učitelské repertoáry přiklánějí k přístupům s nejsilnější evidencí, nebo spíše k postupům, které jsou v situaci jednatelce nejsnáze dostupné. Studie 1 na ni odpovídá nepřímo, skladbou kategorií řešení v korpusu; Studie 3 přímo, rozpoznáváním čtyř přístupů v hodnocených řešeních. Následující pododdíly u každého přístupu shrnují původ a principy, stav evidence, hlavní kritiky a český kontext; oddíl uzavírá srovnávací tabulka.

Pozitivní behaviorální intervence a podpora (PBIS)

Pozitivní behaviorální intervence a podpora (Positive Behavioral Interventions and Supports, PBIS; v projektu zkráceně „pozitivní behaviorální podpora“) vyrostla z aplikované behaviorální analýzy a je koncipována jako celoškolský systém, ne jako technika jednotlivého učitele. Její zakladatelé ji popisují jako příklad behaviorální vědy rozšířené do společensky významného měřítka. Školy explicitně definují očekávané chování, systematicky je nacvičují a oceňují, pracují s odstupňovaným kontinuem důsledků a svá rozhodnutí opírají o průběžně sbíraná data o chování; ve Spojených státech byl tento rámec zaveden ve více než 21 000 škol (Horner a Sugai, 2015). Podstatný je vícevrstvý model podpory: univerzální prevence

pro všechny žáky, cílená podpora pro žáky se zvýšeným rizikem a intenzivní individuální intervence pro žáky s nejzávažnějšími obtížemi.

PBIS patří k nejlépe empiricky prověřeným celoškolním rámcům. Aktualizovaná metaanalýza skupinových studií, zahrnující randomizované i kvaziexperimentální studie z USA a Evropy, doložila významné snížení kázeňských postihů a suspenzí a zlepšení akademických výsledků i vnímaného bezpečí a organizačního zdraví školy (Lee a Gage, 2020). Síla tohoto rámce spočívá v propracovanosti zavádění: PBIS je definován měřitelnými prvky, což umožňuje zkoumat nejen, zda funguje, ale i za jakých podmínek.

Kritika PBIS míří především na jeho behaviorální jádro. Systémy explicitního oceňování mohou podle kritiků posilovat vnější motivaci na úkor vnitřní a redukovat morální rozvoj na nácvik poslušnosti; funkcionálně orientovaní autoři zase upozorňují, že důraz na viditelné chování může odvádět pozornost od jeho příčin. Praktickým limitem je náročnost zavedení: efekty stojí a padají s věrností, s jakou škola rámec uplatňuje, což vyžaduje vedení školy, čas a průběžný sběr dat. V českém prostředí PBIS nemá institucionální infrastrukturu obdobnou té americké. Domácí literatura jej doporučuje jako slibný rámec celoškolní podpory duševního zdraví, v kombinaci s trauma-informovaným přístupem (Kubíčková a Felcmanová, 2021), jeho prvky se objevují v metodickém doporučení inspekce (Felcmanová et al., 2021) a školám jej v posledních letech zprostředkovává organizace Society for All, která po pilotáži na třech základních školách vydala českou verzi metodiky třídních strategií PBIS (Felcmanová et al., 2023).

Sociálně-emoční učení (SEL)

Sociálně-emoční učení (Social and Emotional Learning, SEL) vychází z předpokladu, že sociální a emoční dovednosti, jako jsou sebeuvědomění, seberegulace, sociální vnímavost, vztahové dovednosti a odpovědné rozhodování, lze systematicky vyučovat a že jejich rozvoj předchází problémovému chování lépe než následná disciplinace. Na rozdíl od PBIS, který upravuje prostředí a důsledky, SEL cílí na kompetence žáka; oba rámce se proto v praxi často kombinují.

2. Teoretická východiska

Evidence SEL je rozsahem výjimečná. Kanonická metaanalýza univerzálních školních programů doložila významná zlepšení dovedností, postojů, chování i akademického výkonu, s akademickým ziskem přibližně 11 percentilových bodů (Durlak et al., 2011). Následný přehled dvanácti metaanalýz účinky potvrdil a zároveň upozornil, že poznání moderátorů, tedy toho, pro koho a za jakých podmínek programy fungují nejlépe, zůstává překvapivě nejednotné (Durlak et al., 2022). Nejnovější velká metaanalýza experimentálních studií z desítek zemí dokládá, že žáci v SEL intervencích vykazují oproti kontrolám lepší dovednosti, chování, školní klima i akademické výsledky (Cipriano et al., 2023). Souhrnně jde o jeden z nejlépe doložených preventivních rámců v pedagogice.

Ani SEL se nevyhýbá kritice. Účinky se měří převážně krátce po intervenci a na sebevýpovědích; přenos do reálného chování v konfliktní situaci je doložen slaběji. Kulturní kritika upozorňuje, že katalogy „správných“ emočních dovedností nesou implicitní normy středostavovské kultury a mohou patologizovat jiné styly projevu. A stejně jako u PBIS klesají efekty s nevěrným zavedením, přičemž právě věrnost je v běžném provozu škol nejhůře udržitelná.

V českém prostředí nemá SEL podobu programu, má však blízkého příbuzného. Osobnostní a sociální výchova (OSV) byla od zavedení rámcových vzdělávacích programů průřezovým tématem základního vzdělávání (MŠMT, 2023) a revize programu z roku 2025 z ní činí samostatný vzdělávací obor (MŠMT, 2025); sleduje obdobné cíle jako SEL: sebepoznání, sebe-regulaci, vztahy a komunikaci ve skupině. Její česká didaktika se přitom od počátku hlásí k britské tradici personal and social education, z níž převzala i název a důraz na zkušenostní, prožitkové učení (Valenta, 2006). Od SEL se OSV liší tím, co jí chybí: nemá standardizovaný program ani metaanalytickou evidenci účinků a její realizace závisí na jednotlivé škole a učiteli. Pro tuto knihu je SEL relevantní dvojnásob: jako jeden ze čtyř rámců platformy a jako interpretační vodítko pro čtení korpusu, v němž řada popsanych řešení implicitně pracuje právě s emoční regulací a vztahovou prací; štítek SEL ve Studii 3 mezi importovaným programem a domácí OSV nerozlišuje.

Nenásilná komunikace (NVC)

Nenásilná komunikace (Nonviolent Communication, NVC) je komunikační model rozvinutý Marshallem Rosenbergem: mluvčí odlišuje pozorování od hodnocení, pojmenovává pocity, spojuje je s potřebami a formuluje konkrétní prosby, a stejnou strukturou přijímá sdělení druhých (Rosenberg, 2015). V pedagogickém kontextu NVC nabízí jazyk pro deeskalaci konfliktu a pro vztahovou práci se žákem. Na rozdíl od PBIS a SEL nejde o program s kurikulem, ale o praxi jednotlivce, kterou lze uplatnit okamžitě a bez systémové podpory. Právě tato nízkoprahovost vysvětluje popularitu NVC mezi učiteli i její přítomnost mezi rámci platformy Edustories.

Evidence NVC je řádově slabší než u předchozích dvou přístupů. Mapující přehled (scoping review) z oblasti pomáhajících profesí shrnul jen sedm empirických studií nevelkého rozsahu a heterogenní metodiky; NVC v nich vychází jako slibný, ale křehce doložený nástroj a autoři volají po důkladnějším výzkumu (Adriani et al., 2024). Jedna z mála kontrolovaných studií, randomizovaný experiment s mediky, doložila mírný nárůst sebesupozované empatie po krátkém tréninku NVC, ne však v implicitních kognitivních testech (Epinat-Duclos et al., 2021). Recenzovaná metaanalýza účinků NVC ve školním prostředí dosud chybí. Kniha proto s NVC zachází opatrně: jako s vlivným a v praxi rozšířeným jazykem vztahové práce, jehož účinnost je doložena spíše kazuisticky než experimentálně. Tento rozdíl v síle evidence je pozadím Studie 3, v níž anotátorky rozpoznávaly znaky NVC a dalších přístupů. Samotná generační instrukce však žádný rámec nepředepisovala.

Vedle slabé evidence se NVC vytýká riziko mechanizace: čtyřkroková struktura se snadno mění ve formuli, kterou mluvčí odříkává, aniž by nesla postoj, z něhož model vyrůstá, a takto užitá může působit manipulativně nebo odtazité. Druhá námitka míří na asymetrii školní situace. Model předpokládá dialog rovnocenných, zatímco učitel vůči žákovi vystupuje i jako nositel moci a garant pravidel, takže „čisté“ nenásilné jednání naráží na institucionální roli. V českém prostředí se NVC šíří především překlady Rosenbergových knih (Rosenberg, 2022), kurzy dalšího vzdělávání a popularizační literaturou, tedy kanály, které se do recenzované evidence nepropisují. O to důležitější je empirická otázka, zda a v jaké podobě se vztahový,

2. Teoretická východiska

na potřeby orientovaný jazyk objevuje v reálných řešeních učitelů; k ní korpus nabízí data ve Studii 1.

Restorativní praxe

Restorativní praxe přenáší do škol principy restorativní justice. Na místo otázky „jaké pravidlo bylo porušeno a jaký trest následuje“ klade otázky „komu vznikla újma, jaké potřeby tím vznikly a kdo je povinen je napravit“. Typickými nástroji jsou restorativní rozhovory a kruhy, v nichž aktér, poškození i komunita třídy společně hledají nápravu. Přístup je výslovně koncipován jako alternativa k vylučujícím trestům (suspenze, vyloučení), jejichž nerovnoměrné dopady na znevýhodněné skupiny žáků patří k hlavním motivacím jeho zavádění.

Evidence restorativní praxe je smíšená a metodologicky poučná. Narativní přehled výzkumu dokumentuje rychlé šíření přístupu a převážně příznivé výsledky terénních studií (Fronius et al., 2019); navazující přehled kvantitativních studií uzavírá, že programy mohou zlepšit klima a snížit kázeňské postihy, zatímco výsledky pro šikanu, absence a akademický výkon jsou neprůkazné (Darling-Hammond et al., 2020). Nejprísnejší test dopadl střízlivě. Dvouletý klastrový randomizovaný experiment na školách nižšího sekundárního stupně nenašel na úrovni randomizace žádný významný rozdíl mezi intervenčními a kontrolními školami; zkušenost s restorativními praktikami, kterou žáci sami uváděli, však predikovala lepší vztah ke škole, lepší klima i méně viktimizace (Acosta et al., 2019). Rozdíl mezi slabým efektem programu a slibným efektem zkušenosti ukazuje na klíčovou roli zavedení: restorativní praxe zjevně nefunguje jako „balíček“, který stačí formálně zavést.

Kritika restorativní praxe míří na náročnost autentického provedení (kruh vedený bez důvěry a času se snadno stává rituálem), na riziko sekundární viktimizace poškozených a na napětí mezi restorativní logikou a formálními kázeňskými řády škol. V českém prostředí se restorativní principy objevují v metodických materiálech a v nabídce neziskových organizací, systematická domácí evidence však chybí. V korpusu Edustories se restorativně laděná řešení vyskytují, jak ukáže Studie 1, spíše ojediněle, což samo o sobě vypovídá o repertoáru, z něhož čeští učitelé vybírají.

Srovnání a vztah ke knize

Tabulka 2.1 čtveřici shrnuje: na co přístup cílí, jak silná je jeho empirická opora, jaké má limity a o které zdroje se hodnocení opírá.

Tabulka 2.1. Čtyři přístupy k řešení náročného chování, o něž se opírá platforma Edustories i Studie 3. Hodnocení síly evidence se opírá o zdroje v posledním sloupci, podrobně rozebrané v oddílu 2.2.

Přístup	Primární zaměření a mechanismus	Síla evidence	Hlavní limity	Klíčové zdroje
PBIS	prostředí a důsledky; celoškolní systém očekávání, nácviku, oceňování a dat	silná (metaanalýzy včetně randomizovaných studií)	behaviorální jádro; náročná věrnost zavedení; závislost na vedení školy	Horner a Sugai, 2015; Lee a Gage, 2020
SEL	kompetence žáka; kurikulární rozvoj sociálních a emočních dovedností	silná (opakované velké metaanalýzy)	krátkodobá měření a sebevypovědi; kulturní normativita; věrnost zavedení	Durlak et al., 2011; Durlak et al., 2022; Cipriano et al., 2023
NVC	kommunikace jednotlivce; pozorování–pocity– potřeby–prosby	slabá (několik malých studií; jediný randomizovaný experiment, mimo školní prostředí)	chybí evidence ze školního prostředí; riziko mechanického užití „formule“	Rosenberg, 2015; Adriani et al., 2024; Epinat-Duclos et al., 2021
Restorativní praxe	vztahy a náprava újm; rozhovory a kruhy místo vylučujících trestů	smíšená (randomizovaný experiment bez efektu programu, slibný efekt zkušenosti)	stojí na autentickém provedení; napětí s formálními řády; časová náročnost	Fronius et al., 2019; Darling-Hammond et al., 2020; Acosta et al., 2019

Pro knihu mají tyto čtyři rámce dvojí roli. Tvoří normativní horizont: popisují, jak by řešení

2. Teoretická východiska

náročného chování vypadat mohlo, kdyby se opíralo o poznatkový fond oboru, a další kapitoly ukazují, jak daleko od tohoto horizontu leží řešení popisovaná v reálných kazuistikách. Zároveň spolu s perspektivou proaktivní a reaktivní vymezují prostor, v němž platforma nabízí učitelům jiná čtení situace, a ve Studii 3 slouží jako štítky, jimiž anotátorky posuzovaly, zda hodnocené řešení některý z přístupů nese. Přiřazení reálného řešení k přístupu je přitom interpretační akt, ne mechanické čtení: učitelka vedoucí restorativně laděný rozhovor se na žádný rámec neodvolává a tentýž postup může nést prvky několika přístupů zároveň. Kniha proto s přiřazeními zachází jako s úsudky poučených posuzovatelek, jejichž shodu je nutné doložit; činí tak Studie 3.

2.3 Repertoáry učitelů a učňovství pozorováním

Repertoár jako jednotka popisu

Způsob, jímž učitelé na náročné chování reagují, kniha uchopuje pojmem repertoár: soubor osvojených postupů, které má učitel v situaci k dispozici a z nichž pod časovým tlakem vybírá. Pojem přebírá z literatury o profesním jednání: v sociologii kultury označuje zásobu návyků, dovedností a stylů, z níž aktéři skládají strategie jednání (Swidler, 1986), a v literatuře o řízení třídy patří k běžnému popisu učitelské expertizy jako soubor rutinních, často nepovšimnutých způsobů udržování pořádku (Payne a Hustler, 1980). Kniha jej užívá v úzkém, popisném smyslu. Pojem je záměrně popisný, ne hodnotící. Neptá se, co učitel zná nebo čemu věří, ale co reálně dělá; a připouští, že mezi deklarovanými přesvědčeními a jednáním v afektem nabitě situaci bývá rozestup. Repertoár je zároveň jednotkou, kterou lze empiricky pozorovat na velkém souboru situací: právě četnosti a kombinace kategorií řešení v korpusu, popsané ve Studii 1, jsou operacionalizací tohoto pojmu.

Učňovství pozorováním

Podstatná část repertoáru se neformuje formální přípravou. Lortie (1975) ve své klasické sociologické studii učitelství ukázal, že budoucí učitelé procházejí dlouhým „učňovstvím pozorováním“ (apprenticeship of observation). Za školní léta stráví tisíce hodin sledováním učitelů z pozice žáka a z této zkušenosti si odnášejí intuitivní, biograficky ukotvené představy o tom, jak se učí a jak se zjednává pořádek. Tato tichá průprava má dvě zrádné vlastnosti. Je neúplná, protože žák vidí jen jevištní stránku vyučování, ne rozhodování, přípravu a záměry učitele; a je konzervativní, protože reprodukuje postupy, které byly ve třídách viditelné před lety, bez ohledu na jejich doloženou účinnost. Pregraduální příprava tuto průpravu podle Lortieho spíše doplňuje, než přepisuje.

Učňovství pozorováním vysvětluje, proč je podstatná část repertoáru tacitní: osvojila se nápodobou dřív, než ji bylo možné pojmově uchopit, a aktivuje se pod tlakem situace rychleji, než stačí proběhnout deliberace. Z toho plynou dva důsledky, které formovaly uspořádání knihy. Repertoár se špatně měří přímou otázkou: učitelé v dotaznících referují spíše o svých přesvědčeních a o tom, co považují za správné, než o tom, co v afektem nabitě situaci skutečně udělali. Popisy konkrétních situací, jaké shromažďuje korpus, se k jednání dostávají blíže; obdobnou cestou jde i domácí výzkum, který reaktivní a proaktivní strategie zachycoval přímým pozorováním praxe (Vlčková et al., 2020) nebo analýzou konkrétních kázeňských situací začínajících učitelů (Karasová a Nehyba, 2025). A má-li se repertoár rozšiřovat, nestačí předkládat poznatky; je třeba nabízet alternativní čtení konkrétních situací v okamžiku, kdy o nich učitel přemýšlí. Právě to je pedagogická sázka platformy Edustories, která ke vložené kazuistice nabízí řešení v šesti přístupech (kapitola 3). Čtyři přístupy z oddílu 2.2 tvoří jen část této nabídky.

Repertoár nejmenšího odporu

Spojí-li se učňovství pozorováním s časovým tlakem reálné situace, vzniká interpretační hypotéza, s níž kniha porovnává frekvence zaznamenaných postupů. Samotný mechanismus

2. Teoretická východiska

vzniku repertoáru empiricky netestuje. Repertoáry učitelů budou vychýleny k postupům, které jsou ve školní zkušenosti nejviditelnější a v situaci nejdostupnější: k reaktivním, individuálně zaměřeným zásahům typu domluvy, napomenutí nebo trestu. Proaktivní, systémové a na etablovaných rámcích postavené postupy budou naopak vzácné. Evidence oboru přitom směřuje opačně: metaanalýzy řízení třídy dokládají přínos proaktivních strategií a programů (Korpershoek et al., 2016) a přehledy praktik s empirickou oporou kladou důraz na prevenci a strukturu (Simonsen et al., 2008). Napětí mezi tím, co obor doporučuje, a tím, co repertoáry obsahují, je jedním z ústředních motivů knihy. Označujeme je jako repertoár nejmenšího odporu; pojem zavádíme zde, Studie 1 mu dává empirický obsah a kapitola 9 jej rozvíjí.

Osy popisu řešení

Aby bylo možné řešení v korpusu srovnávat mezi sebou i s řešeními generovanými, popisuje je kniha na třech osách odvozených z literatury o řízení třídy a doplňuje je čtvrtou, hodnotící dimenzí celkové vhodnosti pro danou situaci. Osa reaktivní–proaktivní odlišuje zásah po incidentu od utváření podmínek, jež incidentům předcházejí; není hodnotově zcela neutrální, protože prevence bývá v přehledové literatuře spojována s příznivějšími výsledky (Korpershoek et al., 2016; Simonsen et al., 2008). Osa humanistická–behaviorální odlišuje důraz na vztah, potřeby a dialog od důrazu na pravidla, důsledky a posilování; navazuje na dichotomii popsanou v českém diskurzu řízení třídy (Lukas a Lojdová, 2018). Osa systémová–situační odlišuje zásah na úrovni třídy či školy od zásahu mířícího na konkrétní incident. Tyto dvě osy jsou popisné, ne hodnotící; hodnocení nese vedle osy reaktivní–proaktivní především celková vhodnost. Všechny čtyři dimenze kniha používá ve Studii 3 při zaslepeném srovnání učitelských a generovaných řešení.

2.4 Velké jazykové modely v pedagogickém výzkumu

Od tématu k nástroji

Vzdělávací výzkum uchopil velké jazykové modely nejprve jako téma: jako technologii, jejíž příchod do škol je třeba promyslet. Vlivný poziční text shrnul příležitosti (personalizace, podpora učitelů, tvorba materiálů) i rizika (halucinace, zkreslení, ochrana dat, závislost) a zdůraznil potřebu kompetencí na straně učitelů i žáků (Kasneci et al., 2023). Systematický přehled využití jazykových modelů ve vzdělávání pak vedle přehledu automatizovaných úloh upozornil na slabou replikovatelnost a transparentnost publikovaných inovací a na nedostatečné ošetření etiky (Yan et al., 2024). Tato kniha vstupuje do jiné, mladší konverzace. Nezkoumá modely jako předmět, ale používá je jako výzkumný nástroj pro analýzu rozsáhlého korpusu pedagogického textu. Předpokladem takového užití je doložit, že model odvede práci srovnatelnou s lidským kóděrem, a znát hranice jeho spolehlivosti.

Model v roli anotátora

Konverzaci o jazykových modelech jako anotátorech otevřely v roce 2023 studie z výpočetní společenské vědy. Na vzorcích tweetů a novinových článků bylo doloženo, že model bez příkladů v instrukci (zero-shot) překonává v anotačních úlohách placené anotátory z crowdsourcingových platforem: přesnost byla v průměru o desítky procentních bodů vyšší, konzistencí model převyšoval i trénované anotátory a náklady byly řádově nižší (Gilardi et al., 2023). Navazující práce rozšířená na data z jedenácti zemí ukázala, že model při určování politické afiliace autorů zpráv překonává nejen anotátory z platforem, ale i expertní kodéry a supervidované klasifikátory, a to napříč jazyky (Törnberg, 2025). Tyto výsledky vysvětlují, proč se model v roli anotátora (LLM-as-annotator) rychle stal standardním kandidátem pro rozšíření obsahové analýzy tam, kde je lidské kódování úzkým hrdlem.

Následná vlna výzkumu počáteční optimismus zpřesnila. Systematická evaluace řady modelů na pětadvaceti úlohách výpočetní společenské vědy doložila, že v klasifikačních úlo-

2. Teoretická východiska

hách modely zpravidla nepřekonávají doladěné specializované klasifikátory, a doporučila je chápat jako partnera lidského výzkumníka, ne jako náhradu (Ziems et al., 2024). Metodologická varování upozornila, že výstupy modelu jsou nedeterministické a citlivé na drobné změny instrukce, takže konzistence může klesat pod prahy vědecké reliability; autor proto varuje před nasazením bez validace proti lidsky anotovaným datům (Reiss, 2023). Kritika z pozic otevřené vědy připomněla, že spoléhání na proprietární modely ohrožuje reprodukovatelnost výzkumu, protože poskytovatelé modely průběžně mění bez verzování a přístup k nim je uzavřený a zpoplatněný (Ollion et al., 2024). Z této literatury kniha přejímá tři zásady: shodu modelu s lidmi vždy poměřovat stropem, který vytváří reliabilita lidského kódování mezi lidmi navzájem (Studie 2); validovat na vlastních datech, ne přenášet cizí srovnávací sady úloh; a dokumentovat verze modelů i instrukcí (kapitola 4, přílohy B a C).

Model v roli posuzovatele a generátora

Vedle anotace se ustavila role modelu jako posuzovatele kvality textových výstupů (LLM-as-judge). Zakládající studie tohoto paradigmatu doložila, že silný model se v posuzování odpovídá shoduje s lidskými preferencemi srovnatelně, jako se lidé shodují mezi sebou. Zároveň však systematicky popsala zkreslení takového posuzování: citlivost na pořadí posuzovaných odpovědí, preferenci delších textů a sklon modelu nadhodnocovat vlastní výstupy (Zheng et al., 2023). Třetí rolí je model jako generátor obsahu, v pedagogickém kontextu typicky návrhů řešení či zpětné vazby. Kniha empiricky prověřuje jinou trojici: anotátora ve Studii 2, generátora ve Studii 3 a prediktora dopadu ve Studii 4. Ve Studii 3 jsou generovaná řešení hodnocena zaslepeně lidmi; nejde o test modelového posuzovatele. Role LLM-as-judge je zde teoretickým kontextem, nikoli samostatně ověřenou úlohou. Autorský tým přitom navazuje na starší zkušenost s hlubokými jazykovými modely nad reflektivními texty studentů učitelství (Nehyba a Štefánik, 2023), která předznamenala obrat od klasifikátorů trénovaných na míru k obecným generativním modelům.

Jazyková a doménová mezera přenosu

Zakládající studie oddílů mají společný rys, který se snadno přehlédne: téměř všechny pracují s anglickými texty z politické komunikace a sociálních médií. Tweety a novinové titulky, na nichž byla doložena převaha modelu nad anotátory (Gilardi et al., 2023), jsou texty krátké, veřejné a žánrově ustálené; i rozšíření na více zemí zůstalo v doméně politických zpráv (Törnberg, 2025) a evaluační úlohy výpočetní společenské vědy pokrývají příbuzné žánry (Ziems et al., 2024). Kazuistiky v tomto korpusu jsou jiné: dlouhé, narativní, emočně nasycené a psané česky, tedy v jazyce, který je v trénovacích datech modelů zastoupen řádově slaběji než angličtina. Kódovací kategorie navíc nesou pedagogickou teorii. Přenositelnost zakládajících výsledků na takový materiál je proto otevřená empirická otázka, ne bezpečný předpoklad. Totéž platí pro roli posuzovatele a generátora: pedagogická kvalita navrženého řešení je jemnější kritérium než preference mezi dvěma odpověďmi chatbota. Kniha tuto mezeru přenosu neobchází, ale činí z ní předmět měření: každou roli modelu prověřuje přímo na českém pedagogickém materiálu proti lidskému kódování s doloženou reliabilitou.

Český kontext

Český recenzovaný diskurz o umělé inteligenci v pedagogice se konsolidoval teprve nedávno a soustředí se kolem monotematického čísla časopisu *Pedagogika* věnovaného umělé inteligenci ve vzdělávání. Srovnávací studie národních politik dokládá rozdílnou připravenost zemí na integraci generativní umělé inteligence do škol a formuluje podmínky smysluplné integrace (Černochová et al., 2025); aplikační studie mapuje využití generativních nástrojů podle úrovně Bloomovy taxonomie (Kopecký et al., 2025); a přehledová studie demonstruje selhávání modelů na klasických logických úlohách a rámuje je jako principiální mez algoritmického porozumění (Honzík et al., 2025). Konceptuální práci o vymezení gramotnosti pro umělou inteligenci nabízí domácí přehledová studie (Černý, 2024). Pro rané období českého diskurzu je příznačné, že první systematické texty o ChatGPT ve školní praxi vyšly jako nerecenzovaná série na metodickém portálu (Černý, 2023).

2. Teoretická východiska

O rychlosti, s jakou generativní nástroje pronikly do českých škol, vypovídají především rozsáhlá šetření. Dotazníkové šetření mezi tisíci učiteli z jara 2023 ukázalo, že už tehdy měla s nástroji umělé inteligence zkušenost zhruba třetina učitelů a většina očekávala proměnu výukových metod i nároků na dovednosti (Kopecký et al., 2023). Navazující šetření mezi desítkami tisíc žáků základních a středních škol doložilo, že ChatGPT používá nadpoloviční většina žáků, výrazně častěji mimo školu než ve škole (Kopecký a Voráč, 2024). Resortní reakcí byla sada doporučení pro ředitele, učitele, žáky a rodiče vydaná před školním rokem 2023/2024 z podnětu ministerstva (Národní pedagogický institut ČR, 2023). Česká škola se tedy s generativní umělou inteligencí setkává masově a česká pedagogika ji začala reflektovat jako téma. Co v domácím diskurzu dosud chybí, je právě role, kterou rozvíjí tato kniha: jazykový model jako kriticky prověřený nástroj pedagogického výzkumu, nasazený na velký korpus autentického českého textu a poměřovaný lidským kódováním.

2.5 Průsečík obou linií a výzkumná mezera

Obě linie kapitoly se setkávají v jediném materiálu: v rozsáhlém, průběžně rostoucím korpusu autentických kazuistik náročného chování, psaných česky studenty učitelství a učiteli. Pedagogická linie klade otázku, co tento materiál vypovídá o repertoárech učitelů: jaké kategorie chování a řešení v něm převažují, jak se řešení kombinují a s jakými dopady, a jak daleko leží od normativního horizontu čtyř etablovaných přístupů. Metodologická linie klade otázku, co s takovým materiálem zvládne jazykový model: zda dokáže kódovat obsah srovnatelně s lidmi, zda generuje řešení, která obstojí v zaslepeném lidském hodnocení, a kde jeho spolehlivost končí. Odpovědi na obě otázky na sobě závisejí. Pedagogické závěry z velkého korpusu jsou dosažitelné jen s nástrojem použitelným ve velkém rozsahu a nástroj lze prověřit jen na materiálu, jehož pedagogický obsah je nezávisle popsán.

Mezera, kterou kniha zaplňuje, má tedy tři vrstvy. V české pedagogice chybí popis učitelských repertoárů řešení náročného chování opřený o velký soubor autentických situací. V mezinárodní literatuře o jazykových modelech jako nástrojích výzkumu chybí práce z pe-

2.5 Průsečík obou linií a výzkumná mezera

dagogického prostředí a z jazyka mimo angličtinu, která by anotaci, generování i predikci prověřila na jednom reálném korpusu proti lidskému kódování s doloženou reliabilitou. A na průsečíku obou chybí studie, která by obě otázky řešila současně a přiznala si vzájemnou podmíněnost svých odpovědí. Následující kapitoly tuto mezeru zaplňují: kapitola 3 popisuje projekt a platformu, kapitola 4 metodologii a kapitoly 5 až 8 čtyři empirické studie.

3. Projekt Edustories: kontext vzniku dat

Tato kapitola popisuje prostředí, ve kterém vznikla veškerá data této monografie: projekt Edustories. Vysvětluje, proč a jak se sbírají kazuistiky náročného chování žáků, jak vypadá platforma, která je zpřístupňuje učitelské veřejnosti, a proč jsou tytéž kazuistiky zároveň vzdělávacím obsahem pro učitele a výzkumným korpusem pro studium možností velkých jazykových modelů v pedagogickém výzkumu.

3.1 Východisko: proč sbírat kazuistiky náročného chování

Náročné chování žáků patří k nejčastěji uváděným problémům začínajících učitelů a k oblastem, na které se cítí nejméně připraveni. Tak to popsal už klasický přehled studií o začínajících učitelích (Veenman, 1984) a potvrzuje to i současný domácí výzkum (Karasová a Nehyba, 2025). Mezinárodní šetření TALIS 2024 dává tomuto obrazu čísla i pro Českou republiku: jen 31 % českých učitelů souhlasí, že jim počáteční vzdělávání dalo nápady, jak úspěšně zvládat chování ve třídě, což je nejnižší podíl ze všech zúčastněných zemí, a zvládnutí chování žáků je nejčastěji uváděnou oblastí velké potřeby dalšího vzdělávání, zvláště u začínajících učitelů (Havlíčková et al., 2025; OECD, 2025). Učitelská příprava přitom tradičně pracuje s obecnými principy řízení třídy, mnohem hůře však zprostředkovává to, co zkušení učitelé získávají léty praxe: repertoár konkrétních, situačně ukotvených řešení. Případové studie, tedy kazuistiky, jsou v přípravě pomáhajících profesí osvědčeným nástrojem, jak tuto zkušenostní mezeru překlenout. Autentický popis situace, jejího pozadí, zvoleného

3. Projekt Edustories: kontext vzniku dat

řešení a jeho výsledku umožňuje čtenáři zástupně prožít rozhodovací situaci dřív, než v ní bude stát sám.

Dostupné sbírky kazuistik však bývají malé, editorsky stylizované a statické. Projekt Edustories vznikl z opačné intuice: nechat kazuistiky psát přímo studující učitelství a učitele z praxe, sbírat je průběžně a ve velkém a zpřístupnit je jako živou, rostoucí databázi. Právě rozsah sbírky pak otevírá druhou, metodologickou otázku: co si s tak velkým korpusem nestrukturovaného pedagogického textu počne výzkum. Ruční analýza stovek až tisíců kazuistik naráží na kapacitní hranice kvalitativní metodologie. Velké jazykové modely slibují tuto hranici posunout, jejich spolehlivost v roli výzkumného nástroje však musí být teprve doložena. Obě linie, pedagogická i metodologická, se v této knize soustavně proplétají.

3.2 Projekt Edustories

Edustories je aplikovaný výzkumný projekt řešený na Pedagogické fakultě Masarykovy univerzity (MU) a podpořený Technologickou agenturou ČR v programu SIGMA (projekt TQ01000030, září 2023 až říjen 2026). Plný název, „Využití umělé inteligence a virtuální reality v rozvoji kompetencí k řešení výchovných situací ve škole“, vystihuje jeho aplikační ambice: cílem je podpořit studující učitelství a začínající učitele v kompetencích ke zvládnutí náročného chování, a to dvěma komplementárními, volně dostupnými cestami. První je webová platforma psaných kazuistik s podporou umělé inteligence; druhou je větev virtuální reality se simulovanými náročnými situacemi, která stojí mimo záběr této knihy. Projekt je založen multidisciplinárně na pomezí pedagogiky, psychologie a počítačové lingvistiky.

Projekt je zároveň dokladem toho, jak rychle se v posledních letech měnily technologické podmínky pedagogického výzkumu. Návrh vznikl na podzim 2022 a počítal s tehdejším stavem jazykových technologií: se sémantickým vyhledáváním podobných kazuistik, s algoritmy strojového učení pro predikci na základě anotací a s tréninkem respektující komunikace prostřednictvím konverzačního chatbota na specializované platformě. Jen několik

týdnů po dokončení návrhu však byl zveřejněn ChatGPT a nástup velkých jazykových modelů proměnil technické řešení projektu dříve, než začal. Generování alternativních řešení v pojmenovaných rámcích, jazyková podpora anonymizace i strojová klasifikace obsahu dnes stojí na velkých jazykových modelech. Záměr projektu, tedy rozvoj učitelských kompetencí skrze kazuistiky, se nezměnil; vyměnily se nástroje. Právě tato proměna je jedním z důvodů, proč kniha věnuje soustavnou pozornost kritickému prověření jazykových modelů jako výzkumného nástroje (Studie 2 až 4): projekt jejich možnosti využívá, ale jejich spolehlivost nepředpokládá, nýbrž měří. Výpočetní stránka projektu běží na akademické infrastruktuře Masarykovy univerzity a národní e-infrastruktuře.

Hlavním výstupem projektu je veřejná webová platforma edustories.cz. Ta zpřístupňuje zveřejněné kazuistiky s fulltextovým a významovým vyhledáváním. Jejím datovým základem je anonymizovaná databáze, která je rovněž výstupem projektu TA ČR. Ke každé kazuistice nabízí vedle autentického učitelského řešení také řešení generovaná umělou inteligencí v šesti pojmenovaných rámcích (proaktivní a reaktivní přístup, sociálně-emoční učení, pozitivní behaviorální podpora, restorativní praxe a nenásilná komunikace) a doplňuje je o gamifikované tréninkové moduly. Vedle platformy projekt průběžně vydává i výzkumná data, především kurátorovaný anotovaný výběr korpusu v anglickém překladu (datová sada Edustories-en, oddíl 3.4), a e-learningovou oporu v univerzitním informačním systému. Zveřejnění platformy nebo anglického výběru samo o sobě nepopisuje dostupnost všech verzí celé databáze. Pro tuto monografii je podstatné, že platforma není jen výstupem, ale i infrastrukturou sběru: databáze průběžně roste a každý její časový řez představuje jiný stav korpusu. Důsledky tohoto růstu pro analýzu rozebírá kapitola 4; přesné počty kazuistik v jednotlivých řezech dokládá kapitola 5.

3.3 Sběr kazuistik: zrcadlová šablona

Jádrem sběru jsou povinné pedagogické praxe studujících učitelství na MU. Studující podle strukturované šablony zaznamenají situaci náročného chování ze své pedagogické zkuše-

3. Projekt Edustories: kontext vzniku dat

nosti a popíše, v jaké roli v ní vystupovali a jak byla řešena. Šablona má dvě zrcadlové části: kazuistiku úspěšného řešení a kazuistiku řešení neúspěšného. Každá kazuistika má předepsanou čtyřdílnou strukturu: popis vzniku situace na úrovni chování, anamnézu žáka či třídy, popis zvoleného řešení a popis výsledku. K tomu šablona sbírá deskriptivní údaje o vyučujícím v dané situaci (aprobace, délka praxe, absolvované kurzy zvládání náročného chování) a o žákovi (věk, ročník, diagnózy, zájmy).

Sběr je přitom ukotven didakticky, nikoli jen logisticky. Zápis kazuistiky není administrativním úkonem po praxi, ale reflektivním aktem: pisatel musí situaci zpětně rozložit na pozorovatelné chování, jeho pozadí, zvolené řešení a výsledek, a tím ji podruhé, tentokrát analyticky, projít. Pro studující je tedy psaní kazuistiky samo o sobě učební příležitostí, která navazuje na reflektivní semináře doprovázející praxe. Pro projekt je zárukou, že texty vznikají v podpořeném prostředí, v němž lze uhlídat poučení o anonymizaci u zdroje i náležitosti informovaného prohlášení (oddíl 3.4). Tentýž akt, který rozvíjí pisatele, zároveň rozšiřuje korpus. Z povahy sběru plyne i složení korpusu, s nímž musí analýzy počítat: převažuje perspektiva studujících na praxi, tedy právě skupiny, pro niž je náročné chování nejpalčivější; věkové a další charakteristiky popsanych situací dokládá deskriptivně kapitola 5.

Zrcadlové uspořádání šablony má vlastní zdůvodnění. Sbírky dobré praxe trpí systematickým zkreslením přežití: neúspěchy se nezapisují, a čtenář tak získává dojem, že popsaná řešení fungují. Tím, že šablona vyžaduje od téhož pisatele úspěšně i neúspěšně řešenou situaci, vrací neúspěch do záznamu jako rovnocennou datovou kategorii. Pro výzkum repertoárů jsou přitom neúspěšná řešení přinejmenším stejně informativní jako úspěšná, protože ukazují, které postupy učitelé volí, i když nefungují. Šablona je tedy koncipována jako zrcadlový pár a z jednoho odevzdání mohou v databázi vznikat dvě samostatné kazuistiky; kniha proto při počítání jednotek korpusu důsledně pracuje s kazuistikami, nikoli s odevzdáními (kapitola 4). Čtyřdílná struktura navíc činí kazuistiky strojově zpracovatelnými: je jednotkou, se kterou pracují všechny anotační etapy i všechny experimenty s jazykovými modely v této knize.

3.4 Od textů ke korpusu: extrakce, anonymizace, publikace

Mezi odevzdaným textem studujícího a kazuistikou v databázi leží postup zpracování, který podrobně popisuje kapitola 4. Zde jej shrnujeme ve třech krocích. Nejprve extrakce a struktura: odevzdané soubory se programově rozdělují na jednotlivé kazuistiky a jejich čtyři části; tam, kde struktura není explicitní, asistuje jazykový model. Poté anonymizace, pojatá jako trojstupňová s následnou ruční kontrolou: první stupeň provádějí sami pisatelé (poučení, aby neuváděli identifikační údaje), druhý stupeň automatické rozpoznávání pojmenovaných entit pro češtinu, třetí stupeň jazykový model; výsledek se nakonec ručně kontroluje. Tento postup platí pro všechna data analyzovaná v této knize. Od července 2026 platforma anonymizační krok přesunula na národní e-infrastrukturu: náhradu osobních údajů provádí otevřený velký jazykový model provozovaný v akademickém prostředí e-INFRA CZ, a to zásadně před jakýmkoli případným voláním komerční služby; osobní údaje tak neopouštějí akademickou infrastrukturu. Nakonec publikace: kazuistiky, které projdou kontrolou kvality, se zveřejňují na platformě; část korpusu zůstává interní. Publikací status je proto samostatnou proměnnou korpusu a analýzy s ním musí explicitně pracovat. Pro výzkumnou komunitu je zveřejněn kurátorovaný, anotovaný výběr korpusu v anglickém překladu jako datová sada Edustories-en (Nehyba, Karasová a Štefánek, 2024); platforma sama slouží především praxi (studujícím učitelství, učitelům a dalším zájemcům), datová sada slouží výzkumu.

Rozlišení mezi platformou a datovou sadou je podstatné, protože v něm projekt odděluje dvě různé odpovědnosti. Publikace na platformě je produkční rozhodnutí: kazuistika prošla anonymizací a redakční kontrolou kvality a je užitečná čtenáři z praxe. Zařazení do výzkumné datové sady je rozhodnutí kurátorské a přísnější: do výběru vstupují kazuistiky, které prošly dokončeným lidským kódováním a jsou tedy vybaveny ověřenými anotacemi, s nimiž může výzkumná komunita dále pracovat. Datová sada proto není kopií databáze, ale jejím anotovaným výběrem k určitému datu; její rozsah a vztah k řezům korpusu dokládá kapitola 5. Pro reprodukovatelnost knihy z toho plyne praktický důsledek: analýzy neběží nad „živou“ platformou, ale nad datovanými řezy databáze, které lze zpětně dohledat (kapitola 4).

3. Projekt Edustories: kontext vzniku dat

Sběr probíhá s informovaným souhlasem přispěvatelů a bez sběru přímých osobních údajů; výzkumný projekt schválila Etická komise pro výzkum MU pod jednacím číslem EKV-2022-118. Spolehlivost anonymizace kniha kontroluje: nad náhodným vzorkem publikovaných kazuistik byl proveden systematický audit reziduálních osobních údajů, jehož postup a výsledky, včetně nalezených nedostatků a jejich řešení, dokládá příloha D. Měřit vlastní ochranné mechanismy stejně přísně jako výzkumné nástroje pokládá kniha za součást etiky práce s daty psanými reálnými lidmi o reálných dětech. Podrobný anonymizační protokol a znění informovaného prohlášení přispěvatele uvádí příloha D.

3.5 Tři anotační etapy

Nad rostoucím korpusem proběhly tři anotační etapy, na nichž stojí empirické studie knihy. Každá etapa měla vlastní cíl, vlastní kódovací schéma a vlastní posloupnost zaučování anotátorů: od zkušebních anotací přes společné rozborů sporných případů až po měřenou shodu a teprve poté finální anotování. Etapa první (2023 až 2024) kodovala obsah kazuistik do kategorií typů chování, typů řešení a dopadů; na ni navázalo srovnání lidského kódování s kódováním jazykovým modelem (Studie 2). Etapa druhá (2025) hodnotila v zaslepeném uspořádání kvalitu učitelských řešení proti řešením generovaným umělou inteligencí (Studie 3). Etapa třetí (2026) posuzovala kvalitu samotných kazuistik, dopad řešení a jeho vhodnost (Studie 4, kapitola 8). Deskriptivní obraz toho, co kazuistiky obsahují, podává na základě první etapy Studie 1.

Tři etapy na sebe navazují i logicky, jako stupně jednoho validačního žebříku. První etapa vytvořila lidské kódování obsahu, které je pro knihu dvojím základem: popisuje korpus (Studie 1) a zároveň slouží jako měřítko, vůči němuž se poměřuje strojová klasifikace, včetně stropu, který shodě modelu s lidmi vytváří shoda lidí mezi sebou (Studie 2). Druhá etapa tuto logiku obrací: místo aby lidé kontrolovali model v úloze, kterou umějí sami, hodnotí zaslepeně výstupy, u nichž nevědí, zda pocházejí od učitele, nebo od modelu; instrukce, která o původu řešení mlčela (krycí instrukce, kapitola 7), přitom chránila hodnocení před zkres-

lením očekáváním. Třetí etapa míří na hranice obou předchozích: ptá se, jak spolehlivě lze vůbec posoudit kvalitu kazuistiky a úspěšnost řešení, tedy konstrukty, u nichž se i lidští posuzovatelé shodují obtížně. Kniha tak postupně zužuje otázku, co jazykovému modelu v pedagogickém výzkumu svěřit lze a co nikoli.

Podstatným rysem, který odlišuje tuto knihu od izolovaných dílčích studií, je práce s překryvy: část kazuistik prošla více etapami, a tvoří tak přirozené spojnice mezi studiemi. Evidence těchto překryvů, multiplicita anotací a pravidla, jak s nimi analyticky nakládat, jsou popsány v kapitole 4 a doloženy v příloze C.

4. Metodologie

Kapitola popisuje metodologii knihy jako celku, aby jednotlivé studie mohly odkazovat na společný rámec: jak chápeme korpus v čase, jak proběhly tři anotační etapy, jak vznikala data od textu k analyzovatelné podobě, jaká kódovací schémata se použila, jak nakládáme s opakovanými anotacemi téže kazuistiky, jaké platí etické náležitosti a jak je zajištěna reprodukovatelnost.

4.1 Korpus jako časová řada řezů

Data nepocházejí z jednorázového sběru, ale z databáze, která v čase roste (kapitola 3). Každá analýza se proto váže na pojmenovaný časový řez korpusu, nikoli na „korpus“ obecně. Kniha pracuje s doloženými řezy od roku 2023 po export z května 2026 (přehled uvádí Tabulka 5.1 ve Studii 1). Z tohoto pojetí plynou dva důsledky, které platí napříč studiemi. Čísla z různých řezů nelze bez rozmyslu srovnávat ani slučovat; rozdíly ve velikosti korpusu odrážejí jeho růst a publikační pohyb, nikoli chybu. A publikační status kazuistiky (zveřejněná, či interní) je samostatná proměnná: řez z května 2026 obsahuje pouze zveřejněné kazuistiky, přičemž část dříve zveřejněných byla mezitím stažena. Analýzy proto s publikačním statusem pracují explicitně a nesměšují zveřejněné a nezveřejněné kazuistiky bez uvedení.

4.2 Tři anotační etapy a jejich zaučování

Nad korpusem proběhly tři anotační etapy (kapitola 3). Každá měla stejnou vnitřní logiku: zaučování anotátorek na malém vzorku, jedno či více kalibračních kol se společným rozbořem sporných případů, změření shody a teprve poté finální anotování. Tato posloupnost je pro interpretaci spolehlivosti zásadní, protože shodu vykazujeme z finálních kol, nikoli ze zácviků, a případný vývoj shody mezi kalibrací a finálem pojmenováváme jako samostatné zjištění (kapitola 9). Úplný registr etap, jejich kroků a zúčastněných anotátorek (pod pseudonymy) uvádí příloha C; zdrojové datové soubory jednotlivých událostí dokumentuje doprovodný repozitář.

Finální kolo první etapy (kvalitativní obsahové kódování) provádělo pět anotátorek formou dělby práce: každá kodovala jiné kazuistiky, aby se pokryl co největší rozsah korpusu, s vestavěným překryvem pro kontrolu shody. Druhá etapa (hodnocení kvality řešení) zapojila šest anotátorek, které v zaslepeném uspořádání hodnotily každou dvojici řešení nezávisle; materiál etapy tvořilo 324 kazuistik z kategorií agresivního chování (fyzická a verbální agrese), k nimž bylo jazykovým modelem vygenerováno alternativní řešení s vynucenou paritou délky a stylu (podrobně Studie 3 a příloha B).

Třetí etapa

Třetí etapa (kvalita kazuistik, dopad a vhodnost řešení) proběhla se dvěma anotátorkami, v knize pod pseudonymy A2 a A12, nad celým zveřejněným řezem z května 2026. Řez byl rozdělen na dvě poloviny s vestavěným překryvem: anotátorka A12 ohodnotila 1 947 kazuistik, anotátorka A2 dalších 1 938; obě společně hodnotily překryv 693 kazuistik, z něhož se počítá shoda. Etapa měla stejnou posloupnost jako předchozí: zácvik na šesti kazuistikách, první pilot na 19 kazuistikách a druhý pilot na 49 kazuistikách se společným rozbořem neshod, poté finální anotování od března do září 2026. Uprostřed finálního kola, v červenci 2026, se anotátorkám rozešla škála vhodnosti; etapa proto zařadila rekaliibraci, tedy společný podklad s kotvícími kazuistikami pro jednotlivé stupně škály a schůzku nad 40 spornými kazu-

istikami. Rekalibrace uprostřed sběru je změna protokolu; kniha ji vykazuje jako takovou a projednané kazuistiky vylučuje z primárního výpočtu shody (kapitola 8). Etapa byla uzavřena stop-rozhodnutím 8. září 2026, kdy vznikl řez K3_freeze_2026-09-08 z finálních tabulek obou anotátorek; dohodnuté známky u sporných případů, které anotátorky dodaly později, do řezu nevstupují a slouží jen jako referenční štítky. Průběh, shodu i její vývoj během etapy popisuje Studie 4 (kapitola 8).

4.3 Od textu k datům

Odevzdané texty procházejí postupem zpracování, jehož tři kroky (extrakce a struktura, vícestupňová anonymizace, publikace) shrnuje kapitola 3. Z metodologického hlediska jsou podstatné tři body. Extrakce dělí odevzdaný soubor na jednotlivé kazuistiky a jejich čtyři části, přičemž u části dat asistuje jazykový model; struktura se proto může u některých kazuistik lišit kvalitou a některé starší kazuistiky nesou stopy nedokonalé extrakce (viz oddíl 4.6). Anonymizace je trojstupňová s ruční kontrolou; její protokol uvádí příloha D a etické náležitosti shrnuje oddíl 4.7 (data analyzovaná v knize prošla první generací tohoto postupu; současný stav platformy, s anonymizací na národní e-infrastrukturu, popisuje příloha D.2). Publikace je selektivní, což zakládá proměnnou publikačního statusu (oddíl 4.1).

Pro analýzy je klíčové, že tytéž kazuistiky se objevují v různých řezech a souborech pod odlišnými identifikátory. Napříč knihou proto pracujeme s jednotným identifikátorem kazuistiky, který propojuje záznamy z různých řezů; tam, kde chybí sdílený identifikátor, se kazuistiky párují přes otisk textu, a nejednoznačné případy se neslučují. Tento krok je předpokladem jakéhokoli srovnání napříč etapami.

4.4 Kódovací schémata a řezy dat

Každá etapa má vlastní kódovací schéma; schémata se nesměšují. První etapa kodovala tři dimenze (typ chování, typ řešení, dopad) do kategorií, jejichž plné znění uvádí příloha A.

4. Metodologie

Druhá etapa hodnotila řešení na čtyřech ordinálních škálách a přidělovala rámcové štítky. Třetí etapa posuzovala kvalitu kazuistiky, dopad a vhodnost řešení na vlastních škálách. Škály nesoucí podobný název v různých etapách (například vhodnost v druhé a třetí etapě) mají odlišný rozsah i význam a nesmějí se slučovat. Jedinou výjimkou, kterou kniha používá, je dopad řešení: první etapa jej kódovala do čtyř kategorií a třetí do tří, a pro srovnání obou etap (kapitola 8) se částečný a krátkodobý úspěch první etapy slučují do jedné kategorie explicitním pravidlem, ne posuzovatelským úsudkem.

Toto sloučení kategorií však neodstraňuje rozdíl mezi popsáním výsledkem a hodnotovým posouzením. Historický manuál první etapy řadí mezi neúspěchy i eticky nepřijatelné prostředky; třetí etapa může takový případ označit za plochý. Z konečných štítků nelze spolehlivě rekonstruovat důvod tohoto rozhodnutí. Historická data nepřekódujeme odhadem: asociace proto interpretujeme jako vztahy mezi takto definovanými kategoriemi, nikoli jako nezávislé měření pedagogické účinnosti.

Deskriptivní výsledky první etapy (Studie 1) uvádíme na reprodukovatelném řezu 1 359 ručně kódovaných kazuistik. Tento řez je definován jednoznačným pravidlem (deduplikované kazuistiky z matice ze srpna 2024, jimž byla přiřazena lidská anotace) a je reprodukovatelný skriptem. Že anotační sloupce matice skutečně nesou lidské kódování, dokládá nezávislé srovnání s dochovanými anotačními listy etapy: množiny přiřazených kategorií se shodují u 97 % kazuistik u typu chování, u 95 % u typu řešení a u 98 % u dopadu; přímý lidský záznam se dochoval pro 1 350 kazuistik řezu. Dřívější dílčí výstupy projektu uváděly o něco nižší počet kódovaných kazuistik, odpovídající tehdejšímu stavu pracovní databáze; kniha pracuje výhradně s výše vymezeným řezem. Obdobně je vymezen řez třetí etapy K3_freeze_2026-09-08: finální tabulky obou anotátorek k 8. září 2026, spárované s kazuistikami zveřejněného řezu přes jednotný identifikátor (oddíl 4.3), s otisky souborů uloženými v doprovodném repozitáři.

4.5 Multiplicita anotací

Protože kazuistiky prošly etapami nerovnoměrně, je počítání s opakovanými anotacemi samostatným metodologickým problémem. Na úrovni jednotlivých etap je typické, že jedné kazuistice bylo přiřazeno více kategorií zároveň (kódování je víceznačné); frekvence proto vždy odlišujeme jako počet kazuistik s danou kategorií od počtu přiřazení. Na úrovni celku prošlo 973 kazuistik alespoň dvěma různými etapami a 236 všemi třemi; třetí etapa totiž pokryla téměř celý zveřejněný řez z května 2026, takže se překrývá s oběma předchozími. Počítáme-li jemněji jednotlivé anotační události (táž etapa mohla kazuistiku zasáhnout opakovaně, například v pilotním a finálním kole), bylo ve dvou událostech anotováno 790 kazuistik, ve třech 241, ve čtyřech 20 a v jednom případě v pěti; celkem tak více než jednou událostí prošlo 1 052 kazuistik. Přehled anotačních událostí dokládá příloha C; úplná matice pokrytí (kazuistika $\times$ událost) je součástí doprovodného repozitáře.

Z toho plyne závazné pravidlo: opakované anotace téže kazuistiky nejsou nezávislá pozorování. Všude, kde je to relevantní, proto modelujeme kazuistiku jako náhodný efekt (smíšené modely ve Studii 3), nikoli jako nezávislé jednotky, a nikde neslučujeme hodnocení téže kazuistiky napříč nekompatibilními škálami.

4.6 Známá omezení dat

Kniha pojmenovává tři známá omezení už v metodologii. Za prvé, 52 kazuistik bylo v minulosti dotčeno zkrácením textu při automatické extrakci; u menší části z nich je v aktuálním řezu doložena oprava, u většiny nikoli, a proto z analýz závislých na délce textu konzervativně vylučujeme všechny dotčené. Za druhé, kódovací schémata se mezi verzemi mírně vyvíjela (například počet kategorií řešení); verzi schématu proto u každé analýzy výslovně uvádíme a kategorie napříč verzemi nemapujeme mlčky. Za třetí, nízký koeficient shody mezi anotátory může mít dvě odlišné příčiny, které důsledně rozlišujeme: skutečnou nejednoznačnost úsudku danou jemností a překryvností kategorií, a silně nevyvážené rozdělení

4. Metodologie

odpovědí, které srazí koeficient i při vysoké hrubé shodě (paradox shody). Koeficienty proto všude uvádíme spolu s hrubou shodou a u silně nevyvážených škál třetí etapy doplňujeme i koeficient odolný vůči nevyváženosti (kapitola 8).

4.7 Etika

Sběr probíhal s informovaným souhlasem přispěvatelů a bez sběru přímých osobních údajů; výzkumný projekt schválila Etická komise pro výzkum Masarykovy univerzity pod jednacím číslem EKV-2022-118, s finálním schválením dne 27. 9. 2023. Autoři kazuistik přitom nejsou předmětem výzkumu; jejich postavení a informované prohlášení rozvádí příloha D. Kazuistiky jsou anonymizované a v datech ani v textu knihy nevystupují přímé identifikátory žáků, škol ani pisatelů; anotátorky uvádíme pouze pod projektovými pseudonymy A1 až A12. Ve veřejné tabulce K2 je samostatná lokální řada A1 až A6; shodné číslo neznamená totožnou osobu napříč těmito dvěma řadami. Nezveřejněné kazuistiky se nedostávají do žádných veřejných výstupů knihy. Znění informovaného souhlasu a anonymizační protokol uvádí příloha D.

4.8 Reprodukovatelnost

Příprava dat probíhá v jazyce Python, inferenční statistika v jazyce R s uzamčeným prostředím. Každá analýza je zapsána jako spustitelný dokument, který od zdrojových dat vytvoří výsledný report a tabulku výsledných hodnot (název míry a její hodnota, spolu s údajem o skriptu, verzi vstupních dat a nastavení náhodného výběru). Text knihy uvádí čísla jen z těchto tabulek a před každým sestavením knihy automatická kontrola ověřuje, že čísla v textu odpovídají výsledkům analýz a že každá citace má záznam v seznamu literatury. Analýzy přitom předcházejí próze: každá se nejprve uzavře nad verzovaným řezem dat a teprve poté se píše text s výsledky. Všechna čísla v knize jsou tak dohledatelná až ke skriptu a verzi dat.

Ověřitelnost nekončí u autora. Doprovodný repozitář zpřístupňuje analýzy v R, tabulky výsledných hodnot, HTML reporty, skripty obrázků i veřejnou datovou podmnožinu bez textů kazuistik a bez osobních údajů; jeho součástí je český návod, jak si čísla knihy ověřit bez programátorských znalostí, a konfigurace prostředí pro opakování analýz. Studie 1 a 2 jsou přepočitatelné z veřejných odvozených dat, která nenesou texty kazuistik ani jména: Studie 1 z tabulky počtů slov, věku a publikačního statusu na úrovni kazuistiky a z anotačních štítků, Studie 2 z tabulky kategorií přiřazených člověkem a modelem. Studie 3 se přepočítá z tabulky hodnocení dvojic řešení, v níž jsou anotátorky pod pseudonymy a která neobsahuje texty kazuistik; její úplná podoba (včetně textů) je uložena v balíčku na platformě OSF (odkaz bude zveřejněn s publikací souvisejícího článku, do té doby na vyžádání). Studie 4 se přepočítá z tabulky hodnocení třetí etapy, opět bez textů a pod pseudonymy. Doprovodný repozitář nezpřístupňuje úplné textové vstupy těchto analýz. Odvozené tabulky umožňují přepočet statistik, nikoli opakování samotného kódování, generování odpovědí nebo prověření anonymizace. Součástí reprodukce jsou i uložené predikce; nové volání modelu je jiný experiment. Historické monitorovací a provenienční souhrny se přebírají jako označené vstupy. Toto vymezení doprovodného balíčku nepředjímá budoucí vydání nejnovější databáze.

Empirické studie

5. Studie 1: Korpus a jeho obsah

První studie odpovídá na otázku, jak vypadá vybudovaný korpus kazuistik a co obsahuje (VO1). Popisuje rozsah a růst korpusu (5.1), základní charakteristiky kazuistik (5.2), typy chování, řešení a dopadů, které kazuistiky zachycují (5.3), souběhy řešení s typy chování (5.4) a vztah řešení k vnímanému výsledku (5.5). Všechny analýzy kapitoly jsou deskriptivní; kapitola nedělá kauzální závěry.

5.1 Rozsah a růst korpusu


Korpus je průběžně rostoucí databáze (kapitola 3). Analýzy se proto vždy vážou na pojmenovaný časový řez. Tabulka 5.1 shrnuje velikost korpusu v doložených řezech od nejstaršího sběru po aktuální stav.

Tabulka 5.1. Růst korpusu v pojmenovaných časových řezech.

Řez	Počet kazuistik
2023	757
duben 2024	1 507
srpen 2024	1 695
veřejná datová sada*	1 492
květen 2026	3 202

5. Studie 1: Korpus a jeho obsah

Poznámka. Podklady v doprovodném repozitáři: [zdrojová čísla](#)[↗], [analýza v R](#)[↗]; definice řezů viz metodologie, kap. 4. *Veřejná datová sada není chronologickým bodem růstu: jde o kurátorovaný výběr z řezu srpen 2024, zveřejněný jako samostatný datový produkt; uvedený počet jsou záznamy výběru, nikoli unikátní kazuistiky (příloha C.2).




Obrázek 5.1. Růst korpusu v chronologických řezech (hodnoty viz Tabulka 5.1; veřejná datová sada jako kurátorovaný výběr není bodem růstu, proto ve figuře chybí). *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla](#)[↗], [kód obrázku](#)[↗].

Nejnovější řez z května 2026 obsahuje 3 202 zveřejněných kazuistik. Růst není prostou akumulací: srovnání se starším exportem téhož období ukazuje, že 395 kazuistik, přítomných v dřívějším exportu, se v aktuálním řezu již nevyskytuje, protože byly mezitím staženy z publikace. Stažení patří k redakčnímu životu databáze; konkrétní důvody jednotlivých stažení data nezaznamenávají a kniha je proto nerekonstruuje. Pro výzkum z toho plyne zásadní důsledek: „korpus“ bez data není definovaný objekt a jakákoli replikace se musí vztáhnout k datovanému řezu, nikoli k živé databázi. Publikáční status je proto samostatnou proměnnou, s níž analýzy pracují explicitně (kapitola 4). Veřejně dostupná datová sada (kapitola 3) je kurátorovaný výběr z řezu srpen 2024 čítající 1 492 záznamů, jež odpovídají 1 246 unikátním kazuistikám (příloha C.2); rozdíl mezi ním a plným řezem není jen početní, ale i

kvalitativní, protože do výběru vstupovaly kazuistiky s dokončeným lidským kódováním.

5.2 Základní charakteristiky kazuistik

Kazuistiky mají čtyřdílnou strukturu (kapitola 3) a jsou to souvislé texty střední délky. V aktuálním řezu má popis situace medián 102 slov (mezikvartilové rozpětí 76 až 148), popis řešení medián 102 slov (74 až 154), anamnéza medián 79 slov (66 až 109) a popis výsledku medián 68 slov (43 až 102). Rozdělení délek jsou pravostranně zešíkmená s dlouhým chvostem podrobných textů; desetina popisů situace přesahuje 221 slov (Obrázek 5.2). Statistiky délky konzervativně vylučují všech 52 kazuistik dotčených dřívějším zkrácením textu při automatické extrakci (kapitola 4).




Obrázek 5.2. Rozdělení délek čtyř částí kazuistiky (počet slov; houslový graf s vyznačeným mezikvartilovým rozpětím a mediánem; pro čitelnost oříznuto na 99. percentil). *Poznámka.* Podklady v doprovodném repozitáři: [data obrázku ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

Pisatelé věnují nejvíce slov popisu situace a řešení, zatímco výsledek bývá odbyt několika větami: je systematicky nejkratší částí kazuistiky. Pro pedagogické čtení to znamená, že korpus je bohatší na to, co učitelé dělali, než na to, jak to dopadlo; pro strojové zpracování to předznamenává, že právě predikce úspěšnosti řešení (Studie 4) bude pracovat s nejtenčí textovou

5. Studie 1: Korpus a jeho obsah

oporou.

Medián věku žáka, jehož se kazuistika týká, je 13 let (mezikvartilové rozpětí 10 až 15 let; údaj o věku je uveden u 3 142 kazuistik; patnáct záznamů s nulovým věkem, kódem nevyplněného pole, bylo vyřazeno jako chybějící). Rozložení věku (Obrázek 5.3) pokrývá celou školní docházku s těžištěm na druhém stupni základní školy; zastoupeny jsou ale i situace z mateřských a středních škol. Korpus tedy zachycuje náročné chování především tam, kde je literatura lokalizuje nejčastěji, v pubertálním období, aniž by na ně byl omezen. Šíře věkového rozpětí má praktický význam pro obě linie knihy. Pedagogicky umožňuje číst tytéž kategorie chování napříč stupni; nepozornost prvňáka a nepozornost deváťáka jsou různé jevy pod jedním štítkem, což je třeba mít na paměti při interpretaci frekvencí. Metodologicky znamená, že jazykový model je v dalších studiích prověřován na textech o dětech od předškolního věku po adolescenty, tedy v plně širší situaci, s nimiž by se podpůrný nástroj v praxi potkal.



Obrázek 5.3. Rozložení věku žáků v kazuistikách (počet kazuistik podle uvedeného věku).
Poznámka. Podklady v doprovodném repozitáři: [data obrázku](#)[↗], [analýza v R](#)[↗], [kód obrázku](#)[↗].

5.3 Co kazuistiky zachycují: chování, řešení, dopady

Deskriptivní obraz obsahu čerpáme z první anotační etapy na reprodukovatelném řezu 1 359 ručně kódovaných kazuistik (vymezení řezu i doklad lidské provenience kódů uvádí kapitola 4). Kódování je víceznačné: jedné kazuistice mohla anotátorka přiřadit více kategorií. Frekvence proto uvádíme jako počet kazuistik, v nichž se kategorie objevila; celkový počet přiřazení je vyšší než počet kazuistik. U typů chování připadá na jednu kazuistiku v průměru 1,84 kategorie, u typů řešení 2,29, zatímco dopad je téměř vždy jediný (poměr 1,01). Náročné situace zřídka sestávají z jediného projevu a učitelé na ně zřídka odpovídají jediným krokem; řešení jsou v reálné praxi kombinacemi. Typická kazuistika tak nese dvojici projevů (například verbální agrese spolu s narušováním výuky) a dvojici až trojici kroků řešení (například rozhovor se žákem, informování rodičů a zapojení poradenského pracoviště). Tento rys má metodologické důsledky, k nimž se kniha opakovaně vrací: frekvence kategorií nelze počítat do sta procent, míry shody musí víceznačnost zohledňovat (Studie 2) a jednotkou ko-výskytových analýz v oddílu 5.4 je pár kazuistika × kategorie.


Nejčastěji zachycenými projevy jsou verbální agrese (v 330 kazuistikách), verbální narušování výuky (328), fyzická agrese (299), nepozornost a nevěnování se výuce (293) a porušování třídních či školních pravidel (255). Úplné rozdělení všech třinácti kategorií ukazuje Obrázek 5.4. Rozdělení klesá pozvolna a bez dominance jednoho projevu; nezanedbatelné zastoupení mají i závažné a organizačně náročné kategorie jako šikana, emoční výbuchy nebo problémy s docházkou. Korpus tedy nepokrývá jen běžnou nekázeň, ale celé spektrum situací, se kterými se učitelé setkávají.

Kódovací strom první etapy nabízel kategorií čtrnáct. Čtrnáctou byla „Diagnóza“, definovaná jako „žák/žákyně má diagnostikovanou některou z diagnóz speciálních vzdělávacích potřeb“. Tato definice ovšem nepopisuje chování, ale stav žáka, takže do dimenze problémového chování nepatří; z deskriptivy je proto vyřazena a diagnóza vstupuje do analýzy jako kontextová proměnná (oddíl 5.4). Nešlo o chybu sběru dat; kategorie byla shodně v nabídce u všech pěti anotátorek. Šlo o vadu konstrukce kódovacího stromu, kterou data potvrzují ze tří stran. Kategorie se v naprosté většině výskytů objevovala jako přívěsek k jinému, sku-

5. Studie 1: Korpus a jeho obsah

tečně behaviorálnímu kódu; anotátorky ji používaly nesouměřitelně často; a shoda na ní byla nejnižší v celé dimenzi, takže její vyřazení míru shody typů chování zvyšuje (kapitola 6). Podrobný doklad uvádí příloha A.

Neplnění školních povinností (201 kazuistik) ukazuje, že za náročné učitelé nepovažují jen jednání namířené proti nim nebo proti spolužákům, ale i pasivní vzdor vůči školní práci. Na samém konci rozdělení stojí sebedestruktivní chování; jeho výskyt je řádově desítkový, ale právě u něj je cena chybného řešení nejvyšší, což z něj činí důležitý testovací případ pro jakoukoli budoucí podpůrnou technologii. Pro čtení všech frekvencí zároveň platí opatrnost formulovaná v kapitole 4: kategorie odrážejí to, co pisatelé považovali za hodné zaznamenání, nikoli epidemiologii náročného chování v českých školách; nadreprezentace dramatických situací je u dobrovolně psaných kazuistik očekávatelná.



Obrázek 5.4. Typy náročného chování v první anotační etapě (počet kazuistik s kategorií; kódování je víceznačné). *Poznámka.* Podklady v doprovodném repozitáři: [data obrázku ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

V repertoáru učitelů výrazně dominuje rozhovor, přítomný v 922 kazuistikách, následovaný

spoluprací s odborníky (461), podporou žáka (342), prací s důsledky (245) a upozorněním (229).




Obrázek 5.5. Nejčastější typy řešení v první etapě (počet kazuistik s kategorií; kódování je víceznačné, hodnoty viz text). *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla](#), [kód obrázku](#).

Skladba repertoáru je pro tuto knihu podstatná: převažují snadno dostupné postupy reagující na již vzniklý incident. Samostatnou proaktivní kategorii finální kódovací schéma (V2) neobsahuje, proto proaktivitu v první etapě přímo nekvantifikujeme; reaktivní charakter repertoáru potvrzuje bipolární dimenze reaktivní–proaktivní ve Studii 3 (kapitola 7). Jednu výjimku je třeba uvést: vysoko v žebříčku stojí spolupráce s odborníky, tedy krok, který překračuje hranici třídy a zapojuje poradenský systém školy. Reaktivnost repertoáru tedy neznamená, že by učitelé zůstávali na řešení sami; znamená, že i kroky za hranici třídy jsou typicky spouštěny až incidentem, nikoli prací s podmínkami, které mu předcházejí. Toto čtení, které ve Studii 3 poslouží jako srovnávací pozadí pro řešení generovaná umělou inteligencí, komentuje jako „repertoár nejmenšího odporu“ diskuse v kapitole 9.

Vnímaný výsledek řešení je nejčastěji dlouhodobý úspěch (598 kazuistik) nebo naopak neúspěch (483), méně často částečný (158) či krátkodobý úspěch (84). Bimodální tvar rozdělení (Obrázek 5.6) je přímým důsledkem sběru zrcadlovou šablonou (kapitola 3): pisatelé ode-

5. Studie 1: Korpus a jeho obsah


vzdávají úspěšně a neúspěšně řešenou situaci v páru, a korpus se tak vyhýbá zkreslení přezítí, jímž trpí typické sbírky dobré praxe. Mezi krajními póly leží jen málo případů: částečný a krátkodobý úspěch dohromady tvoří menšinu dopadů. I to je pravděpodobně důsledek šablony, která pisatele vede k volbě jednoznačně vydařené a jednoznačně nevydařené situace; reálná praxe bude na částečné úspěchy bohatší, než korpus ukazuje, a Studie 4 s touto výhradou u posuzování dopadů dále pracuje.



Obrázek 5.6. Dopady řešení v první anotační etapě (počet kazuistik s kategorií). *Poznámka.* Podklady v doprovodném repozitáři: [data obrázku ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

5.4 Jak se řešení pojí s chováním

Frekvence kategorií říkají, co učitelé dělají; neříkají, kdy to dělají. Obrázek 5.7 proto ukazuje podmíněné podíly: pro každý typ chování podíl kazuistik s tímto chováním, v nichž se objevilo dané řešení. Jednotkou je pár kazuistika $\times$ kategorie (kódování je víceznačné, kapitola 4), do analýzy vstupují typy chování s dostatečným počtem kazuistik a podíly se čtou po řádcích; jde o popis souběhů v kazuistikách, nikoli o doporučení či kauzální vztah.



Obrázek 5.7. Podmíněné podíly řešení podle typu chování, $P(\text{řešení} \mid \text{chování})$: podíl kazuistik s daným chováním, v nichž se objevilo dané řešení. Řádky = typy chování (seřazeny podle četnosti), sloupce = typy řešení; kódování je víceznačné, řádkové podíly se proto ne-sčítají do 1. *Poznámka.* Podklady v doprovodném repozitáři: [data obrázku ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

Obrázek ukazuje především univerzalitu rozhovoru: je nejčastějším řešením u všech typů chování a jeho podíl kulminuje u šikany, kde se objevuje v 81 % kazuistik. Jde o četnost zmínek, nikoli o pořadí jednání učitele. Zastoupení dalších postupů se mezi typy situací liší; analýza však neurčuje, který krok byl první, druhý nebo třetí. U šikany je nadprůměrně častá práce s kolektivem (37 % kazuistik se šikanou oproti výrazně nižším podílům, nejvýše kolem jedné pětiny, u ostatních typů chování), což odpovídá skupinové povaze jevu. U porušování pravidel je nadprůměrně časté sahání k důsledkům (35 %) a tam, kde pisatel popisuje nezvládnutí výuky, se vedle rozhovoru rovným dílem objevuje podpora (64 %).

Totéž ukazuje srovnání dvou zdánlivě podobných řádků. U verbálního narušování výuky, typického drobného incidentu, se vedle rozhovoru (59 %) objevují se srovnatelnou četností podpora žáka (31 %) a upozornění (31 %), tedy vedle práce s příčinami i okamžitá, nízkonákladová korekce v běhu hodiny. U neplnění školních povinností, které je v korpusu rovněž časté, ale má pomalejší dynamiku, okamžitá korekce ustupuje: upozornění klesá na 14 %, za-

5. Studie 1: Korpus a jeho obsah


tímco vedle rozhovoru (66 %) stojí spolupráce s odborníky (40 %) a podpora žáka (39 %). Tam, kde incident nevyžaduje zásah v běhu hodiny, tedy z repertoáru mizí především okamžitá korekce; práce s příčinami zůstává. Repertoár se tedy podle situace liší, ale až za univerzální první volbou a v mezích převážně reaktivních kategorií.

Samostatnou otázkou je, zda se repertoár mění tam, kde má žák zaznamenanou diagnózu. Protože diagnóza není typem chování, čteme ji z kurátorovaného pole korpusu, nikoli z anotace: vyplněné je u 530 kazuistik řezu, tedy u 39 %. Zřetelný posun se týká jediné kategorie. Podpora žáka se v těchto kazuistikách objevuje ve 37 % oproti 25 % v celém řezu; opačným směrem se posouvají důsledky (13 % oproti 18 %) a nerespektující komunikace (9 % oproti 11 %). Spolupráce s odborníky přitom zůstává prakticky beze změny (36 % oproti 34 %): zaznamenaná diagnóza sama nevede k častějšímu zapojení poradenského pracoviště. Tam, kde je diagnóza známa, tedy učitelé sahají spíše k podpoře než k sankci, ale mezioborový krok tím nepřibývá. I zde jde o popis souběhů: kazuistiky s diagnózou se liší i skladbou situací, takže rozdíl v podílech nelze číst jako účinek diagnózy samotné.

5.5 Dopad podle typu řešení

Historický kód neúspěchu zahrnuje nejen nezměněné chování, ale také normativní odmítnutí nevhodného prostředku (příloha A.1). Z konečných štítků tyto důvody nelze oddělit. Následující asociace proto popisují vztah anotačních kategorií, nikoli nezávisle zjištěnou účinnost strategií.

Poslední deskriptivní pohled spojuje řešení s vnímaným výsledkem. Obrázek 5.8 ukazuje pro každý typ řešení podíl kazuistik s tímto řešením, které skončily dlouhodobým úspěchem. I zde platí, že jde o popis souběhů: typ řešení si učitelé nevybírají náhodně, ale podle situace, takže rozdíly mezi řešeními odrážejí i rozdílnou skladbu situací, v nichž se používají. Z podílů proto nelze vyvozovat, že by některé řešení úspěch způsobovalo.



Obrázek 5.8. Podíl kazuistik s dlouhodobým úspěchem podle typu řešení (deskriptivně; n = počet kazuistik s daným řešením a uvedeným dopadem). *Poznámka.* Podklady v doprovodném repozitáři: [data obrázku ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

Rozdíly jsou přesto zřetelné. Nejvyšší podíl dlouhodobého úspěchu vykazují kazuistiky s prací s kolektivem (67 % z 178 kazuistik), s dohodou (63 %) a s podporou žáka (50 %); rozhovor, univerzální první volba, leží uprostřed (49 %). Na opačném konci stojí kategorie mocenského vynucení: kázeňské tresty (39 %), přemístění žáka (37 %), fyzické zakročení (27 %) a nerespektující komunikace, u níž pisatelé referují dlouhodobý úspěch nejméně často (22 %). Deskriptivně tedy platí, že vztahová a systémová řešení se v korpusu vyskytují spolu s příznivějšími vnímanými výsledky než řešení represivní. To je v souladu s poznatky shrnutými v kapitole 2; kauzální čtení by však vyžadovalo jiné uspořádání studie a kniha se ho zdržuje.

Dva mechanismy, které mohou vzorec spoluutvářet, je třeba uvést, protože ukazují, co by kauzální čtení muselo vyloučit. Prvním je selekce situací: k práci s kolektivem nebo k dohodě učitel sahá typicky tam, kde situace ještě dohodu připouští, zatímco fyzické zakročení je z povahy věci vyhrazeno situacím eskalovaným, jejichž vyhlídky jsou horší bez ohledu na zvolený zásah. Druhým je pohled pisatele: dopad hodnotí tentýž člověk, který řešení volil a popsal, takže vnímaná úspěšnost může být přikrášlena u řešení, s nimiž se pisatel identifi-

5. Studie 1: Korpus a jeho obsah

kuje. Zrcadlová šablona (kapitola 3) druhý mechanismus částečně krotí, protože neúspěchy do korpusu aktivně přivádí; selekci situací však žádný sběr tohoto typu neodstraní. Právě proto kniha vzorec předkládá jako popis souběhů a jeho silnější čtení ponechává studiím s uspořádáním, které by umělo situace srovnávat.

5.6 Shrnutí

Studie 1 popsala korpus jako rostoucí databázi, jejíž aktuální zveřejněný řez z května 2026 čítá 3 202 kazuistik, s doloženým publikačním pohybem v čase. Kazuistiky jsou souvislé texty střední délky se čtyřdílnou strukturou, v níž je popis výsledku systematicky nejkratší; těžištěm korpusu je druhý stupeň základní školy. Obsahově dominují verbálně a fyzicky agresivní projevy a projevy narušující výuku; v řešeních převažuje rozhovor a další dostupná, převážně reaktivní řešení. Podmíněné podíly ukázaly, že repertoár se diferencuje podle situace až za univerzální první volbou rozhovoru, a deskriptivní spojení řešení s dopady ukázalo, že vztahová a systémová řešení se v kazuistikách pojí s příznivějšími vnímanými výsledky než řešení represivní. Tento základ otevírá otázky dalších studií: nakolik spolehlivě lze takový obsah kódovat jazykovým modelem (Studie 2) a jak si učitelská řešení stojí ve srovnání s generovanými (Studie 3).

6. Studie 2: Jazykový model jako anotátor

Druhá studie se ptá, zda velký jazykový model dokáže kódovat obsah kazuistik tak, aby se shodl s vyškolenými lidskými anotátorkami (VO2). Shodu dokládá pro dimenzi typu řešení, tedy nejjemnější a nejbohatší část schématu; kódování chování a dopadu modelem neověřuje. Postupuje od kódovacího schématu a shody mezi lidmi (6.2, 6.3) ke shodě modelu s lidmi, souhrnně, po kategoriích i na úrovni jednotlivých záměn (6.4), a ke kvalitativnímu pohledu na neshody (6.5).

6.1 Východiska

Kapitola 5 ukázala, co kazuistiky obsahují, na řezu, který bylo možné ručně okódovat. Ruční kódování je však úzké hrdlo: rostoucí korpus (kapitola 3) brzy přeroste kapacitu, kterou lidští anotátoři unesou. Přirozenou úvahou je proto použít jazykový model jako anotátor, který týměž kódovacím schématem zpracuje libovolně velký objem textu. Taková úvaha ovšem stojí a padá s doložením, že se model s lidmi shoduje. Studie 2 proto srovnává lidské kódování s modelovým na sdíleném vzorku kazuistik. Že se srovnání opírá právě o dimenzi typu řešení, není náhoda: je to dimenze s nejjemnějšími a nejvíce se překrývajícími hranicemi mezi kategoriemi a, jak ukáže oddíl 6.3, také s nejnižší shodou mezi lidmi. Pokud model obtojí zde, obtojí pravděpodobně i na hrubších dimenzích; opačný závěr z hrubší dimenze by neplatil. Zároveň jde o dimenzi, na níž stojí ústřední pedagogické čtení knihy, repertoáry řešení, takže právě u ní je doložená spolehlivost nejcennější.

6.2 Metoda

Kódovací schéma a lidské kódování

Ve finálním kole první anotační etapy (kapitola 3) kódovalo pět vyškolených anotátorek kazuistiky do tří dimenzí: typ náročného chování, typ řešení a dopad řešení. Schéma vzniklo induktivně otevřeným kódováním na části korpusu a bylo zpřesněno do kódovacího stromu (příloha A). Finální anotování probíhalo jako dělba práce: každá anotátorka kódovala jiné kazuistiky, aby se pokryl co největší rozsah korpusu, s vestavěným překryvem sloužícím ke kontrole shody. Údaje o spolehlivosti proto počítáme na tomto překryvu, deskriptivní frekvence uvádí Studie 1. U typu chování vstupuje do výpočtu třináct behaviorálních kategorií; kontextová položka původního stromu, která pouze zaznamenávala přítomnost diagnózy žáka, je stejně jako v deskriptivě Studie 1 vyřazena (oddíl 5.3 a příloha A).

Modelové kódování a srovnávací vzorek

Nad týmž korpusem provedl jazykový model deduktivní klasifikaci řešení podle stejného schématu. Pro srovnání lidského a modelového kódování slouží archivní soubor 334 řádků. Jeden neobsahuje lidský štítek; hlavní přepočít proto zahrnuje 333 úplných dvojic. Prázdný štítek nepovažujeme za další kategorii řešení. Že oba sloupce nesou to, co mají, bylo ověřeno proti anotační matici korpusu: lidský sloupec se s ní shoduje v 99 % případů, zatímco modelový jen v 72 %; modelový sloupec je zároveň totožný s hlavní kategorií finálního klasifikačního běhu (shoda 100 %). Srovnání pracuje s 12 kategoriemi řešení: jedenácti kategoriemi kódovací knihy první etapy a kategorií proaktivního řešení, kterou model dostal v klasifikačním promptu (příloha A); pozdější veřejná datová sada používá odlišnou variantu schématu s jinou sadou štítků, kterou v souladu s pravidly této knihy nesměšujeme s verzí použitou zde.


Míry shody

Shodu mezi lidmi kvantifikujeme Krippendorffovým α (nominálním) na jednotkách kazuistika $\times$ anotátorka a doplnkově průměrným párovým Jaccardovým indexem přes všechny přiřazené kategorie (schéma je víceznačné). Shodu lidí a modelu vyjadřujeme přesnou shodou na primární kategorii, rozšířenou shodou (lidská kategorie se objeví mezi kategoriemi modelu) a Cohenovým κ . Všechny míry doplňujeme 95% intervaly spolehlivosti z bootstrapu přes kazuistiky (tisíc opakování).

6.3 Shoda mezi lidskými anotátorkami

Na překryvové podmnožině dosahovala shoda pěti anotátorek různých hodnot podle dimenze. U dimenze dopadu byla vysoká, $\alpha = 0,72$ (95% CI 0,63 až 0,81, na 85 společně kódovaných kazuistikách), což odpovídá tomu, že dimenze dopadu má jen několik zřetelně odlišných kategorií. U typu chování byla shoda střední, $\alpha = 0,50$ (0,41 až 0,58), zatímco u typu řešení nejnižší, $\alpha = 0,29$ (0,19 až 0,38). Obrázek 6.1 tyto hodnoty shrnuje spolu s klíčovou mírou následujícího oddílu; shoda modelu s lidmi se čte na pozadí toho, jak se shodují lidé mezi sebou.

6. Studie 2: Jazykový model jako anotátor



Obrázek 6.1. Reliabilita kódování: Krippendorffovo α shody mezi anotátorkami po dimenzích a Cohenovo κ shody člověk × model u typu řešení (95% intervaly spolehlivosti z bootstrapu; svislice vyznačují konvenční prahy 0,667 a 0,80). Obě míry pocházejí z odlišného uspořádání (pět anotátorek na překryvu vs. konsolidovaný lidský kód × model na srovnávacím vzorku) a figura je řadí vedle sebe pro orientaci, ne jako přímo srovnatelné hodnoty (oddíl 6.4). *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

Nižší shodu u typu řešení vysvětluje především jemnost a překryvnost jeho kategorií: totéž řešení lze legitimně zařadit pod více blízkých kategorií, což α (které trestá každou neshodu stejně) tlačí dolů. Přispívá k tomu i silně nerovnoměrné rozdělení kategorií v čele s rozhovorem (paradox shody, kapitola 4). Ukazuje to i pohled zohledňující víceznačnost kódování: průměrný párový Jaccardův index, který částečný překryv přiznává, dosahuje u řešení 0,56, u chování 0,61 a u dopadu 0,86. Tato zjištění mají přímý důsledek pro následující srovnání s modelem i pro celou knihu. Frekvenční výsledky Studie 1 uvádíme na úrovni kategorií, ne jako přesné jednotlivé klasifikace, a hlubší psychometrické čtení jednotlivých kódů typu řešení by přesahovalo spolehlivost, kterou data unesou.

6.4 Shoda jazykového modelu s lidmi

Na srovnávacím vzorku se model shodl s lidskou primární kategorií řešení v 72 % případů (95% CI 68 % až 77 %). Připustíme-li rozšířenou shodu, tedy případy, kdy se lidská kategorie objeví mezi kategoriemi přiřazenými modelem, stoupá shoda na 93 %. Cohenovo κ , které koriguje shodu očekávanou náhodou, dosahuje hodnoty 0,64 (95% CI 0,58 až 0,70), což se konvenčně řadí k dobré shodě.

Tyto výsledky nejsou důkazem dosažení ani překročení lidské úrovně. Vícehodnotitelské nominální α pěti anotátorek na malém překryvu a κ konsolidovaného lidského kódu vůči modelu na jiném vzorku neodhadují tutéž veličinu. Z jejich rozdílu nelze stanovit lidský strop. Neshody mohou souviset s nejednoznačností schématu i s chybami modelu; tento design jejich podíly neodděluje. U vzácných kategorií navíc zůstává odhad nejistý. Výsledek podporuje kontrolované použití modelových kategorií, nikoli nahrazení lidského úsudku ani nezávisle ověřenou generalizaci.


Dodatečná kontrola překryvu příkladů

Při revizi byly v příkladech archivovaného promptu nalezeny celé texty řešení 36 případů ze srovnávacího souboru. Kontrola sjednotila Unicode, velikost písmen a mezery a hledala úplné řešení v příkladové části archivní buňky. Nejde o detekci parafrází ani o doklad, že je dochován přesný prompt každého požadavku; úplné záznamy požadavků nejsou k dispozici. Srovnávací soubor proto nelze označit za nezávislý test bez překryvu s příklady.

Retrospektivní citlivostní analýza vylučuje tyto shody i neúplný lidský štítek. Na 297 případech činí přesná shoda 71 % a $\kappa = 0,61$. Interval spolehlivosti κ sahá od 0,55 do 0,68. Příznaky překryvu bez textů a úplné výsledky obsahuje veřejný analytický report. Tato kontrola neodstraňuje jiné možné vazby mezi vývojem promptu a testem. Silnější tvrzení vyžaduje nový oddělený soubor, který nebyl použit při tvorbě instrukcí.

Shoda po kategoriích

Souhrnné κ zakrývá, že spolehlivost modelu není napříč kategoriemi stejná. Obrázek 6.2 proto rozkládá přesnou shodu podle lidské kategorie řešení. U zdaleka nejčastější kategorie, rozhovoru, se model shodl s lidmi v 77 % případů ($n = 155$); vysokou shodu má i upozornění (76 %, $n = 17$) a důsledky (75 %, $n = 16$). Nejnižší mezi kategoriemi s více než hrstkou případů leží podpora žáka, u níž se model shodl s lidmi v 56 % případů ($n = 43$), tedy právě u kategorie, která je významově nejširší. Prakticky stejně nízko je i dohoda, tu však nese jen devět případů. U kategorií s jednotkami případů čísla uvádíme jen pro úplnost; nelze z nich usuzovat.




Obrázek 6.2. Přesná shoda modelu s lidským kódem po kategoriích řešení (n = počet kazuistik s danou lidskou kategorií). *Poznámka.* Podklady v doprovodném repozitáři: [data obrázku ↗](#), [zdrojová čísla ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

Anatomie záměn

Konfuzní matice (Obrázek 6.3) ukazuje, kam neshody směřují, a dokládá, že záměny nejsou nahodilé. Více než čtvrtina případů, které lidé kódovali jako podporu žáka, dostala od modelu štítek proaktivního řešení. Obě kategorie popisují vstřícné jednání ve prospěch žáka a

liší se především časováním (podpora reaguje, proaktivní řešení předchází), tedy rozlišením, které je v retrospektivním textu často nejednoznačné. Kategorie proaktivního řešení přitom v lidském kódování první etapy pochází od jediné anotátorky (chybně sestavený výběrový seznam, viz příloha A). Zde proto vystupuje prakticky jen jako štítek predikovaný modelem, jemuž byla kategorie nabídnuta v promptu, ne jako plnohodnotná lidská kategorie. Pětina případů nerespektující komunikace skončila u modelu jako rozhovor, což odráží skutečnost, že toto jednání má v kazuistikách typicky podobu slovní výměny s žákem a model se přiklonil k jejímu doslovnému, hodnotově neutrálnímu čtení. Záměny tedy kopírují významové hranice mezi kategoriemi; totéž ukázala analýza lidské shody (oddíl 6.3), kde tytéž hranice snižovaly α .



Obrázek 6.3. Konfuzní matice lidského a modelového kódu řešení (řádkově normalizované podíly; řádky = lidský kód, sloupce = kód modelu; prázdné buňky = podíl menší než 0,005). *Poznámka.* Podklady v doprovodném repozitáři: [data obrázku ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

6.5 Kvalitativní pohled: tři neshody zblízka

Z neshodných případů, jejichž text řešení je zveřejněn na platformě (kniha zásadně necituje nezveřejněné texty), jsme náhodně vylosovali vzorek kandidátů a vybrali z něj tři případy ilustrující navzájem odlišné mechanismy neshody. Citace jsou doslovné, včetně pravopisu.

„Nemělo cenu s ním na tu chvíli chodit do kabinetu, když za chvíli byla přestávka. Nechala jsem ho tedy být a po chvíli jsem se snažila s ním příklady dopočítat, neúspěšně. Zazvonilo na přestávku a před začátkem další hodiny jsem se ještě jednou pokusila s ním příklady vypočítat, ale marně, tak bohužel musel dostat příklady za úkol na doma, protože ty příklady dodělat musí.“ (člověk: rozhovor; model: přemístění žáka)

První případ ukazuje citlivost na zmíněné, ale neuskutečněné jednání. Text přemístění žáka výslovně zavrhuje („nemělo cenu s ním chodit do kabinetu“), přesto model tuto kategorii zvolil; nabízí se čtení, že reagoval na přítomnost tématu přemístění bez ohledu na negaci, byť z jediného případu nelze mechanismus doložit. Pro praxi strojového kódování je to připomínka, že klasifikace podle povrchových vodítek může selhat právě tam, kde pisatel zvažuje a odmítá alternativy.

„Vyučování pokračovalo a nic se neřešilo. Ten den se mi ozvala matka žáka, že takovému jednání se jí nelíbí. Já jsem samozřejmě o té situaci neměla žádné bližší informace, tak jsem jako třídní napsala, že o tom bohužel nic nevím a ať se obrátí na tu konkrétní paní učitelku.“ (člověk: nerespektující komunikace; model: rozhovor)

Druhý případ odlišuje hodnotící a doslovné čtení. Anotátorka jednání vyhodnotila jako nerespektující komunikaci, tedy kategorii, která nese normativní úsudek o kvalitě jednání; model kódoval doslovný komunikační akt, výměnu zpráv, jako rozhovor. Neshoda tu není omylem v pravém slova smyslu: je rozdílem mezi popisem toho, co se stalo, a soudem o tom, jak se to stalo. Právě hodnotící kategorie se ukazují jako nejtěžší disciplína strojového kódování, což odpovídá obrazu z konfuční matice.

„Domlouvání studentovi nezabíralo. A tak se pan ředitel domluvil s maminkou žáka a kamarády u policie, že studenta přijdou ‚vytáhnout z postele‘. A tak jej přišli vzbudit a policie v tomto případě zapůsobila. Platilo na něj jen takové vystrašení. Hned se posbíral a utíkal do školy. Asi si konečně uvědomil možné následky svého chování.“ (člověk: rozhovor; model: práce s kolektivem)

Třetí případ ukazuje vícečetné jednání, na které je jednoznačný primární kód krátký: v řešení vystupuje ředitel, matka i policie a obhajitelných kategorií je několik. Neshoda modelu s primárním kódem anotátorky tu z velké části odráží víceznačnost samotné situace; při rozšířené shodě, která připouští více kategorií modelu (oddíl 6.4), může být hodnocen jinak. Vybrané případy ilustrují možná vysvětlení neshody, nikoli systematické rozdělení příčin všech chyb. Pro praxi strojového kódování z toho plyne konkrétní doporučení: nasazení modelu na velký korpus by mělo být doprovázeno lidskou kontrolou právě u hodnotících a významově širokých kategorií, zatímco u kategorií zřetelně ohraničených lze modelu důvěřovat více. Paušální míra shody takové rozlišení neumožňuje, rozklad po kategoriích ano.

6.6 Shrnutí

Studie 2 doložila, že jazykový model kóduje typy řešení náročného chování ve shodě s lidskými anotátkami na úrovni Cohenova $\kappa = 0,64$, tedy dobré shody, s přesnou shodou 72 % a rozšířenou shodou 93 %; platí to pro dimenzi typu řešení, na niž se srovnání omezovalo. Po vyloučení zjištěných překryvů s příklady zbývá $\kappa = 0,61$; tato dodatečná analýza není novým nezávislým testem. Lidské α z jiného uspořádání nelze použít jako výkonový strop modelu. Rozklad po kategoriích ukázal, že spolehlivost modelu je nejvyšší u frekventovaných a zřetelně ohraničených kategorií a nejnižší u kategorií významově širokých. Konfuzní matice a kvalitativní analýza neshod doložily, že záměny kopírují významové hranice schématu (podpora versus proaktivní řešení, hodnotící versus doslovné čtení jednání) a ilustrují významovou nejednoznačnost některých kódovacích rozhodnutí. Vybrané příklady však neurčují podíl všech chyb způsobených schématem. Model proto v této knize slouží jako nástroj

6. Studie 2: Jazykový model jako anotátor

pro rozšíření obsahové analýzy, ne jako autorita nahrazující lidské kódování. Následující kapitola obrací pozornost od klasifikace řešení k jejich kvalitě a srovnává řešení generovaná modelem s řešeními učitelů.

7. Studie 3: Řešení generovaná umělou inteligencí versus řešení učitelů

Třetí studie odpovídá na otázku, jak se řešení náročných situací generovaná velkým jazykovým modelem liší od autentických řešení, která zvolili učitelé (VO3). Využívá druhou anotální etapu: zaslepené hodnocení dvojic řešení šesti vyškolenými anotátorkami na čtyřech pedagogických dimenzích a v úloze rozpoznávání rámců opřených o důkazy. Kapitola popisuje materiál a uspořádání studie (7.2), dokládá spolehlivost hodnocení (7.3) a předkládá výsledky smíšených modelů (7.4).

7.1 Východiska

Kapitola 2 vymezila generování řešení jako jednu ze tří rolí, v nichž kniha jazykový model prověřuje; otevřenou otázkou zůstává, zda generované návrhy obstojí před měřítky pedagogické kvality: vhodností pro danou situaci, poměrem prevence a reakce, hodnotovou orientací a systémovostí zásahu. Přímé srovnání na autentických případech přitom naráží na zjevný metodologický problém: kdyby hodnotitelé věděli, které řešení pochází od stroje, jejich očekávání by hodnocení kontaminovala. Druhá etapa proto byla navržena jako zaslepená: anotátorky hodnotily obě řešení téže kazuistiky, aniž věděly, že jedno z nich je generované.

7.2 Metoda

Materiál

Z korpusu (kapitola 5) bylo vybráno 324 kazuistik z kategorií agresivního chování (fyzická a verbální agrese), tedy ze závažného a silně zastoupeného segmentu korpusu, s úplným popisem situace i učitelského řešení. Ke každé kazuistice bylo modelem gpt-4o vygenerováno alternativní řešení se stejným zadáním, jaké implicitně řešil učitel; prompt vynucoval paritu délky, gramatického rodu a minulého času, aby povrchové rysy textu neprozrazovaly jeho původ. Šlo o jediné srovnávací řešení generované jednotným promptem; se šesticí rámcovaných řešení, která nabízí platforma (kapitola 3), se nezaměňuje. Postup výběru a generování shrnuje kapitola 4, prompt je uveden v příloze B.

Hodnocení

U každé dvojice řešení bylo plánováno hodnocení všech 6 anotátorek, a to nezávisle a v zaslepeném, znáhodněném pořadí (krycí instrukce bez zmínky o AI). Každé řešení bylo posuzováno na čtyřech ordinálních pětibodových dimenzích: celková vhodnost pro danou situaci, orientace reaktivní versus proaktivní, orientace humanistická versus behaviorální a zaměření systémové versus situační. V analyzovaném souboru jsou všechny čtyři uloženy na škále od -2 do $+2$ (vhodnost byla v kódovacím formuláři zadávána jako pětibodová a pro analýzu lineárně překódována). Vedle škál anotátorky označovaly, zda řešení rozpoznatelně odráží některý z rámců opřených o důkazy (sociálně-emoční učení, pozitivní behaviorální podpora, nenásilná komunikace, restorativní praxe). Závěk proběhl ve dvou kalibračních kolech s rozbořem neshod; jeho průběh dokládá registr anotačních etap v příloze C. Soubor hodnocení obsahuje 15 476 hodnoticích polí (kombinace kazuistiky, řešení, dimenze a anotátorky), z nichž 1 600 (přibližně desetina) zůstalo nevyplněno; chybění nebylo rozloženo rovnoměrně mezi anotátorky a analýzy pracují se všemi vyplněnými odpověďmi. V dochovaných řádcích činí podíl prázdných hodnocení 11 % u řešení generovaných, 10 % u učitelských. Úplný plán obsahuje 15 552 buněk, ale 76 řádků v exportu zcela chybí, všechny

u učitelského zdroje. Celkem tedy chybí 1 676 hodnocení. Zaslepení samo nezaručuje náhodné chybení: vynechání mohlo souviset s vlastnostmi textu nebo s nejistotou anotátorky. Rozpis podle zdroje, dimenze a anotátorky obsahuje veřejný report.

Ve veřejné tabulce K2 mají anotátorky lokální označení A1 až A6. Tato řada není totožná s projektovými pseudonymy v knize a neslouží k propojování osob napříč etapami; veřejný převodník osob nezveřejňujeme.

Analýza

Primárním modelem je lineární smíšený model (LMM) s pevným efektem zdroje řešení (referenční kategorie AI) a náhodnými průsečíky pro kazuistiku a anotátorku; tím model zohledňuje opakovaná hodnocení týchž případů i systematické rozdíly v přísnosti hodnotitelů. Jeho koeficient má přímočarou interpretaci v bodech škály, zachází však s pětibodovou škálou, jako by vzdálenosti mezi sousedními stupni byly stejné.


Předem stanovenou citlivostní analýzou je proto kumulativní logitový smíšený model (CLMM), který tento předpoklad nepotřebuje. Hodnocení v něm vystupuje jako uspořádaná kategoriální proměnná a model popisuje kumulativní pravděpodobnosti, tedy šanci, že hodnocení nepřekročí daný stupeň škály, přes čtyři prahy mezi pěti stupni. Logit každé kumulativní pravděpodobnosti je lineární funkcí týchž členů jako v primárním modelu: pevného efektu zdroje řešení a náhodných průsečíků pro kazuistiku a anotátorku. Model předpokládá proporcionalitu šancí: jediný efekt zdroje posouvá všechny prahy stejně. Exponenciála koeficientu je pak poměr šancí (odds ratio, OR). OR menší než jedna znamená, že učitelské řešení má oproti řešení generovanému nižší šanci dosáhnout vyššího stupně škály, a to u kterékoli hranice mezi stupni, při hodnocení téže kazuistiky touž anotátorkou; OR větší než jedna znamená šanci vyšší. Model odhadujeme metodou maximální věrohodnosti (balík ordinal, funkce clmm) a k odhadům uvádíme Waldovy 95% intervaly spolehlivosti. Závěry se opírají o LMM; CLMM slouží k ověření, že směr a věrohodnost efektů nestojí na předpokladu stejných vzdáleností mezi stupni škály. Protože uspořádání je párové uvnitř kazuistiky, doplňujeme ještě druhou citlivostní analýzu: LMM s náhodným sklonem zdroje

7. Studie 3: Řešení generovaná umělou inteligencí versus řešení učitelů

po kazuistikách, který připouští, že se rozdíl mezi zdroji případ od případu liší (oddíl 7.4). Spolehlivost hodnocení vyjadřujeme Krippendorffovým α (ordinálním) s 95% intervaly spolehlivosti získanými bootstrapem přes kazuistiky a u rámců průměrným párovým Jaccardovým indexem.

7.3 Spolehlivost hodnocení

Shoda šesti anotátorek na jednotkách kazuistika $\times$ řešení dosahovala hodnot $\alpha = 0,53$ (95% CI 0,49 až 0,57) pro vhodnost, $\alpha = 0,65$ (0,61 až 0,68) pro dimenzi reaktivní–proaktivní, $\alpha = 0,53$ (0,49 až 0,57) pro dimenzi humanistickou–behaviorální a $\alpha = 0,56$ (0,52 až 0,59) pro dimenzi systémovou–situační. Obrázek 7.1 hodnoty shrnuje. Jde o střední míru položkové shody, očekávatelnou u úsudkových škál tohoto typu; nejvyšší shody dosahovala dimenze reaktivní–proaktivní, jejíž póly jsou v textu řešení nejsnáze rozpoznatelné (zásah po incidentu versus práce s podmínkami). Podstatné je, že smíšené modely v oddíle 7.4 s mezipo-
suzovatelskou variabilitou přímo počítají, takže závěry o rozdílu mezi zdroji řešení na položkové shodě nestojí. Vývoj shody mezi kalibračními koly a finálním anotováním, včetně jeho možných příčin, komentujeme v kapitole 9.



Obrázek 7.1. Reliabilita hodnocení: Krippendorffovo ordinální α podle dimenzí (95% intervaly spolehlivosti z bootstrapu přes kazuistiky; svislice vyznačují konvenční prahy 0,667 a 0,80). *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

Hodnocené konstrukty jsou úsudkové: co je pro danou situaci „vhodné“, závisí na pedagogickém přesvědčení hodnotitelky a čtyři osy vyžadují vážení protichůdných signálů v jednom textu. Škály tohoto typu zpravidla nedosahují reliability jednoduchých klasifikací ani po pečlivém zácviku; podstatné je, že zbylá neshoda je v analýze modelována, ne zamlčena. Zároveň hodnoty připomínají, proč kniha důsledně mluví o „hodnocené vhodnosti“, a ne o vhodnosti samé: měříme úsudek vyškolených posuzovatelek, konsenzuální konstrukt, jehož nejistotu známe a přenášíme ji do intervalů spolehlivosti výsledků.

U rozpoznávání rámců dosahoval průměrný párový Jaccardův index hodnoty 0,73 v konvenci, která shodu dvou prázdných množin počítá jako souhlas (tj. obě anotátorky se shodly, že řešení žádný rámec nenese). Protože většina řešení žádný rámec nenesla, uvádíme pro úplnost i přísnou konvenci bez prázdných průniků, kde index klesá na 0,12; rozdíl obou konvencí je dalším projevem paradoxu shody při šikmých rozděleních, který podrobně rozebírá kapitola 4.

7.4 Výsledky

Deskriptivní obraz

Tabulka 7.1 shrnuje průměrná hodnocení podle zdroje řešení. Slovník kvality přitom náleží jen dimenzím, které ji nesou (oddíl 2.3): jednoznačně příznivěji pro generovaná řešení vyznívá vhodnost a orientace reaktivní–proaktivní. Obě zbývající osy jsou popisné. Na ose humanistická–behaviorální se generovaná řešení klonila k humanistickému pólu a učitelská k behaviorálnímu; na ose systémová–situační se oba zdroje klonily k situačnímu pólu, generovaná řešení o něco výrazněji, byla tedy nepatrně vzdálenější systémovému pólu než řešení učitelů.


Tabulka 7.1. Průměrná hodnocení řešení podle zdroje (škály –2 až +2).

7. Studie 3: Řešení generovaná umělou inteligencí versus řešení učitelů

Dimenze	AI	Učitel
Vhodnost	1,56	0,71
Reaktivní–proaktivní	0,69	−0,32
Humanistická–behaviorální	−0,44	0,34
Systémová–situační	0,35	0,17

Poznámka. Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [analýza v R ↗](#).


Vedle rozdílů jsou podstatné i absolutní polohy průměrů. Průměrné hodnocení vhodnosti generovaných řešení 1,56 leží blízko stropu pětibodové škály, což znamená, že anotátorky generovaná řešení nejen preferovaly, ale hodnotily je téměř jednohlasně jako vhodná; zároveň to ohlašuje stropový efekt, kvůli němuž může být skutečný rozdíl na horním konci škály podhodnocen. Učitelská řešení přitom s průměrem 0,71 nejsou hodnocena záporně: leží nad středem škály, na straně spíše vhodných řešení. Učitelská řešení tedy nebyla hodnocena jako špatná; generovaná vedle nich působila ještě vhodněji.



Obrázek 7.2. Průměrná hodnocení řešení podle zdroje (hodnoty viz Tabulka 7.1; oranžově řešení generovaná umělou inteligencí, modře řešení učitelů; u bipolárních dimenzí odpovídá záporný pól reaktivnímu, humanistickému a systémovému řešení). *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [kód obrázku ↗](#).

Primární modely

Lineární smíšené modely potvrzují, že rozdíly nejsou důsledkem opakovaných měření ani rozdílné přísnosti anotátovek. Učitelská řešení byla oproti generovaným hodnocena jako méně vhodná, s rozdílem $-0,85$ bodu škály (95% CI $-0,90$ až $-0,81$) a jako výrazně reaktivnější, s rozdílem $-1,01$ bodu ($-1,07$ až $-0,95$). Na hodnotové dimenzi se učitelská řešení posouvala k behaviorálnímu pólu o $0,77$ bodu ($0,71$ až $0,83$), zatímco na dimenzi systémové–situační byl rozdíl nejmenší: $-0,17$ bodu ($-0,23$ až $-0,11$), oba zdroje se klonily k situačním zásahům.



Obrázek 7.3. Efekty zdroje řešení ze smíšených modelů: rozdíl učitel – AI v bodech škály s 95% intervalem spolehlivosti (hodnoty viz text; nula = žádný rozdíl mezi zdroji). *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [kód obrázku ↗](#).

Rozpoznávání rámců

Anotátorky přiřadily celkem 874 rámcových štítků; z nich 72 % připadlo na řešení generovaná umělou inteligencí. Logistický smíšený model s náhodnými průsečíky pro kazuistiku a anotátorku ukazuje, že učitelské řešení mělo výrazně nižší šanci být rozpoznáno jako ne-soucí některý z pojmenovaných rámců: poměr šancí $0,31$ (95% CI $0,26$ až $0,38$); šance učitelského řešení na rozpoznání rámce byla tedy zhruba třetinová. Vztaheno k prostým četnostem to odpovídá přibližně dvaapůlnásobku: generovaná řešení nesla necelé tři čtvrtiny

7. Studie 3: Řešení generovaná umělou inteligencí versus řešení učitelů

všech rámcových štítků, učitelská zbytek.

Podstatné je, že srovnávací řešení nebyla generována s instrukcí držet se některého z přístupů: vznikala jednotným promptem bez rámcového zadání (oddíl 7.2). Rámcové rysy, které v nich anotátorky rozpoznávaly, tedy nejsou splněním explicitního zadání, ale vlastností textu, který model o řešení náročné situace typicky produkuje. Zjištění má dvě výhody. Rozpoznání rámce je úsudek s nízkou shodou mezi anotátorkami (oddíl 7.3), takže vypovídá spíše o celkové tendenci než o spolehlivé klasifikaci jednotlivých řešení; a rozpoznání rámce není totéž co věrné uplatnění přístupu, k němuž by texty musely posoudit expertky na příslušné rámce.


Citlivostní analýza

Kumulativní logitové smíšené modely (specifikace v oddíle 7.2) potvrzují směr všech čtyř efektů; Tabulka 7.2 uvádí poměry šancí s intervaly spolehlivosti a Obrázek 7.4 je vynáší na logaritmické ose.

Tabulka 7.2. Citlivostní CLMM: poměr šancí pro zdroj = učitel (referenční kategorie AI; Waldovy 95% intervaly spolehlivosti).

Dimenze	OR	95% CI
Vhodnost	0,06	0,05 až 0,07
Reaktivní–proaktivní	0,11	0,09 až 0,12
Humanistická–behaviorální	5,38	4,68 až 6,19
Systémová–situační	0,77	0,68 až 0,88

Poznámka. Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [analýza v R ↗](#).



Obrázek 7.4. Citlivostní CLMM: poměry šancí pro zdroj = učitel na logaritmické ose (95% Waldovy intervaly spolehlivosti; svislice OR = 1 značí žádný rozdíl mezi zdroji; hodnoty viz Tabulka 7.2). *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [kód obrázku ↗](#).

Čtení tabulky ilustrujme na vhodnosti: OR 0,06 znamená, že šance učitelského řešení na překročení kterékoli hranice mezi stupni škály (například na hodnocení „spíše vhodné a lepší“ místo „neutrální a horší“) je při hodnocení téže kazuistiky touž anotátorkou zhruba šestnáctkrát nižší než u řešení generovaného. Interval spolehlivosti je úzký a hluboko pod jedničkou, efekt tedy nestojí na předpokladu stejných vzdáleností mezi stupni škály. Obdobně silný je efekt u orientace reaktivní–proaktivní; u hodnotové dimenze míří opačným směrem (učitelská řešení mají vyšší šanci na behaviorálnější hodnocení) a u dimenze systémové–situační je nejslabší, byť i jeho interval leží celý pod jedničkou. Shoda směru mezi primárním a citlivostním modelem na všech čtyřech dimenzích splňuje předem stanovené kritérium robustnosti.

Druhá citlivostní analýza uvolňuje předpoklad stejného rozdílu mezi zdroji napříč kazuistikami: LMM s náhodným sklonem zdroje po kazuistikách konvergoval u všech čtyř dimenzí bez singularit a odhady efektů se od primárního modelu prakticky neliší (u vhodnosti –0,86 bodu s 95% CI –0,93 až –0,78; u dimenze systémové–situační, kde je efekt nejslabší, –0,16 bodu s intervalem –0,27 až –0,05, stále celým pod nulou). Závěry tedy nestojí ani na předpokladu konstantního rozdílu mezi zdroji.

7. Studie 3: Řešení generovaná umělou inteligencí versus řešení učitelů

Dodatečná analýza pouze úplných dvojic uvnitř kombinace kazuistiky, anotátorky a dimenze zachovává směr všech čtyř rozdílů. U vhodnosti vychází rozdíl učitel minus AI $-0,86$ bodu, s intervalem od $-0,90$ do $-0,82$. Výsledek omezuje obavu, že hlavní směr závisí pouze na neúplných dvojicích, ale nedokazuje náhodnost chybení.

7.5 Shrnutí

Studie 3 v zaslepeném uspořádání porovnála 324 dvojic řešení hodnocených šesti anotátorkami na čtyřech dimenzích. Primární smíšené modely ukázaly, že řešení generovaná umělou inteligencí byla hodnocena jako vhodnější a proaktivnější, učitelská jako behaviorálnější. Citlivostní ordinální modely (Tabulka 7.2) směr všech efektů potvrdily s intervaly spolehlivosti ležícími celými mimo hodnotu žádného rozdílu, stejně jako druhá citlivostní analýza s náhodným sklonem zdroje po kazuistikách. Spolehlivost hodnocení byla střední; náhodné efekty zohledňují závislost hodnocení, neodstraňují však veškerou chybu měření. Dodatečný přepočít na úplných dvojicích ověřuje citlivost na zacházení s chybením. Ani tento přepočít nedokazuje, že jsou chybějící odpovědi náhodné. Přibližně dvaapůlkrát častěji podle prostých četností rozpoznávaly anotátorky v generovaných řešeních rámce opřené o důkazy (oddíl 7.4). Učitelská řešení byla reaktivnější a behaviorálnější, což odpovídá obrazu „repertoáru nejmenšího odporu“ ze Studie 1.

Interpretace však vyžaduje zdrženlivost, kterou rozvíjí kapitola 9. Hodnocena byla textová podoba řešení, ne jeho proveditelnost v reálné třídě. Učitelé řešili situaci v čase a pod tlakem, zatímco model formuloval odpověď bez těchto omezení. Přes vynucenou paritu délky a stylu nelze zcela vyloučit, že jazykové rysy generovaného textu hodnocení ovlivnily. A výsledky se vážou k jedinému modelu (gpt-4o) a jediné instrukci, takže je nelze bez dalšího zobecňovat na jazykové modely obecně ani na jiné způsoby generování. Studie proto nedokládá, že „AI radí lépe než učitel“. Dokládá, že generovaná řešení mají textové vlastnosti, které vyškolení hodnotitelé spojují s kvalitním, proaktivním a rámcově ukotveným postupem; pro zamýšlenou podpůrnou roli takových systémů je to zjištění podstatné.

Právě podpůrné čtení výsledky spojuje se zbytkem knihy. Studie 1 ukázala repertoár vychýlený k reaktivním, situačním zásahům; Studie 3 ukazuje, že generovaná řešení nabízejí právě ten typ řešení, který v repertoáru chybí: proaktivnější a rámcově ukotvený. Generované řešení tak může učiteli nad konkrétní situací zviditelnit alternativy, jež jeho repertoár nenabízí, aniž by nahrazovalo jeho úsudek o proveditelnosti. Zda takový kontrast skutečně rozšiřuje repertoár, je otázka pro intervenční studii, kterou tato kniha nedělá; její výsledky pro ni ale vymezují realistické očekávání i rizika, včetně toho, že textová přesvědčivost není totéž co pedagogická proveditelnost. Následující kapitola (Studie 4) obrací pozornost od řešení k samotným kazuistikám a ptá se, jak spolehlivě lze posoudit jejich kvalitu.

8. Studie 4: Kvalita kazuistik, spolehlivost jejího posouzení a predikce úspěchu řešení

Čtvrtá studie obrací pozornost od řešení k samotným kazuistikám. Ptá se, jakou mají kvalitu, jak spolehlivě ji lze posoudit a nakolik dokáže jazykový model předvídat úspěšnost řešení (VO4). Využívá třetí anotační etapu, v níž dvě vyškolené anotátorky posuzovaly celý zveřejněný řez korpusu ve třech dimenzích: kvalita kazuistiky, dopad řešení a vhodnost řešení. Kapitola popisuje materiál a průběh etapy včetně rekaliibrace uprostřed sběru (8.2), rozdělení hodnocení (8.3), spolehlivost posouzení a její vývoj (8.4), spojení s první etapou, které dovoluje ptát se, jaké typy řešení se pojí s úspěchem (8.5), a predikční experiment s jazykovým modelem (8.6).

8.1 Východiska

Předchozí studie pracovaly s kazuistikami jako s daným materiálem. Studie 1 ukázala, že popis výsledku je systematicky nejkratší částí kazuistiky, a že právě na něm bude predikce úspěšnosti řešení stát nejhůř (oddíl 5.2). Studie 3 ukázala, že i vyškolené posuzovatelky se na úsudkových škálách shodují jen středně (oddíl 7.3). Třetí etapa proto míří na hranice obou předchozích (kapitola 3): ptá se, které kazuistiky vůbec unesou interpretaci, jak dopadlo popsání řešení a jak vhodné bylo, a především, jak spolehlivě lze tyto tři úsudky učinit.

Dvě rozlišení jsou pro čtení kapitoly zásadní. Kvalita kazuistiky zde neznamená literární úroveň, ale použitelnost: zda text poskytuje dost informací pro pochopení situace a inter-

pretaci řešení a zda popsané jednání učitele neporušuje práva dítěte (příloha A.3). A dopad řešení není měřený výsledek, ale posouzení toho, co pisatel o výsledku napsal; jde o čtení sebevýpovědi, ne o pozorování ve třídě. Spolehlivost obou úsudků je tedy vlastností dvojice posuzovatelka $\times$ text, a proto ji kniha vykazuje s koeficienty i hrubou shodou zároveň. U silně nevyvážených kategorií doplňuje koeficient odolný vůči nevyváženosti (Gwet, 2008), protože κ a α při vysoké hrubé shodě paradoxně klesají (Feinstein a Cicchetti, 1990; kapitola 4).

8.2 Metoda

Materiál a anotátorky

Materiálem byl celý zveřejněný řez korpusu z května 2026 čítající 3 202 kazuistik (kapitola 5). Etapu provedly dvě anotátorky, v knize pod pseudonymy A2 a A12; obě prošly předchozími etapami. Číslo pseudonymů nesou pořadí, v němž se anotátorky zapojily do projektu jako celku, ne pořadí v této etapě: A2 kódovala už v první etapě, A12 přibyla ve druhé. Táž osoba proto vystupuje pod tímž pseudonymem v celé knize (příloha C). Veřejná tabulka druhé etapy používá samostatnou lokální řadu pseudonymů, která se s projektovou řadou nepojuje. Kazuistiky byly rozděleny na dvě poloviny s vestavěným překryvem, takže každá anotátorka hodnotila přibližně tři pětiny řezu a část kazuistik hodnotily obě. Anotátorka A12 ohodnotila 1 947 kazuistik a anotátorka A2 dalších 1 938 kazuistik; dohromady jde o 3 185 doložených jedinečných identifikátorů. Dvojitě hodnocený překryv čítá 693 kazuistik. Sedm hodnocených textů se nepodařilo spárovat s jednotným identifikátorem kazuistiky (kapitola 4); v rozděleních zůstávají, do překryvu a do spojení s první etapou nevstupují. Jejich vzájemnou odlišnost nelze ověřit. Hodnota 3 192 je pouze horní mez při předpokladu, že každý z těchto řádků přidává jiný případ.

Nástroje

Operacionalizaci všech tří dimenzí uvádí doslovně příloha A.3. Kvalita kazuistiky je binární: plochá (nepoužitelná) proti plné. Dopad řešení má tři kategorie: neúspěch, krátkodobý nebo částečný úspěch a dlouhodobý úspěch; oproti první etapě jsou tedy částečný a krátkodobý úspěch sloučeny. Vhodnost řešení je čtyřbodová bez středového bodu, od zcela nevhodného po zcela vhodné; s pětibodovou vhodností druhé etapy se nesměšuje (kapitola 4). Manuál u ploché kazuistiky předepisuje dopad a vhodnost nevyplňovat. Historický export však obsahuje výjimky: u A12 má dopad vyplněno 29 plochých záznamů a u A2 šestnáct; vhodnost má vyplněno 33 záznamů A12 a sedmnáct záznamů A2. Příčinu výjimek z konečných štítků nedokážeme určit. Hlavní analýza zachovává dochované hodnoty; dodatečná citlivostní analýza omezuje shodu dopadu a vhodnosti na případy označené oběma anotátorkami jako plné. Kód plochosti zahrnuje i normativní posouzení jednání učitele, nejde tedy pouze o technickou úplnost textu. Vedle kategorií vyplňovaly anotátorky tři volné komentáře: jazykový komentář, povinné zdůvodnění plochosti a další komentář.

Průběh etapy a rekalibrace

Etapu měla stejnou posloupnost jako obě předchozí: zácvik na šesti kazuistikách, první pilot na 19 kazuistikách, druhý pilot na 49 kazuistikách se společným rozbořem neshod a teprve poté finální anotování (příloha C). Pilotní shoda na druhém pilotu byla vysoká: hrubá shoda u dopadu i vhodnosti se blížila devadesáti procentům a κ leželo nad 0,8 (doslovný záznam podkladu v příloze A.3).

Během dlouhého finálního kódování se však škála vhodnosti oběma anotátorkám rozešla. Průběžná kontrola v polovině července 2026, kdy bylo společně hodnoceno 239 kazuistik, ukázala u vhodnosti hrubou shodu jen 45 % a váženou $\kappa = 0,42$; rozdíl měl jasný směr. Anotátorka A2 dávala v průměru 3,49 bodu, anotátorka A12 2,95; a tam, kde se lišily, dávala A2 vyšší známku ve 120 ze 128 případů. Kniha na to reagovala rekalibrací: anotátorky dostaly podklad s kotvami (kazuistiky, na nichž se shodly, pro každý stupeň škály) a se sezna-

8. Studie 4: Kvalita kazuistik, spolehlivost jejího posouzení a predikce úspěchu řešení

mem 40 sporných kazuistik k projednání. Do týdne se sešly s koordinátorkou týmu, sporné případy probraly a zbytek řezu dokódovaly podle sjednoceného výkladu škály. Rekalibrace uprostřed sběru je změna protokolu. Kniha ji nezastírá, ale kvantifikuje (oddíl 8.4) a případy z podkladu vylučuje z primárního výpočtu spolehlivosti, protože po projednání už nejde o nezávislá dvojí měření.

Uzavření etapy a adjudikace

Etapa byla uzavřena stop-rozhodnutím 8. září 2026 a analýzy kapitoly běží nad řezem K3_freeze_2026-09-08, tedy nad finálními tabulkami obou anotátorek s otiskem, který dokumentuje doprovodný repozitář. Adjudikace sporných případů zůstala nedokončená: dohodnutá známka je zapsána jen u tří ze sporných kazuistik vhodnosti. Schůzka však proběhla a její výsledek se promítl přímo do dat. U projednaných kazuistik změnila anotátorka A12 svou známku ve 28 případech, anotátorka A2 ve dvou, a v 23 případech se dnes obě tabulky shodují. Zpětné přepisy nejsou v datech označeny, takže finální tabulky míchají původní a revidované hodnocení; kniha proto vykazuje spolehlivost dvakrát, bez projednaných případů a s nimi.

Analýza

Shodu anotátorek vyjadřujeme hrubou shodou, Cohenovým κ (u vhodnosti váženým kvadraticky), Krippendorffovým α a Gwetovým AC1; u vhodnosti uvádíme i podíl hodnocení lišících se nejvýše o jeden stupeň a AC2 s kvadratickými vahami. Interval spolehlivosti pocházejí z bootstrapu přes kazuistiky (tisíc opakování). Primární výpočet vylučuje z překryvu 64 kazuistik uvedených v rekalibračním podkladu; plný překryv slouží jako citlivostní analýza. Spojení s první etapou (oddíly 8.4 a 8.5) páruje kazuistiky výhradně přes jednotný identifikátor (kapitola 4); z první etapy vstupuje primární kategorie chování a řešení a dopad převedený ze čtyř kategorií na tři explicitním sloučením částečného a krátkodobého úspěchu. Vztah typu řešení k dopadu popisujeme podíly a intervaly spolehlivosti z bootstrapu

přes kazuistiky; jde o popis souběhů, ne o kauzální model. Uspořádání predikčního experimentu popisuje oddíl 8.6.

8.3 Co anotátorky v kazuistikách viděly


Tabulka 8.1 a Obrázek 8.1 shrnují rozdělení všech tří dimenzí zvlášť pro každou anotátorku. Rozdělení pocházejí převážně z různých kazuistik, protože každá anotátorka hodnotila jinou polovinu řezu; rozdíl mezi nimi tedy směřují rozdíl mezi případy a rozdíl v přísnosti. Rozhodnout mezi oběma umí jen překryv (oddíl 8.4).

Tabulka 8.1. Rozdělení hodnocení ve třetí etapě podle anotátorky (počet kazuistik a podíl z vyplněných hodnocení dané dimenze).

Dimenze a kategorie	A12	A2
Kvalita: plná	1 855	1 852
Kvalita: plochá	92 (4,7 %)	86 (4,4 %)
Dopad: neúspěch	425 (23 %)	251 (13 %)
Dopad: krátkodobý nebo částečný úspěch	655 (35 %)	784 (42 %)
Dopad: dlouhodobý úspěch	803 (43 %)	833 (45 %)
Vhodnost 1 (zcela nevhodné)	85 (4,5 %)	11 (0,6 %)
Vhodnost 2 (spíše nevhodné)	300 (16 %)	288 (15 %)
Vhodnost 3 (spíše vhodné)	650 (34 %)	748 (40 %)
Vhodnost 4 (zcela vhodné)	852 (45 %)	822 (44 %)

Poznámka. Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [analýza v R ↗](#). Anotátorky hodnotily převážně různé kazuistiky (překryv viz oddíl 8.4).

8. Studie 4: Kvalita kazuistik, spolehlivost jejího posouzení a predikce úspěchu řešení



Obrázek 8.1. Rozdělení hodnocení ve třetí etapě podle anotátorky (podíl z vyplněných hodnocení; hodnoty viz Tabulka 8.1). *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

Korpus je podle obou anotátorek použitelný. Plochých kazuistik označila A12 92 (4,7 %) a A2 86 (4,4 %). Zdůvodnění plochosti napsaly téměř vždy: A12 u 86 z 92 plochých, A2 u 83 z 86. Nejčastějším důvodem je chybějící řešení nebo výstup, tedy kazuistika, která končí popisem situace; méně často nesrozumitelná struktura textu a jen ojediněle jednání učitele porušující práva dítěte. Chybění dopadu a vhodnosti převážně souvisí s označením plochosti. Anotátorka A12 chybí dopad u 64 kazuistik, z toho 63 jsou ploché; anotátorka A2 u 70 kazuistik a všech 70 je plochých. Tato souvislost neopravňuje předpokládat jediné pravidlo vzniku všech chybějících hodnot ani zpětně mazat výše popsané výjimky.

U dopadu se anotátorky liší v tom, jak často vidí neúspěch: A12 v 23 % posouzených kazuistik, A2 ve 13 %. Dlouhodobý úspěch vidí obě zhruba u dvou pětín. Vhodnost je u obou vychýlená ke kladnému pólu: stupně 3 a 4 pokrývají u A12 80 % a u A2 84 % hodnocení, stupeň 1 je vzácný. Škála se v praxi chová spíše jako trojstupňová, což samo o sobě omezuje dosažitelnou shodu.

Volné komentáře nesou informaci, kterou kódy neunesou, jsou však mezi anotátorkami neso-
souměrné. Jazykový komentář napsala A12 u 38 kazuistik, A2 u 348; další komentář A12 u 21 a A2 u 258 kazuistik. V jazykových komentářích převažují překlepy a pravopis; u 46 kazu-

istik A2 a 14 kazuistik A12 komentář žádá překlad do češtiny (zpravidla ze slovenštiny) nebo vytýká anglické označení žáka („pupil“) v českém textu; jde o jazykovou vrstvu korpusu, s níž kapitola 9 počítá mezi omezeními. Ve 145 dalších komentářích anotátorky A2 stojí značka nejistoty „??“, nejčastěji u vhodnosti; tento seznam je fakticky širší registr sporných případů, než jaký obsahoval rekaliбраční podklad. Rozdíl v počtu komentářů vypovídá o pracovním stylu anotátorek, ne o kazuistikách, a kniha jej proto nekvantifikuje jako proměnnou.

Posuzovaný text byl přitom rozsáhlý: medián délky popisu situace je 664 znaků, anamnézy 478, řešení 610 a výstupu 410 znaků. Úsudek se tedy opíral o souvislý případ, ne o útržek; výstup je i zde nejkratší částí, v souladu s obrazem ze Studie 1.

8.4 Spolehlivost posouzení


Tabulka 8.2 shrnuje shodu obou anotátorek na dvojité kódovaném překryvu, primárně bez kazuistik projednaných při rekaliбраci a pro srovnání na plném překryvu. Obrázek 8.2 ukazuje matice záměn.

Tabulka 8.2. Shoda anotátorek A12 a A2 na dvojité kódovaném překryvu třetí etapy (primární výpočet bez projednaných kazuistik; v závorce 95% intervaly spolehlivosti z bootstrapu přes kazuistiky).

Dimenze	n	Hrubá shoda	κ (95% CI)	Gwet AC1
Kvalita	629	98 %	0,77 (0,64 až 0,88)	0,98
Dopad	603	81 %	0,69 (0,63 až 0,74)	0,73
Vhodnost (vážená κ)	603	58 %	0,52 (0,46 až 0,58)	0,47
Dopad, plný překryv	663	80 %	0,67	–
Vhodnost, plný překryv	664	58 %	0,53	–

Poznámka. Podklady v doprovodném repozitáři: [zdrojová čísla](#)[↗], [analýza v R](#)[↗]. U vhodnosti je κ kvadraticky vážené; Krippendorffovo α se od κ liší nejvýše v setinách.

8. Studie 4: Kvalita kazuistik, spolehlivost jejího posouzení a predikce úspěchu řešení



Obrázek 8.2. Matice záměn na plném překryvu: řádky = anotátorka A12, sloupce = anotátorka A2; na diagonále je shoda. *Poznámka.* Podklady v doprovodném repozitáři: [data obrázku ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

Kvalita

Na kvalitě se anotátorky shodly v 98 % kazuistik. Právě zde je paradox shody vidět v praxi: kategorie je tak nevyvážená, že $\kappa = 0,77$ má široký interval spolehlivosti, zatímco $AC1 = 0,98$ vyjadřuje, co hrubá shoda říká přímo. Posouzení použitelnosti kazuistiky je tedy spolehlivé; pro korpus to znamená, že podíl plochých kazuistik kolem pěti procent není artefaktem jedné posuzovatelky.

Dopad

U dopadu se anotátorky shodly v 81 % kazuistik, $\kappa = 0,69$. Neshoda má tvar (Obrázek 8.2): zdaleka nejčastější záměnou je krátkodobý úspěch u A12 proti dlouhodobému úspěchu u A2, zatímco záměny mezi neúspěchem a dlouhodobým úspěchem jsou ojedinělé. Anotátorka A2 tedy čte tentýž výstup častěji jako trvalý; rozdíl v podílu neúspěchu v Tabulce 8.1 je zčásti rozdílem v přísnosti, ne jen rozdílem mezi hodnocenými kazuistikami. Posouzení dopadu

je tak spolehlivé na úrovni kategorií neúspěch versus úspěch a nejistější právě v rozlišení trvalosti úspěchu, tedy tam, kde je popis výstupu nejtenčí.

Vhodnost

Vhodnost je nejméně spolehlivá dimenze: přesná shoda 58 %, vážená $\kappa = 0,52$. Neshoda je však téměř vždy posun o jediný stupeň: v 98 % kazuistik se známky liší nejvýše o jeden bod a AC2 s kvadratickými vahami dosahuje 0,87. Protichůdná hodnocení, kdy jedna anotátorka vidí řešení jako nevhodné a druhá jako zcela vhodné, se prakticky nevyskytují. Zůstává systematický posun: A2 hodnotí výš u 149 kazuistik, A12 u 105; průměry na překryvu jsou 3,30 u A12 a 3,37 u A2, rozdíl 0,07 bodu (95% CI 0,01 až 0,12). Vhodnost je hodnotový soud; kniha s ní proto pracuje jako s hodnocenou vhodností dvou poučených posuzovatelek, stejně jako ve Studii 3, a neklade ji na jednu stupnici s pětibodovou vhodností druhé etapy.

Dodatečná citlivostní analýza na případech oběma anotátorkami označených jako plně zahrnuje 593 úplných dvojic dopadu i vhodnosti. κ dopadu činí 0,69 a vážená κ vhodnosti 0,50. Hlavní obraz shody je podobný, ale tato citlivost neodděluje normativní složku kódování od popsaného výsledku.

Rozdíly mezi částmi etapy kolem rekalibrace

Průběh etapy lze rekonstruovat podrobněji, než dovolují samotné finální tabulky. Jde o popis časových segmentů, nikoli odhad kauzálního účinku rekalibrace. Záloha dat z 22. července 2026 obsahuje tehdejší verzi obou tabulek. Schůzka proběhla do týdne od rozeslání podkladu, tedy zhruba v touž dobu; do dat se však promítla až po ní, protože záloha neobsahuje ani dohodnuté opravy sporných případů, ani žádné z pozdějších hodnocení. Zachycuje tedy stav, v němž se rekalibrace ještě nijak neprojevila, a kontrolní přepočty z ní navíc reprodukuje červencový monitorovací bod do posledního desetinného místa. Řádkové srovnání obou verzí dělí finální řez na tři části: hodnocení pořízená do tohoto data a od té doby nezměněná (1 249 řádků), hodnocení pořízená až po tomto datu (2 598 řádků) a zpětné přepisy,

8. Studie 4: Kvalita kazuistik, spolehlivost jejího posouzení a predikce úspěchu řešení

tedy řádky ohodnocené v červenci a později změněné (38 řádků, z toho 37 projednaných na schůzce; ve 31 případech se změnila vhodnost).

Pro interpretaci je podstatné nerovnoměrné rozvržení práce. K témuž datu měla anotátorka A2 ohodnoceno 1 048 kazuistik a mezi nimi celý pozdější překryv, zatímco anotátorka A12 měla ohodnoceno 239. Celý dvojité kódovaný překryv tedy nese hodnocení A2 z doby před rekalicací; A12 jej z větší části dokódovala až po ní. Obě anotátorky ohodnotily ještě v tomto dřívějším stavu 203 kazuistik překryvu, dalších 454 ohodnotila A12 až po ní a u 35 svých dřívějších hodnocení je přepsala. Hodnocení A2 se přitom v celé tabulce změnila jen ve třech případech. Srovnání obou částí překryvu je proto srovnáním anotátorky A12 před rekalicací a po ní vůči témuž nezměněnému měřítku.


Mezi částmi etapy se liší průměrný rozdíl hodnocení. Před rekalicí se anotátorky u vhodnosti přesně shodly v 52 % kazuistik, průměry byly 3,04 u A12 a 3,47 u A2, rozdíl 0,43 bodu (95% CI 0,36 až 0,51), a tam, kde se lišily, hodnotila A2 výš u 90 kazuistik proti šesti. Po rekalicí stoupla přesná shoda na 60 %, průměry se srovnaly na 3,39 a 3,32, rozdíl klesl na -0,07 bodu (95% CI -0,13 až 0,00) a směr neshod se vyrovnal: A12 hodnotila výš u 101 kazuistik, A2 u 72. V pozdější části je průměrný rozdíl menší a opačně orientovaný. Vážená κ však zůstala prakticky stejná: 0,55 před rekalicí a 0,52 po ní. Tento popis odpovídá změně průměrného nastavení škály bez obdobného růstu vážené shody. Samostatný účinek rekalicí z něj však odvodit nelze. U dopadu a kvality zůstaly míry v obou částech srovnatelné (κ dopadu 0,64 před a 0,67 po rekalicí; hrubá shoda kvality 96 % a 97 %), zatímco nejvýraznější rozdíl průměrů se týká vhodnosti.

Dvě výhrady k tomuto srovnání patří. Obě části překryvu tvoří jiné kazuistiky a ty z první části byly pro anotátorku A12 vůbec první prací v etapě, takže se do rozdílu promítá i pokračující zácvik. A hodnocení A2 pochází v obou částech z doby před rekalicí, takže se měří posun jedné anotátorky vůči pevnému měřítku, ne sblížení obou. Pro čtení celé kapitoly je podstatné, že finální překryv v Tabulce 8.2 obě části míchá, a jeho hodnoty proto leží mezi nimi. Citlivostní srovnání v téže tabulce zároveň ukazuje, že vyloučení projednaných kazuistik hodnotami prakticky nehne; rozdíl obou souhrnů je malý. To není důkaz nezávislosti

projednaných hodnocení.

Shoda napříč etapami a opakované posouzení dopadu

Obrázek 8.3 shrnuje koeficienty tří etap. Liší se nejen úsudkové úlohy, ale i počet kategorií, rozdělení štítků, vzorky a použité koeficienty. Pořadí hodnot proto není samostatným testem náročnosti úsudku ani jednou společnou stupnicí kvality měření.



Obrázek 8.3. Shoda anotátorek napříč třemi anotačními etapami a mezi etapami ($K1 \times K3$): koeficienty s 95% intervaly spolehlivosti; svislice vyznačují konvenční prahy 0,667 a 0,80. Koeficienty pocházejí z různých uspořádání (pět anotátorek na překryvu v první etapě, šest ve druhé, dvě ve třetí) a figura je řadí vedle sebe pro orientaci. *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla ↗](#), [analýza v R ↗](#), [kód obrázku ↗](#).

Třetí etapa umožňuje porovnat dopad na stejných textech v jiném čase. Spojení přes identifikátor dává 926 kazuistik. Po sloučení částečného a krátkodobého úspěchu a vyloučení chybějících včetně prázdných štítků zbývá 885 úplných dvojic. Všechny pozdější hodnoty v tomto propojeném souboru pocházejí od A12; starší od pěti jiných anotátorek první etapy. Nejde o sebehodnocení, ale ani o externí replikaci dvěma nezávislými týmy. Shoda činí 73

8. Studie 4: Kvalita kazuistik, spolehlivost jejího posouzení a predikce úspěchu řešení

$\kappa = 0,59$. Výsledek ukazuje opakovatelnost kódování v tomto souboru, nikoli sám o sobě konstruktovou validitu nebo účinnost popsání řešení.

8.5 Co se pojí s úspěchem řešení


Spojení obou etap otevírá otázku, kterou Studie 1 mohla položit jen uvnitř jedné etapy (oddíl 5.5): jaké typy řešení se pojí s dlouhodobým úspěchem a s vyšší hodnocenou vhodností, když typ řešení určila první etapa a dopad i vhodnost později posoudila A12 bez znalosti dřívějších kódů. Tabulka 8.3 a Obrázek 8.4 to ukazují pro 917 kazuistik s primární kategorií řešení z první etapy, jednotkou je opět dvojice kazuistika $\times$ anotátorka třetí etapy a uvedeny jsou kategorie s alespoň dvaceti kazuistikami.

Tabulka 8.3. Typ řešení z první etapy (primární kategorie) a hodnocení dopadu na týchž úplných dvojicích oběma etapami: podíl dlouhodobého úspěchu podle první a podle třetí etapy (u třetí etapy s 95% intervalem spolehlivosti z bootstrapu přes kazuistiky) a průměrná vhodnost (1–4) ze třetí etapy.

Typ řešení (K1)	Celkem / úplné		Úspěch podle K3	
	dvojice	Úspěch podle K1	(95% CI)	Vhodnost (K3)
Práce s kolektivem	38 / 37	70 %	51 % (35 % až 67 %)	3,38
Přemístění žáka	35 / 35	54 %	49 % (31 % až 66 %)	3,20
Rozhovor	463 / 449	50 %	42 % (37 % až 47 %)	3,25
Spolupráce s odborníky	93 / 89	48 %	38 % (29 % až 49 %)	3,31
(Kázeňské) tresty	20 / 20	40 %	35 % (15 % až 55 %)	2,75
Podpora	66 / 63	43 %	35 % (23 % až 47 %)	3,43
Důsledky	28 / 27	33 %	30 % (12 % až 48 %)	2,78
Upozornění	97 / 91	38 %	30 % (20 % až 39 %)	2,75
Nerespektující komunikace	45 / 39	18 %	23 % (11 % až 38 %)	2,10

Poznámka. Podklady v doprovodném repozitáři: [zdrojová čísla](#), [data tabulky](#), [analýza v R](#). Kategorie s méně než dvaceti kazuistikami (dohoda, fyzické zakročení) vynechány. Druhé číslo ve sloupci rozsahu je společným

jmenovatelem obou podílů úspěchu, první označuje všechny dostupné kazuistiky kategorie. Vhodnost využívá vlastní dostupná hodnocení. Přesné jmenovatele jsou ve zdrojové tabulce.



Obrázek 8.4. Podíl kazuistik s dlouhodobým úspěchem podle primárního typu řešení z první etapy, posouzený oběma etapami na týchž úplných dvojicích (plné body = třetí etapa s 95% intervalem spolehlivosti z bootstrapu přes kazuistiky, prázdné = první etapa; jen kategorie s alespoň dvaceti kazuistikami; hodnoty viz Tabulka 8.3). *Poznámka.* Podklady v doprovodném repozitáři: [data obrázku](#), [analýza v R](#), [kód obrázku](#).

Podíly dlouhodobého úspěchu se mezi kategoriemi liší, ale jejich pořadí není v obou etapách totožné. Pozdější hodnocení nejsou všeobecně přísnější: například u nerespektující komunikace je podíl dlouhodobého úspěchu vyšší ve třetí etapě. Úplné dvojice umožňují porovnat stejné případy, nikoli oddělit vliv anotátorky, času a schématu. Celková asociace typu řešení s dopadem je slabá (Cramérovo $V = 0,13$), což však neurčuje, které jiné faktory výsledek způsobují. Interval malých kategorií jsou široké; bez přímých kontrastů nedokládáme průkazné rozdíly jednotlivých dvojic kategorií.

Interpretaci dále omezují výběr strategií podle situace, povaha retrospektivní sebevýpovědi a zastoupení víceetapového řešení jedinou primární kategorií. Navíc historický kód neúspěchu a vyřazení plochých případů obsahují normativní složku (příloha A). Oddělené čtení týchž textů jinou anotátorkou tento problém neodstraňuje. Zjištění je popisem souvislosti

anotačních kategorií; nezávislé ověření účinnosti by vyžadovalo oddělené měření přijatelnosti a výsledku, ideálně v intervenčním designu.

8.6 Umí jazykový model předvídat úspěch řešení?

Druhá část VO4 se ptá, zda jazykový model dokáže z popisu situace, anamnézy a řešení odhadnout, jak řešení dopadlo. Uspořádání experimentu bylo stanoveno předem (kapitola 4). Model dostává tři části kazuistiky bez záměrného vložení pole výstupu. Historický automatický test hledal jen doslovný začátek výstupu ve vstupu; nevylučoval parafráze, pozdější části výstupu ani jiné významové nápovědy (příloha B.6). Předpovídá jednu ze tří kategorií dopadu podle definic třetí etapy (příloha A.3, doslovné znění instrukce v příloze B.6), v základní variantě bez příkladů a v doplňkové variantě s pevnou sadou šesti příkladů z kazuistik mimo hodnocenou množinu.

Experiment běžel na jazykových modelech nasazených v národní akademické infrastruktuře e-INFRA CZ. Volba má tři důvody: texty kazuistik neopouštějí akademickou infrastrukturu, modely mají otevřené váhy, takže běh lze zopakovat i mimo tento projekt, a omezuje se závislost na komerční službě (Ollion et al., 2024). Otevřené váhy samy nezaručují totožnost konfigurace obsluhující služby. Cenou je, že predikce neběží na témže modelu jako Studie 2 a 3; napříč studiemi se proto nesrovnává. Protože ani akademická infrastruktura neverzuje nasazení, zaznamenává skript ke každému běhu otisk modelu, tedy zkrácený otisk jeho odpovědi na pevnou kontrolní otázku při nulové teplotě, spolu s datem běhu. Takový otisk není identifikátorem vah ani důkazem totožnosti backendu; navíc historická kontrolní odpověď mohla pocházet z mezipaměti. Nová verze skriptu proto kontrolní dotaz necacheje a odděluje cache podle běhu, endpointu a deklarovaného nasazení. Tím se zpětně nedoplňuje chybějící identifikace historického nasazení.

Volba konkrétního modelu je součástí uspořádání, ne výsledkem. Čtyři kandidáti byli porovnání na vývojové množině, kterou tvoří kazuistiky mimo dvojité kódovaný překryv, a

8.6 Umí jazykový model předvídat úspěch řešení?

teprve model s nejvyšší vyváženou přesností vstoupil do hodnocení. Hodnocenou množinou je dvojitě kódovaný překryv třetí etapy bez projednaných kazuistik, tedy 601 kazuistik; dvě kazuistiky z něj vypadly, protože jim ve zdrojové tabulce sklouzly sloupce a popis výstupu se objevoval v zadání, což zachytil právě test úniku informace. Předpověď se srovnává s hodnocením každé anotátorky zvlášť a s podmnožinou, na níž se obě shodly.

Protože třídy dopadu jsou nevyvážené, uvádíme vyváženou přesnost, makro-F1, prostou přesnost a κ . Prázdná nebo neplatná modelová odpověď zůstává ve jmenovateli jako neúspěšná předpověď. Pro κ dostává zvláštní štítek pouze na straně predikce; podmíněné κ jen na platných odpovědích obsahuje doplňkový report. Žádná metrika tak selhání tiše nevyřazuje.

Shoda anotátorek při znalosti výstupu je kontextovou referencí, nikoli stropem predikce. Lidé a model mají jiné informace a konsenzuální podmnožina má jiné složení než celý překryv. Bez lidské predikce ze stejných vstupů nelze porovnat člověka a model v téže úloze.

Na celé hodnotící množině obsahuje Kimi třináct neplatných odpovědí, každá varianta GLM sedm; na konsenzuální podmnožině jde o jedenáct, respektive šest odpovědí. Pokrytí, intervaly všech metrik a podmíněné κ pouze platných odpovědí obsahuje veřejný report a tabulka predikčních výsledků. Tabulka 8.4 uvádí nepodmíněné metriky včetně selhání.

Tabulka 8.4. Predikce dopadu řešení jazykovým modelem na hodnotící množině (kazuistiky dvojitě kódovaného překryvu bez projednaných; „shoda obou“ = podmnožina, na níž se anotátorky shodly). Referenční rámec tvoří shoda anotátorek mezi sebou a hádání většinové třídy.


Srovnání	n	Přesnost	Vyvážená	Macro-F1	κ
			přesnost		
kimi-k3 × A12	601	52 %	59 %	0,54	0,29
kimi-k3 × A2	601	49 %	57 %	0,51	0,25
kimi-k3 × shoda obou	487	52 %	60 %	0,55	0,30
glm-5.3 × shoda obou	487	52 %	60 %	0,55	0,30
glm-5.3 s příklady × shoda obou	487	56 %	63 %	0,58	0,34

8. Studie 4: Kvalita kazuistik, spolehlivost jejího posouzení a predikce úspěchu řešení

Srovnání	n	Přesnost	Vyvážená přesnost	Macro-F1	κ
A12 $\times$ A2 (čtení výstupu)	601	81 %	80 %	0,80	0,69
většinová třída (báze)	601	49 %	33 %	–	0

Poznámka. Podklady v doprovodném repozitáři: [zdrojová čísla](#), [predikce](#), [skript](#). Anotátorky popis výstupu při hodnocení viděly, model nikoli; poslední dva řádky proto nejsou predikce, ale referenční rámec.

Vyvážená přesnost modelu Kimi vůči společnému štítku činí 60 %, nad třetinovou hodnotou většinové báze. Není však měřením správnosti skutečného výsledku ve třídě: cílem je štítek odvozený z vyprávění. Obrázek 8.5 odlišuje predikci od lidského čtení popsaného výstupu.



Obrázek 8.5. Vyvážená přesnost předpovědi dopadu proti dvěma referenčním bodům: hádání většinové třídy a shodě anotátorek mezi sebou. Oranžově model, modře lidé, šedě báze; vodorovná úsečka měří vzdálenost od báze. *Poznámka.* Podklady v doprovodném repozitáři: [zdrojová čísla](#), [kód obrázku](#).

Dodatečné párové bootstrapové porovnání na stejných případech dává rozdíl vyvážených přesností GLM minus Kimi 0,004 s intervalem od $-0,039$ do $0,048$. U GLM s příklady minus bez příkladů činí rozdíl 0,029, s intervalem od $-0,011$ do $0,065$. Oba intervaly zahrnují nulu. Nelze proto prokázat výhodu konkrétní varianty, ale ani tvrdit ekvivalenci modelů či informační strop úlohy.

V rozdělení odpovědí Kimi převažuje prostřední kategorie. Krátkodobý nebo částečný úspěch předpovídá u 52 % kazuistik, zatímco anotátorky jej kódují u 35 % a 31 %; naopak dlouhodobý úspěch předpovídá jen u 22 % proti 49 % a 53 % u lidí. Podle toho vypadá i citlivost po třídách: neúspěch model rozpozná v 77 % případů, dlouhodobý úspěch jen v 38 %. Model má v tomto testu nižší citlivost pro dlouhodobý úspěch než pro neúspěch. Proč tomu tak je, samotná matice předpovědí nerozhoduje.

Dvě čísla ukazují, kde přesně model selhává. U kazuistik, na nichž se anotátorky shodly, se trefil do jejich společné známky v 52 % případů; u kazuistik, kde se anotátorky lišily, padla jeho předpověď na jednu z obou známek v 89 %. Druhé číslo používá mírnější kritérium zásahu jedné ze dvou kategorií. Nelze je přímo srovnávat s přesností vůči jedinému společnému štítku ani z něj odvozovat přijatelnost předpovědi.

Odpověď na druhou část VO4 je omezená: uložené modelové předpovědi mají v tomto souboru jen dílčí shodu s kódovaným dopadem. Nelze z toho určit, zda vstupní text potřebnou informaci neobsahuje, nebo ji použité modely a instrukce nevyužívají. Pro doporučování postupů ve třídě tato validace nestačí.

8.7 Shrnutí

Třetí etapa pokrývá 3 185 doložených jedinečných identifikátorů a sedm dalších nespárovaných řádků. V posouzení použitelnosti je vysoká vzájemná shoda, což není doklad bezchybnosti vůči vnějšímu kritériu. Shoda dopadu a vhodnosti je nižší; doplňkové analýzy oddělují projednané případy a výjimky u plochých textů. Rozdíly časových segmentů neidentifikují

8. Studie 4: Kvalita kazuistik, spolehlivost jejího posouzení a predikce úspěchu řešení

samostatný účinek rekalibrace. Mezi-etapové srovnání se týká jiného čtení týchž textů jednou pozdější anotátorkou. Souvislosti strategií s historickými štítky nejsou nezávislým ověřením jejich pedagogické účinnosti.

Predikční experiment dokládá omezenou shodu se štítky, ne informační strop úlohy. Selhání odpovědí zůstávají ve výpočtu a intervaly párových rozdílů modelů zahrnují nulu. Lidské čtení výstupu nelze považovat za predikci za stejných podmínek. Následující kapitola tato omezení zachovává při spojení pedagogické a metodologické linie knihy.

Integrace

9. Diskuse

Čtyři studie této knihy položily čtyři otázky nad jedním korpusem. Tato kapitola je čte dohromady. Nejprve shrne, co která studie zjistila a s jakou jistotou (9.1). Poté rozvine tři motivy, které studie spojují: repertoár nejmenšího odporu jako empirický obraz učitelské praxe (9.2), otázku, co lze jazykovému modelu v pedagogickém výzkumu svěřit (9.3), a spolehlivost posouzení jako proměnnou, kterou je třeba měřit, ne předpokládat (9.4). Následují omezení (9.5), důsledky pro přípravu učitelů, pro platformu Edustories a pro výzkum s jazykovými modely (9.6) a směry dalšího výzkumu (9.7).

9.1 Oblouk čtyř studií

Kniha začala materiálem a skončila u hranic jeho použitelnosti. Studie 1 vybudovala a popsala korpus, Studie 2 prověřila jazykový model jako anotátora tohoto korpusu, Studie 3 nechala lidi zaslepeně hodnotit řešení, která model generuje, a Studie 4 se ptala, jak spolehlivě lze posoudit kvalitu kazuistik a úspěšnost řešení a nakolik to dokáže model předvídat. Tabulka 9.1 shrnuje odpovědi a míru jistoty, s níž je kniha předkládá.

9. Diskuse

Tabulka 9.1. Výzkumné otázky, hlavní zjištění a míra jistoty.

Otázka	Hlavní zjištění	Míra jistoty
VO1: korpus a jeho obsah (Studie 1)	Zveřejněný řez čítá 3 202 kazuistik se čtyřdílnou strukturou. V repertoáru dominuje rozhovor (v 922 z 1 359 kódovaných kazuistik) a další reaktivní kroky; vztahová a kolektivní řešení se pojí s příznivějším vnímaným výsledkem.	Vysoká pro četnosti a strukturu; souběhy řešení a dopadu jsou popis, ne příčina.
VO2: model jako anotátor (Studie 2)	$\kappa = 0,64$ na úplných dvojicích, po dodatečném vyloučení překryvů s příklady $\kappa = 0,61$.	Omezená validace; retrospektivní citlivost není nový nezávislý test a nesrovnává výkon modelu s lidským stropem.
VO3: generovaná versus učitelská řešení (Studie 3)	Učitelská řešení hodnocena jako méně vhodná (rozdíl $-0,85$ bodu), reaktivnější a behaviorálnější; šance na rozpoznání rámce třetinová (OR 0,31).	Vysoká pro směr a robustnost efektů v textové podobě řešení; nevypovídá o proveditelnosti.
VO4: kvalita, spolehlivost, predikce (Studie 4)	Posouzení použitelnosti kazuistiky s vysokou vzájemnou shodou ($\kappa = 0,77$, AC1 = 0,98), dopadu spolehlivé ($\kappa = 0,69$), vhodnosti střední (vážená $\kappa = 0,52$); dopad se při opakovaném čtení týchž textů jinou anotátorkou shoduje $\kappa = 0,59$. Předpověď dopadu jazykovým modelem dosáhla vyvážené přesnosti 60 % proti 33 % u hádání a 80 % u shody dvou lidí.	Vzájemná shoda není správnost vůči externímu kritériu; predikce omezená a s výhradou, že lidé výstup četli.

Poznámka. Hodnoty ze zdrojových čísel studií 1 až 4 (kapitoly 5 až 8); intervaly spolehlivosti a podmínky výpočtu uvádějí příslušné kapitoly.

Čtyři odpovědi drží pohromadě dvěma způsoby. Zaprvé věcně: obraz repertoáru ze Studie

1 se vrací ve Studii 3 jako pozadí, na němž vynikají generovaná řešení, a ve Studii 4 jako souvislost kategorií při opakovaném čtení týchž kazuistik. Zadruhé metodologicky: každý výsledek o modelu je vztažen k lidskému měřítku, jehož spolehlivost kniha měří místo toho, aby ji předpokládala. Právě tento druhý způsob dává knize tvar validačního žebříku popsaného v kapitole 3. Model byl nejprve poměřen lidmi v úloze, kterou lidé umějí (klasifikace), poté lidé zaslepeně hodnotili to, co model dokáže vytvořit (alternativní řešení), a nakonec kniha změřila, kde končí spolehlivost lidí samotných. Odpovědi tak nejsou čtyři izolovaná čísla, ale stupně jedné otázky: co lze o učitelských repertoárech zjistit z textu a komu, člověku nebo stroji, lze které čtení textu svěřit.

9.2 Repertoár nejmenšího odporu

Kapitola 2 zavedla repertoár nejmenšího odporu jako interpretační pojem pro převahu snadno dostupných reakcí v zaznamenaných situacích. Studie mapují frekvence a vlastnosti textů; neměří však úplný repertoár jednotlivce, jeho znalosti, časový tlak ani vznik konkrétního rozhodnutí. Mechanismy učňovství pozorováním a situační dostupnosti proto zůstávají hypotézami pro další výzkum.

Studie 1 dala pojmu obsah. Rozhovor je přítomen ve dvou třetinách kódovaných kazuistik a za ním následují spolupráce s odborníky, podpora, důsledky a upozornění; samostatnou proaktivní kategorii finální schéma ani neobsahovalo: příslušné podkategorie byly při vývoji schématu přesunuty. Absence samostatné kategorie proto není dokladem absence proaktivního jednání. Studie 3 přidala měřítko zvenčí. Když šest anotátorek zaslepeně hodnotilo učitelské řešení vedle řešení generovaného pro tutéž situaci, bylo učitelské reaktivnější (rozdíl $-1,01$ bodu) a behaviorálnější (o $0,77$ bodu) a mělo jen třetinovou šanci na to, že v něm anotátorky rozpoznají některý z pojmenovaných přístupů. Studie 4 pak ukázala, že vzorec ze Studie 1, podle něhož se vztahová a kolektivní řešení pojí s příznivějším výsledkem než řešení represivní, přečte z týchž kazuistik i pozdější anotátorka. Na týchž kazuistikách hodnotil první tým podíl dlouhodobého úspěchu u práce s kolektivem na 70 % a třetí etapa na

51 %, u rozhovoru na 50 % a 42 %, u upozornění na 38 % a 30 %. U těchto příkladů jsou podíly třetí etapy nižší; neplatí to pro všechny kategorie a ani jejich pořadí není totožné (Tabulka 8.3).

Proč repertoár vypadá právě takto, vysvětluje kapitola 2 dvěma mechanismy, které data knihy nemohou přímo testovat, ale s nimiž jsou v souladu. Učňovství pozorováním (Lortie, 1975) dodává učitelům zásobu postupů, které viděli z lavice: napomenutí, domluvu, trest, posílání za dveře. Proaktivní práce může být z lavice méně viditelná a časový tlak může zvýhodnit dostupné postupy. Tato vysvětlení však předložená data přímo neověřují. Repertoár nejmenšího odporu tedy není označení pro pohodlnost učitelů. Je to hypotetický výklad vztahu mezi profesním učením a podmínkami jednání; v pojetí, které nabízí Swidler (1986), jde o zásobu, z níž se strategie skládají, ne o volbu mezi známými alternativami. S tímto čtením se shoduje i domácí výzkum, který reaktivní strategie zachytil přímým pozorováním praxe (Vlčková et al., 2020) a v situacích začínajících učitelů (Karasová a Nehyba, 2025), a evidence oboru, která proaktivním a strukturovaným strategiím přiznává větší přínos (Korpershoek et al., 2016; Simonsen et al., 2008).

Jedno upřesnění je podstatné. Reaktivnost repertoáru neznamena, že by učitelé zůstávali na řešení sami: spolupráce s odborníky patří k nejčastějším krokům. Znamená, že i tento krok je spouštěn incidentem. A vzorec dopadů zůstává popisem souběhů, jak opakují kapitoly 5 a 8: učitelé si typ řešení nevybírají náhodně, k trestu sahají v situacích s horšími vyhlídkami a dopad posuzuje čtenář sebevýpovědi. Opakované čtení jinou anotátorkou kauzální interpretaci nezakládá. Historické kódy navíc částečně spojují výsledek s přijatelností prostředku; bez jejich oddělení nelze vztah kategorií pokládat za nezávislou validaci účinnosti.

9.3 Co lze jazykovému modelu svěřit

Knihy prověřuje tři odlišné role: anotátora, generátora a prediktora. Ve Studii 2 dosahuje κ vůči lidskému kódu typu řešení 0,64, po dodatečném vyloučení zjištěného překryvu příkladů 0,61. Přenos poznatků z krátkých anglických textů (Gilardi et al., 2023; Törnberg,

2025) na tento korpus je tedy podpořen jen omezeně: chybí nový test nezávislý na vývoji promptu. Lidské α z jiného uspořádání není výkonovým stropem modelu. Část neshod může souviset se schématem, ale podíl takových neshod zde nelze určit.

V roli generátora model obstál v zaslepeném lidském hodnocení. Jeho řešení byla hodnocena jako vhodnější a proaktivnější a nesla rozpoznatelné rysy přístupů opřených o důkazy, aniž k tomu byl model instruován. Kniha z toho nevyvozuje, že „AI radí lépe než učitel“. Hodnocen byl text, ne jednání ve třídě; model odpovídal bez časového tlaku a bez odpovědnosti za následky; a výsledky se vážou k jedinému modelu a jediné instrukci. Co lze z výsledku vyvodit, je skromnější a užitečnější: generované řešení nabízí učiteli nad konkrétní situací kontrast k zaznamenanému postupu. Zda učitel tento postup již zná, studie nezjišťovala. Zda takový kontrast repertoár rozšiřuje, je otázka pro intervenční studii.

Modelové posuzování vhodnosti kniha přímo netestovala. Z lidské shody proto nelze dovodovat úspěch ani selhání modelu v této roli. Studie 4 ukázala proč. Vhodnost řešení posuzují i dvě vyškolené anotátorky jen se střední shodou (vážená $\kappa = 0,52$) a ve druhé etapě šest anotátorek s $\alpha = 0,53$. Model posuzující vhodnost by tedy byl validován proti měkkému měřítku a jeho „shoda s lidmi“ by vypovídala hlavně o tom, se kterým člověkem se shoduje. Naopak dopad řešení, jak jej pisatel popsal, posuzují lidé spolehlivě ($\kappa = 0,69$ uvnitř etapy, $\kappa = 0,59$ mezi etapami), a právě proto je dopad tou dimenzí, na níž kniha model prověřuje v roli prediktora (oddíl 8.6). Predikce má však jinou logiku než posouzení: anotátorky výstup četly, model jej nevidí. Srovnání proto neříká, zda model předvídá lépe než člověk, ale zda se s lidským čtením výsledku shoduje tak jako druhý člověk. Predikční experiment dosáhl vyvážené přesnosti 60 % . Intervaly párových rozdílů mezi modely a variantami zahrnují nulu (oddíl 8.6). Výsledek nedokládá ekvivalenci ani informační strop úlohy. Chybí lidská predikce při stejné informaci a externí měření skutečného dopadu ve třídě; pro individuální doporučení proto tato validace nestačí.

Z toho plyne rozdělení rolí, které kniha doporučuje. Modelu lze svěřit klasifikaci obsahu velkého korpusu na úrovni kategorií, vždy po validaci na vlastních datech proti lidskému kódování s doloženou reliabilitou (Reiss, 2023; Ziems et al., 2024). Lze mu svěřit generování

kontrastních řešení pro reflexi, ne pro rozhodnutí. Nelze mu svěřit posouzení vhodnosti bez lidské reference ani rozhodování o jednotlivém žákovi. A protože poskytovatelé modely průběžně mění (Ollion et al., 2024), platí každý takový výsledek pro doložený běh a instrukci. Alias služby a otisk odpovědi však nezaručují totožnost vah; omezení popisuje příloha B.

9.4 Spolehlivost jako proměnná, ne konstanta

Nejméně nápadným, ale pro metodologii nejdůležitějším výsledkem knihy je, jak se chovala spolehlivost lidského posouzení. Nebyla vlastností anotátorek ani konstantou etapy. Měnila se s konstruktem, se schématem, s fází etapy a s časem, a kniha tyto změny měřila.

S konstruktem: Obrázek 8.3 řadí koeficienty všech tří etap podle náročnosti úsudku. Binární kvalita kazuistiky a dopad se třemi kategoriemi leží nad konvenčním prahem, úsudkové škály vhodnosti a orientací řešení pod ním a jedenáctikategoriální schéma typů řešení nejnižší. Se schématem: u typu řešení srazila shodu jemnost a překryvnost kategorií, což ukázal Jaccardův index 0,56 přiznávající částečný překryv, zatímco α trestá každou neshodu stejně. S fází etapy: ve třetí etapě dosáhl druhý pilot na padesáti kazuistikách κ nad 0,8 u dopadu i vhodnosti, finální kolo na stovkách kazuistik však $\kappa = 0,69$ a vážené $\kappa = 0,52$. Pilotní shoda je měřena krátce po společném rozboru, na malém vzorku a s čerstvou instrukcí; finální shoda po měsících samostatné práce. Kniha proto spolehlivost vykazuje z finálních kol, a kde má obě hodnoty, uvádí obě. Totéž platí pro druhou etapu, jejíž dvě kalibrační kola byla malá a společně rozebíraná; srovnatelný pilotní koeficient pro ni kniha nemá, a proto se i tam opírá jen o finální kolo. A s časem: uprostřed třetí etapy se škála vhodnosti oběma anotátorkám rozešla o půl stupně. V pozdějším segmentu byl průměrný rozdíl menší bez obdobného růstu vážené shody; samostatný účinek rekalibrace však tento design neidentifikuje (oddíl 8.4).

Z těchto pozorování kniha odvozuje čtyři pravidla, která považuje za svůj metodologický příspěvek pro výzkum s posuzovateli, lidskými i strojovými. Koeficient se uvádí vždy s hrubou shodou a u nevyvážených kategorií s mírou odolnou vůči nevyváženosti, protože paradox

shody (Feinstein a Cicchetti, 1990; Gwet, 2008) vede při vysoké hrubé shodě kvality k nižšímu κ se širokým intervalem. Spolehlivost se vykazuje z finálních dat, ne z pilotu. Zásah do protokolu uprostřed sběru, jako byla rekalibrace, se přiznává, kvantifikuje a projednané případy se z primárního výpočtu vyloučí, protože po projednání už nejde o nezávislá měření. A zpětné přepisy hodnocení se v datech označují; kde se to nestalo, jako ve třetí etapě, pomůže archivovaná starší verze týchž tabulek. Řádkový rozdíl mezi ní a finálem segmenty rekonstruuje a zpětné přepisy pojmenuje, takže i dodatečně lze vykázt shodu zvlášť pro dobu před zásahem a po něm. Právě to ve třetí etapě rozlišilo změnu průměrného rozdílu od vážené shody. Časová souvislost s rekalibrací přitom není jejím kauzálním účinkem. Zálohovaná verze dat je tedy metodologický nástroj, ne jen pojistka proti ztrátě. Tato pravidla nejsou nová v teorii reliability (Krippendorff, 2018; Hallgren, 2012); nová je jejich uplatnění na dlouhé, vícefázové anotační etapy nad pedagogickým textem, kde se shoda v čase prokazatelně mění.

9.5 Omezení

Omezení knihy plynou z povahy materiálu, z uspořádání studií a z nástroje.

Materiál je korpus dobrovolně psaných sebevypovědí. Kazuistiky nadreprezentují dramatické situace, dopad posuzuje čtenář toho, co pisatel o výsledku napsal, a zrcadlová šablona vede pisatele k jednoznačně vydařeným a jednoznačně nevydařeným situacím, takže částečné úspěchy jsou v korpusu vzácnější než v praxi (kapitoly 3 a 5). Korpus roste a kniha pracuje s datovanými řezy; každé číslo platí pro svůj řez. Část kazuistik je psána slovensky nebo nese anglické zástupné označení žáka a část byla v minulosti dotčena zkrácením textu při extrakci; kniha tyto případy z analýz závislých na délce vylučuje, jazykovou vrstvu však popisuje jen z komentářů anotátorek (kapitoly 4 a 8). Kódovací schémata se mezi etapami liší a kniha je nesměšuje; jedinou převodní operací je sloučení částečného a krátkodobého úspěchu pro srovnání dopadu mezi etapami.

Uspořádání studií je popisné a srovnávací, ne intervenční. Souběhy typů řešení s dopadem

nezakládají kauzální tvrzení a kniha jich žádné nečiní. Zaslepené hodnocení ve Studii 3 chránilo před zkreslením očekáváním, ale hodnotilo text, ne jednání ve třídě. Třetí etapu nesly jen dvě anotátorky, její adjudikace zůstala nedokončená a rekalibrace uprostřed sběru je změnou protokolu; její účinek lze doložit jen proto, že se dochovala starší verze tabulek, a i pak jde o srovnání dvou různých souborů kazuistik. Kazuistiky prošly etapami nerovnoměrně a část jich prošla několika, což kniha eviduje v matici pokrytí (kapitola 4), ale co omezuje čtení překryvů jako nezávislých vzorků.

Studie 2 a 3 pracovaly každá s konkrétním modelem a instrukcí. Predikční experiment na-proti tomu zahrnul více kandidátů ve vývoji a dva modely při hodnocení, včetně varianty s příklady. Výsledky nelze zobecnit na jiné instrukce, jazyky, poskytovatele ani budoucí verze. Otevřené váhy a akademické nasazení nejsou zárukou totožnosti backendu; otisk kontrolní odpovědi je jen doplňkovým údajem. Příloha B rozlišuje doloženou identifikaci historického běhu od podmínek nového experimentu. Lidé v predikčním srovnání výstup četli, model nikoli; lidská predikční báze za shodných podmínek není k dispozici.

9.6 Důsledky

Pro přípravu učitelů a školní praxi

Obraz repertoáru nejmenšího odporu nabízí podnět pro přípravu učitelů: pracovat s konkrétními situacemi a vedle zaznamenaného postupu zvažovat alternativy. Data však nerozhodují, zda rozdíly souvisejí s neznalostí, časovým tlakem, dostupnými prostředky nebo vlastnostmi situace. Kazuistiky a generované kontrasty mohou sloužit jako materiál k reflexi; jejich účinek na jednání musí prověřit intervenční studie. Pozorované asociace historických kategorií neopravňují k doporučení strategie jako účinnější bez dalšího ověření.

Pro platformu Edustories

Platforma nabízí řešení v šesti přístupech (kapitola 3). Studie 3 však použila jednu instrukci bez předepsaného rámce, a není tedy validací všech platformových generátorů. Studie 4 měřila lidské posouzení použitelnosti; automatický filtr kvality netestovala. Pro platformu z toho plynou návrhy k ověření: kontrola úplnosti před generováním, označení výstupu jako materiálu k reflexi a sběr zpětné vazby o jeho využití. Spolehlivost případného automatického filtru musí být vyhodnocena zvlášť.

Pro jazykové modely v pedagogickém výzkumu

Pro výzkum kniha nabízí postup, který lze převzít: validovat model na vlastních datech proti lidskému kódování s měřenou reliabilitou, vykazovat shodu modelu s lidmi vždy vedle shody lidí mezi sebou, používat zaslepené lidské hodnocení tam, kde model generuje, a dokumentovat verze modelů i instrukcí. Doprovodný repozitář tento postup zpřístupňuje včetně odvozených dat bez textů kazuistik, takže hlavní statistiky lze přepočítat bez nového volání modelu. Původní anotace, textové kontroly a historické souhrny mají odlišný rozsah ověřitelnosti popsány v kapitole 4. Pro český pedagogický výzkum je to první doklad, že jazykový model může být kriticky prověřeným nástrojem analýzy velkého korpusu autentického českého textu.

9.7 Další výzkum

Tři směry plynou z výsledků přímo. První je intervenční studie kontrastu: zda učitelé, kteří nad vlastní situací dostanou generované řešení v jiném rámci, volí v dalších situacích proaktivnější kroky. Korpus a platforma pro ni poskytují materiál i měřicí nástroj, velikost intervenčního účinku však tato kniha neodhaduje.

Druhým směrem je spolehlivost v čase. Třetí etapa ukázala, že se shoda během měsíců samostatné práce mění. Rozdíly segmentů samostatný účinek rekalibrace neidentifikují; příští

etapa by měla mít časový záznam každého hodnocení, průběžné kontrolní body a označené přepisy, aby segmenty nebylo nutné rekonstruovat ze zálohy. Totéž uspořádání dovolí ověřit, zda pilotní shoda předpovídá finální.

Třetím směrem je rozšíření modelů a jazyků. Výběr modelů zůstal omezený; opakování Studie 2 a predikčního experimentu s dalšími modely, včetně otevřených a lokálně provozovaných, by ukázalo, nakolik jsou výsledky vlastností úlohy a nakolik vlastností jednoho poskytovatele. Anglická datová sada Edustories-en (kapitola 3) navíc umožňuje ptát se, zda model kóduje tentýž obsah v obou jazycích shodně, a tedy měřit jazykovou mezeru přenosu přímo.

9.8 Shrnutí

Kniha propojuje popis korpusu, modelové kódování, zaslepené hodnocení alternativních řešení a opakované lidské posouzení s predikcí dopadu. Rozlišuje přitom frekvence od příčin volby strategií, shodu od správnosti a hodnocení textu od účinku jednání. Modelové kódování má omezenou retrospektivní validaci, generované alternativy byly hodnoceny příznivěji a predikce dopadu zůstává nejistá. Žádný z těchto výsledků nestanovuje univerzální lidský ani informační strop. Změny protokolu, překryvy příkladů, neúplné odpovědi a normativní složka kategorií patří k výsledku, nikoli jen k technickým poznámkám.

10. Závěr

Kniha vyšla z jednoduché otázky: co vypovídají kazuistiky náročného chování o tom, jak čeští učitelé takové chování zvládají, a nakolik lze jejich výzkum ve velkém rozsahu svěřit jazykovému modelu. Odpověď hledala ve čtyřech studiích nad jedním korpusem projektu Edustories. Tato kapitola shrnuje odpovědi na čtyři výzkumné otázky, pojmenovává přínos knihy a naznačuje, kam práce směřuje.

10.1 Odpovědi na výzkumné otázky

Na první otázku, jak vybudovat a popsat rozsáhlý korpus autentických kazuistik a co zachycuje, odpovídá Studie 1. Korpus vznikl na platformě projektu zrcadlovou šablonou, která od pisatelů žádá úspěšně i neúspěšně řešenou situaci, prošel strukturací, anonymizací a redakční kontrolou a jeho zveřejněný řez z května 2026 čítá 3 202 kazuistik. Kazuistiky zachycují celé spektrum náročného chování od narušování výuky po šikanu a sebedestruktivní chování a repertoár řešení, v němž dominuje rozhovor a další reaktivní kroky; vztahová a kolektivní řešení se v nich pojí s příznivějším vnímaným výsledkem než řešení represivní. Korpus je zároveň časovou řadou řezů, a každé číslo knihy proto platí pro svůj datovaný řez.

Na druhou otázku, nakolik se jazykový model shodne s vyškolenými lidmi při deduktivní klasifikaci obsahu, odpovídá Studie 2. Na úplných dvojicích dosáhla shoda s lidským kódem typu řešení $\kappa = 0,64$. Po dodatečném vyloučení zjištěných překryvů s příklady činí $\kappa = 0,61$. Jde o retrospektivní kontrolu, ne o nový nezávislý test, a rozdíl oproti lidskému α na jiném

10. Závěr

vzorku dosažení lidského stropu nedokládá. Modelové kategorie proto vyžadují průběžnou kontrolu a nenahrazují lidský úsudek nad jednotlivým případem.

Na třetí otázku, jak se liší řešení generovaná modelem od autentických řešení učitelů, odpovídá Studie 3 zaslepeným hodnocením 324 dvojic řešení. Učitelská řešení byla hodnocena jako méně vhodná (rozdíl $-0,85$ bodu škály), jako reaktivnější a behaviorálnější, a měla zhruba třetinovou šanci, že v nich anotátorky rozpoznají některý z přístupů opřených o důkazy. Výsledek platí pro textovou podobu řešení, pro jediný model a jedinou instrukci; nedokládá, že „AI radí lépe než učitel“, ale že generované řešení může nabídnout kontrast k zaznamenanému postupu. Úplný repertoár ani znalosti jednotlivých učitelů studie neměřila.

Na čtvrtou otázku odpovídá Studie 4. Na dvojité posouzeném překryvu 693 kazuistik rozlišuje použitelnost textu, popsany dopad a vhodnost řešení. Po vyloučení projednaných případů vykazuje použitelnost vysokou vzájemnou shodu; bez vnějšího kritéria však nelze určit správnost posouzení. U dopadu činí $\kappa = 0,69$, u vhodnosti je shoda nižší. Porovnání dřívějších hodnocení s jednou pozdější anotátorkou dosahuje $\kappa = 0,59$; nejde o externí replikaci dvěma týmy. Rozdíly mezi částmi etapy časově souvisejí s rekalicací, ale její samostatný účinek nelze oddělit od závěru a změny posuzovaných případů.

Při předpovědi dopadu bez jeho popisu dosahuje model Kimi vyvážené přesnosti 60 %, tedy zřetelně nad hádáním většinové třídy, které dává 33 %. Párové intervaly rozdílů mezi modely i variantami s příklady zahrnují nulu, takže výsledek nedokládá jejich ekvivalenci ani informační strop úlohy. Lidská shoda při čtení popisu výsledku je kontextová reference, nikoli srovnatelná predikční úloha.

10.2 Přínos knihy

Přínos knihy je trojí. Empirický: kniha popisuje učitelské postupy zaznamenané v rozsáhlém souboru autentických českých situací. Převahu snadno dostupných reakcí označuje interpretačním pojmem repertoár nejmenšího odporu. Neměří však znalosti učitelů ani pří-

činy volby postupů. Souvislosti s kódovaným úspěchem se týkají historických anotačních kategorií, které částečně zahrnují i normativní posouzení přijatelnosti. Nejsou nezávislým důkazem účinnosti strategií.

Metodologický: kniha prověřila jazykový model ve třech rolích na jednom reálném korpusu v jazyce mimo angličtinu a v každé roli jej poměřila lidským měřítkem s měřenou reliabilitou. Z toho odvodila rozdělení rolí, které lze převzít: klasifikace obsahu na úrovni kategorií po validaci na vlastních datech, generování kontrastních řešení pro reflexi, žádné posuzování vhodnosti bez lidské reference. A doložila, že spolehlivost lidského posouzení je proměnná, kterou je třeba měřit, vykazovat z finálních dat, chránit před paradoxem shody a doprovázet přiznáním každého zásahu do protokolu.

Infrastrukturní: kniha zanechává korpus s datovanými řezy, tři anotační etapy s dokumentovanými schématy a maticí pokrytí, a doprovodný repozitář, v němž jsou analýzy, tabulky výsledných hodnot, skripty obrázků a odvozená data bez textů kazuistik a bez osobních údajů. Hlavní statistické výsledky lze přepočítat z odvozených dat a uložených predikcí bez nového volání modelu. Historické souhrny a dokumentační údaje jsou označené vstupy; bez neveřejných textů nelze nezávisle zopakovat původní anotaci, tvorbu příkladů ani kontrolu anonymizace. Pro český pedagogický výzkum je to zároveň první doklad, že jazykový model může být kriticky prověřeným nástrojem analýzy velkého korpusu autentického českého textu.

10.3 Směřování

Práce pokračuje třemi směry, které kniha připravila. Intervenční studie prověří, zda generované kontrastní řešení nad vlastní situací repertoár učitelů skutečně rozšiřuje; platforma Edustories pro ni poskytuje materiál, měřicí nástroj i očekávanou velikost mezery. Příští anotační etapa dostane časový záznam hodnocení, kontrolní body a označené přepisy, aby bylo možné vývoj spolehlivosti sledovat přesně. A opakování Studie 2 a predikčního experimentu s dalšími modely i poskytovateli, spolu s anglickou datovou sadou Edustories-en, ukáže, nakolik jsou výsledky vlastností úlohy a nakolik vlastností jednoho modelu a jednoho jazyka.

10. Závěr

Kniha tak nekončí tvrzením, že jazykové modely pedagogický výzkum promění. Ukazuje možnosti jejich kontrolovaného použití i hranice dosavadních ověření. Praktická doporučení rozlišují shodu, správnost, predikci a pedagogickou účinnost. Pro další použití je podstatné tuto odlišnost zachovat, nikoli hledat jediný koeficient vyjadřující univerzální hranici.

Literatura

- Acosta, J., Chinman, M., Ebener, P., Malone, P. S., Phillips, A., & Wilks, A. (2019). Evaluation of a whole-school change intervention: Findings from a two-year cluster-randomized trial of the Restorative Practices Intervention. *Journal of Youth and Adolescence*, 48(5), 876–890. <https://doi.org/10.1007/s10964-019-01013-2> ↗
- Adriani, P. A., Hino, P., Taminato, M., Okuno, M. F. P., Santos, O. V., & Fernandes, H. (2024). Non-violent communication as a technology in interpersonal relationships in health work: A scoping review. *BMC Health Services Research*, 24, Article 289. <https://doi.org/10.1186/s12913-024-10753-2> ↗
- Bendl, S. (2001). *Školní kázeň: Metody a strategie* [School discipline: Methods and strategies]. ISV.
- Bendl, S. (2011). *Kázeňské problémy ve škole* [Discipline problems at school] (2., aktualiz. a dopl. vyd.). Triton.
- Cipriano, C., Strambler, M. J., Naples, L. H., Ha, C., Kirk, M., Wood, M., Sehgal, K., Zieher, A. K., Eveleigh, A., McCarthy, M., Funaro, M., Ponnock, A., Chow, J. C., & Durlak, J. A. (2023). The state of evidence for social and emotional learning: A contemporary meta-analysis of universal school-based SEL interventions. *Child Development*, 94(5), 1181–1204. <https://doi.org/10.1111/cdev.13968> ↗
- Černochová, M., Selcuk, H., Cohen, A., Voštinár, P., Cohen, G., Azaria Yaakov, A., Jeřábek, T., Beneš, M., & Škrinářová, J. (2025). Generative artificial intelligence (GenAI) in K-12 edu-

cation: National policy perspectives from the Czech Republic, Israel, Latvia, and Slovakia. *Pedagogika*, 75(4), 381–400. <https://doi.org/10.14712/23362189.2025.4924>

Černý, M. (2023, 18. dubna). *ChatGPT ve školní praxi: nástroj oborové didaktiky* [ChatGPT in school practice: A tool for subject didactics]. Metodický portál RVP.CZ. <https://clanky.rvp.cz/clanek/23455/CHATGPT-VE-SKOLNI-PRAXI-NASTROJ-OBOROVE-DIDAKTIKY.html>

Černý, M. (2024). Gramotnost pro umělou inteligenci: koncepty, přístupy a otevřené otázky [Literacy for artificial intelligence: Concepts, approaches and open questions]. *e-Pedagogium*, 24(2), 7–16. <https://doi.org/10.5507/epd.2024.009>

Darling-Hammond, S., Fronius, T. A., Sutherland, H., Guckenburg, S., Petrosino, A., & Hurley, N. (2020). Effectiveness of restorative justice in US K-12 schools: A review of quantitative research. *Contemporary School Psychology*, 24(3), 295–308. <https://doi.org/10.1007/s40688-020-00290-0>

Durlak, J. A., Mahoney, J. L., & Boyle, A. E. (2022). What we know, and what we need to find out about universal, school-based social and emotional learning programs for children and adolescents: A review of meta-analyses and directions for future research. *Psychological Bulletin*, 148(11–12), 765–782. <https://doi.org/10.1037/bul0000383>

Durlak, J. A., Weissberg, R. P., Dymnicki, A. B., Taylor, R. D., & Schellinger, K. B. (2011). The impact of enhancing students' social and emotional learning: A meta-analysis of school-based universal interventions. *Child Development*, 82(1), 405–432. <https://doi.org/10.1111/j.1467-8624.2010.01564.x>

Epinat-Duclos, J., Foncelle, A., Quesque, F., Chabanat, E., Duguet, A., Van der Henst, J.-B., & Rossetti, Y. (2021). Does nonviolent communication education improve empathy in French medical students? *International Journal of Medical Education*, 12, 205–218. <https://doi.org/10.5116/ijme.615e.c507>

Feinstein, A. R., & Cicchetti, D. V. (1990). High agreement but low kappa: I. The problems of two paradoxes. *Journal of Clinical Epidemiology*, 43(6), 543–549. <https://doi.org/10.1016/>

[0895-4356\(90\)90158-L ↗](#)

Felcmanová, L., Hečková, L., Myšková, L., Němec, Z., Krejčová, L., Winkler, P., Dvořáková, K., Houška, P., Franke, H., Korbel, M., Kubíčková, A., Šimáčková Laurenčíková, K., Nosál, I., Salomonová, M., Smrž, J., Turková, K., Zatloukal, T., Andrys, O., Pražáková, D., ... Borkovcová, I. (2021). *Přístupy k náročnému chování dětí a žáků ve školách a školských zařízeních a možnosti jeho řešení: Metodické doporučení* [Approaches to challenging behaviour of children and pupils in schools and school facilities and options for addressing it: Methodological recommendation]. Česká školní inspekce. https://www.csicr.cz/CSICR/media/Elektronicke-publikace/2021/MD_Pristupy_k_narocnemu_chovani_deti_a_zaku/html5/index.html ↗

Felcmanová, L., Kubíčková, A., & Vlachová, P. (2023). *Pozitivní podpora a vhodné reakce na chování žáků: Ověřené pedagogické strategie pro práci s žáky* [Positive support and appropriate responses to pupil behaviour: Evidence-based teaching strategies]. Society for All. <https://www.societyforall.cz/pozitivni-podpora-a-vhodne-reakce-na-chovani-zaku> ↗

Fronius, T., Darling-Hammond, S., Persson, H., Guckenburg, S., Hurley, N., & Petrosino, A. (2019). *Restorative justice in U.S. schools: An updated research review*. WestEd Justice and Prevention Research Center. <https://eric.ed.gov/?id=ED595733> ↗

Gilardi, F., Alizadeh, M., & Kubli, M. (2023). ChatGPT outperforms crowd workers for text-annotation tasks. *Proceedings of the National Academy of Sciences*, 120(30), Article e2305016120. <https://doi.org/10.1073/pnas.2305016120> ↗

Gwet, K. L. (2008). Computing inter-rater reliability and its variance in the presence of high agreement. *British Journal of Mathematical and Statistical Psychology*, 61(1), 29–48. <https://doi.org/10.1348/000711006X126600> ↗

Hallgren, K. A. (2012). Computing inter-rater reliability for observational data: An overview and tutorial. *Tutorials in Quantitative Methods for Psychology*, 8(1), 23–34. <https://doi.org/10.20982/tqmp.08.1.p023> ↗

Havlíčková, M., Šťastný, V., Boudová, S., & Basl, J. (2025). *Národní zpráva TALIS 2024* [TALIS 2024 national report]. Česká školní inspekce. <https://www.csicr.cz/cz/Dokumenty/Publikace-a-ostatni-vystupy/Narodni-zprava-TALIS-2024> ↗

Honzík, L., Huclová, M., Königsmarková, S., & Vrbová, V. (2025). Některá omezení generativní umělé inteligence při řešení logických problémů [Some limitations of generative artificial intelligence in solving logical problems]. *Pedagogika*, 75(4), 341–353. <https://doi.org/10.14712/23362189.2025.4920> ↗

Horner, R. H., & Sugai, G. (2015). School-wide PBIS: An example of applied behavior analysis implemented at a scale of social importance. *Behavior Analysis in Practice*, 8(1), 80–85. <https://doi.org/10.1007/s40617-015-0045-4> ↗

Karasová, J., & Nehyba, J. (2023). Student-centered teacher responses to student behavior in the classroom: A systematic review. *Frontiers in Education*, 8, Article 1156530. <https://doi.org/10.3389/feduc.2023.1156530> ↗

Karasová, J., & Nehyba, J. (2025). Novice teachers' classroom behaviour management: Situations, responses and impact on student behaviour. *British Educational Research Journal*, 51(5), 2116–2141. <https://doi.org/10.1002/berj.4166> ↗

Kasneci, E., Seßler, K., Küchemann, S., Bannert, M., Dementieva, D., Fischer, F., Gasser, U., Groh, G., Günemann, S., Hüllermeier, E., Krusche, S., Kutyniok, G., Michaeli, T., Nerdel, C., Pfeffer, J., Poquet, O., Sailer, M., Schmidt, A., Seidel, T., ... Kasneci, G. (2023). ChatGPT for good? On opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103, Article 102274. <https://doi.org/10.1016/j.lindif.2023.102274> ↗

Kopecký, K., & Voráč, D. (2024). *Čeští žáci a umělá inteligence – výzkumná zpráva* [Czech pupils and artificial intelligence – research report]. Centrum prevence rizikové virtuální komunikace, Pedagogická fakulta Univerzity Palackého v Olomouci. <https://e-bezpeci.cz/index.php/ke-stazeni/vyzkumne-zpravy/190-cesti-zaci-a-umela-inteligence-2024/file> ↗

- Kopecký, K., Kříž, M., Krejčí, V., Mašát, M., & Voráč, D. (2025). Using generative artificial intelligence to support learning with a specific focus on language and literature education. *Pedagogika*, 75(4), 471–484. <https://doi.org/10.14712/23362189.2025.4911> ↗
- Kopecký, K., Szotkowski, R., Voráč, D., Krejčí, V., & Dobešová, P. (2023). *České školy a umělá inteligence – výzkumná zpráva* [Czech schools and artificial intelligence – research report]. Centrum prevence rizikové virtuální komunikace, Pedagogická fakulta Univerzity Palackého v Olomouci. <https://www.e-bezpeci.cz/index.php/ke-stazeni/vyzkumne-zpravy/163-ceske-skoly-a-umela-inteligence-2023/file> ↗
- Korpershoek, H., Harms, T., de Boer, H., van Kuijk, M., & Doolaard, S. (2016). A meta-analysis of the effects of classroom management strategies and classroom management programs on students' academic, behavioral, emotional, and motivational outcomes. *Review of Educational Research*, 86(3), 643–680. <https://doi.org/10.3102/0034654315626799> ↗
- Krippendorff, K. (2018). *Content analysis: An introduction to its methodology* (4th ed.). SAGE.
- Kubíčková, A., & Felcmanová, L. (2021). Možnosti podpory duševního zdraví žáků [Opportunities for pupils' mental health support]. *Pedagogická orientace*, 31(1), 70–96. <https://doi.org/10.5817/PedOr2021-1-70> ↗
- Lee, A., & Gage, N. A. (2020). Updating and expanding systematic reviews and meta-analyses on the effects of school-wide positive behavior interventions and supports. *Psychology in the Schools*, 57(5), 783–804. <https://doi.org/10.1002/pits.22336> ↗
- Lortie, D. C. (1975). *Schoolteacher: A sociological study*. University of Chicago Press.
- Lukas, J., & Lojďová, K. (2018). Řízení třídy: přístupy, oblasti, strategie [Classroom management: Approaches, areas, strategies]. *Pedagogika*, 68(2), 155–172. <https://doi.org/10.14712/23362189.2017.1180> ↗
- Ministerstvo školství, mládeže a tělovýchovy. (2010). *Metodické doporučení k primární prevenci rizikového chování u dětí, žáků a studentů ve školách a školských zařízeních* (č. j. 21291/2010-28) [Methodological recommendation on primary prevention of risk behaviour

among children, pupils and students in schools and school facilities]. <https://msmt.gov.cz/vzdelavani/socialni-programy/metodicke-dokumenty-doporuceni-a-pokyny> ↗

Ministerstvo školství, mládeže a tělovýchovy. (2023). *Rámcový vzdělávací program pro základní vzdělávání* [Framework educational programme for basic education]. https://www.edu.cz/wp-content/uploads/2023/07/RVP_ZV_2023_cista_verze.pdf ↗

Ministerstvo školství, mládeže a tělovýchovy. (2025). *Rámcový vzdělávací program pro základní vzdělávání* [Framework educational programme for basic education] (revidované znění, opatření ministra č. j. MSMT-20704/2024-5). <https://prohlednout.rvp.cz/zakladni-vzdelavani> ↗

Národní pedagogický institut ČR. (2023). *Doporučení, jak pracovat s umělou inteligencí* [Recommendations on how to work with artificial intelligence]. NPI ČR. <https://www.npi.cz/aktuality/74837-doporuceni-jak-pracovat-s-umelou-inteligenci> ↗

Nehyba, J., & Štefánik, M. (2023). Applications of deep language models for reflective writings. *Education and Information Technologies*, 28(3), 2961–2999. <https://doi.org/10.1007/s10639-022-11254-7> ↗

Nehyba, J., Karasová, J., & Štefánik, M. (2024). *Edustories-en* [Data set]. Hugging Face. <https://huggingface.co/datasets/MU-NLPC/Edustories-en> ↗

Nehyba, J., Karasová, J., Škarková, L., Fico, M., Košatková, M., Košatka, D., & Štefánik, M. (2024). Edustories: analýza kazuistik o náročném chování žáků [Edustories: An analysis of case studies on challenging student behaviour]. In A. Rozkovcová & J. Pivarč (Eds.), *Spolupráce oborů pro podporu kvality vzdělávání: Sborník příspěvků z XXXII. výroční konference České asociace pedagogického výzkumu* (s. 256–260). MSD.

OECD. (2025). *Results from TALIS 2024: The state of teaching*. OECD Publishing. <https://doi.org/10.1787/90df6235-en> ↗

Ollion, É., Shen, R., Macanovic, A., & Chatelain, A. (2024). The dangers of using proprietary LLMs for research. *Nature Machine Intelligence*, 6(1), 4–5. <https://doi.org/10.1038/s42256-023-00783-6> ↗

- Payne, G., & Hustler, D. (1980). Teaching the class: The practical management of a cohort. *British Journal of Sociology of Education*, 1(1), 49–66. <https://doi.org/10.1080/0142569800010104> ↗
- Reiss, M. V. (2023). *Testing the reliability of ChatGPT for text annotation and classification: A cautionary remark* [Preprint]. arXiv. <https://doi.org/10.48550/arXiv.2304.11085> ↗
- Rosenberg, M. B. (2015). *Nonviolent communication: A language of life* (3rd ed.). PuddleDancer Press.
- Rosenberg, M. B. (2022). *Nenásilná komunikace: Řeč života* [Nonviolent communication: A language of life] (N. Garciová, Přel.; rev. a dopl. vyd.). Portál.
- Simonsen, B., Fairbanks, S., Briesch, A., Myers, D., & Sugai, G. (2008). Evidence-based practices in classroom management: Considerations for research to practice. *Education and Treatment of Children*, 31(3), 351–380. <https://doi.org/10.1353/etc.0.0007> ↗
- Swidler, A. (1986). Culture in action: Symbols and strategies. *American Sociological Review*, 51(2), 273–286. <https://doi.org/10.2307/2095521> ↗
- Šed'ová, K., Švaříček, R., & Šalamounová, Z. (2012). *Komunikace ve školní třídě* [Communication in the school classroom]. Portál.
- Ševčíková, J., Buchtová, T., & Plischke, J. (2023). Nekázeň žáků v reflexích začínajících učitelů v České republice (a možnosti jejich ovlivnění) [Pupil indiscipline in the reflections of novice teachers in the Czech Republic (and options for influencing them)]. *Paidagogos*, 2023(1–2), čl. 1. <https://paidagogos.net/issues/2023/1-2/article.php?id=1> ↗
- Törnberg, P. (2025). Large language models outperform expert coders and supervised classifiers at annotating political social media messages. *Social Science Computer Review*, 43(6), 1181–1195. <https://doi.org/10.1177/08944393241286471> ↗
- Valenta, J. (2006). *Osobnostní a sociální výchova a její cesty k žákovi* [Personal and social education and its paths to the pupil]. AISIS.

Veenman, S. (1984). Perceived problems of beginning teachers. *Review of Educational Research*, 54(2), 143–178. <https://doi.org/10.3102/00346543054002143> ✓

Vlčková, K., Lojdová, K., Lukas, J., Mareš, J., Škarková, L., Kohoutek, T., Květon, P., & Ježek, S. (2020). *Řízení třídy: studenti učitelství a jejich provázející učitelé* [Classroom management: Student teachers and their mentor teachers]. Masarykova univerzita. <https://doi.org/10.5817/CZ.MUNI.M210-9652-2020> ✓

Vyhláška č. 27/2016 Sb., o vzdělávání žáků se speciálními vzdělávacími potřebami a žáků nadaných. (2016). *Sbírka zákonů České republiky*, částka 10. <https://www.zakonyprolidi.cz/cs/2016-27> ✓

Yan, L., Sha, L., Zhao, L., Li, Y., Martinez-Maldonado, R., Chen, G., Li, X., Jin, Y., & Gašević, D. (2024). Practical and ethical challenges of large language models in education: A systematic scoping review. *British Journal of Educational Technology*, 55(1), 90–112. <https://doi.org/10.1111/bjet.13370> ✓

Zákon č. 82/2015 Sb., kterým se mění zákon č. 561/2004 Sb., o předškolním, základním, středním, vyšším odborném a jiném vzdělávání (školský zákon), ve znění pozdějších předpisů, a některé další zákony. (2015). *Sbírka zákonů České republiky*, částka 37. <https://www.zakonyprolidi.cz/cs/2015-82> ✓

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track*. https://proceedings.neurips.cc/paper_files/paper/2023/hash/91f18a1287b398d378ef22505bf41832-Abstract-Datasets_and_Benchmarks.html ✓

Ziems, C., Held, W., Shaikh, O., Chen, J., Zhang, Z., & Yang, D. (2024). Can large language models transform computational social science? *Computational Linguistics*, 50(1), 237–291. https://doi.org/10.1162/coli_a_00502 ✓

Příloha A. Kódovací manuály

Tato příloha dokládá kódovací nástroje všech tří anotačních etap v podobě, v jaké je anotátorky používaly. Definice kategorií a škálových bodů jsou převzaty doslovně ze zdrojových souborů (včetně případných stylistických nedokonalostí předlohy); komentář knihy je od citací typograficky oddělen. Vývoj nástrojů mezi verzemi je popsán explicitně, protože kniha verze schémat zásadně nesměšuje (kapitola 4).

A.1 První etapa: kódovací kniha obsahového kódování

Kódovací kniha vznikala induktivně: v zácvičné fázi (zima 2023/2024) anotátorky otevřeně kodovaly menší vzorky kazuistik do vlastních listů a z těchto kódů byl postupně sestaven kódovací strom (verze V1), který byl po kalibračních kolech zpřesněn do finální verze V2. Verze V2 přidala anotační kódy (zkratky kategorií) a upřesnila definice; kategorie chování „Neuposlechnutí pokynu“ z V1 byla ve V2 zrušena. Finální anotování (kapitola 4) probíhalo podle V2 se závazným kódovacím postupem, který zdrojový soubor uvádí takto:

1. Při kódování kódujeme pouze to, co je explicitně napsáno, snažíme se vystihnout jen to, co přímo souvisí s problémem/řešením. [...]
2. U kódů k řešení situací je to stejné - kóduji pouze to, co učitel explicitně zmiňuje, že použil jako konkrétní řešení (ne, co by si myslel, že by fungovalo; ne co se stalo o pár měsíců později).
3. Pozor na to, aby byly v kategoriích napsány přesné názvy kódů.
4. Pozor na to, jak zní definice kategorie, kterou ke kódu dáváte. Vždy

si jí dobře pročtete a zvažte, jestli i ta definice sedí s tím, co je v textu.

[z navazujícího seznamu téhož listu, bod 1:]

1. Flat/deep - budeme kódovat jako flat, pokud v kazuistice chybí nějaká část, pokud kazuistika z nějakého jiného důvodu nejde použít (je příliš stručná, není ze školního kontextu, nejedná se o popis problémové situace atd.). [...]

Poznámka. Přepsáno z interního kódovacího stromu první etapy (list Kódovací postup). Výpustky vyznačeny [...]; vynechány zbylé body navazujícího seznamu (kontrola správnosti výstupu šablony) a technická poznámka o zaškrťovací liště; plné znění ve zdrojovém souboru.

Tabulka A.1. Analyticky použité kategorie typů náročného chování (finální verze V2; definice doslovně).

Kategorie	Kód	Definice
Fyzická agrese	FAG	Žák/žákyně fyzicky napadá/poškozuje/ubližuje nebo hrozí ublížením spolužákům, učiteli, nebo ničí majetek školy nebo věci spolužáků/učitele (hází věcmi, rozbíjí věci, vyhrožuje nožem, kope do věcí, pere se, bije,...)

A.1 První etapa: kódovací kniha obsahového kódování

Kategorie	Kód	Definice
Verbální agrese	VAG	Žák záměrně používá verbální výraz/y, které jsou vulgární nebo mají za cíl ublížit (ponížit,...) učiteli/spolužákům.
Šikana	SIK	Dlouhodobé záměrné verbální nebo neverbální ubližování spolužákovi/spolužačce/učiteli.
Emoční výbuchy	EV	Afektivní - Vyafektované chování, krátkodobá silná a prudká emoční reakce na podnět při sníženém sebeovládání. Žák nezvládne nápor emocí. Může se to projevit tak, že je vybíjí agresivním chováním ven (udeří spolužáka, hází předměty, ničení nábytku školy,...)
Lhaní a podvody	LH	Žák/žákyně záměrně poskytuje nepravdivé informace učiteli/rodičům.

Kategorie	Kód	Definice
Nevěnování se výuce/Nepozornost při výuce	NEV	Žák/žákyně se nevěnuje výuce - nedává pozor, není aktivní, běhá po třídě, ignoruje pokyny učitele, spí, dívá se z okna, atd.
Neplnění školních povinností/nepřipravenost na výuku	NEP	Žák/žákyně neplní své školní povinnosti (učení se, nošení pomůcek,...)
Nezvládání výuky	NEZ	Dítěti brání absence dovednosti zvládat výuku.
Verbální narušování výuky	VER	Žák/žákyně narušuje hodinu verbálními projevy.
Porušování třídních/školních pravidel	PRA	Žák porušuje třídní nebo školní pravidla
Neverbální narušování výuky	NEVER	Žák/žákyně narušuje vyučování neverbálním chováním (interakcí s věcmi, hlučnými pohyby,...)
Sebedestruktivní chování	SEB	Žák/žákyně si záměrně ubližuje/hrozí ublížením.
Problémy s docházkou	DOC	Dívka chodila za školu.

Poznámka. Přepsáno z interního kódovacího stromu první etapy (list Problémové chování). Definice kategorie Problémy s docházkou je ve zdroji formulována příkladem; ponecháno doslovně. Zdrojový strom obsahoval ještě položku DIA, jejíž definice popisovala přítomnost diagnózy žáka, nikoli jeho chování. V deskriptivě i výpočtu shody je proto vyřazena a údaj o diagnóze se čte z kurátorovaného kontextového pole korpusu (oddíly 5.3, 5.4 a 6.3). Tím zů-

stává zachován doklad původního nástroje, aniž by byla kontextová vlastnost prezentována jako čtrnáctý typ chování.

Tabulka A.2. Kategorie typů řešení (finální verze V2; definice doslovně).

Kategorie	Kód	Definice
Rozhovor	ROZ	Řešení problému rozhovorem (s rodiči, se žákem, s třídou,...). Cíleně vedený rozhovor za účelem zjištění více informací a řešení dané situace.
Dohoda	DOH	Dohoda učitele s žákem/třídou na společně přijatelném řešení.
Práce s kolektivem	KOL	Učitel řeší situaci skrze podporu vztahů ve třídě, čímž se snaží situaci vyřešit a zároveň předcházet dalším
Spolupráce s odborníky	SPO	Učitel vyhledává pomoc jinde - mezi odborníky v rámci školy i mimo školu.
Upozornění	UPO	Učitel popisuje žákovo chování, které je pro něj rušivé. Žák je verbálně upozorněn na rušivé chování.

Kategorie	Kód	Definice
Přemístění žáka	PRE	Učitel řeší situaci tak, že žák/žákyně opouští danou situaci a je přemístěn(a) v rámci třídy, školy nebo systému.
Nerespektující komunikace	NER	Učitel volí formu reakce skrze verbální komunikační bloky, např. vyhrožování, křik, oplácení chování, rozkaz...
(Kázeňské) Tresty	TRE	Učitel řeší situaci formou trestu, který není přímým důsledkem žákova chování. Příčina-následek není - trest nesouvisí přímo s chováním žáka. Učitel pojmenovává zásah jako trestající.
Důsledky	DUS	Žák/žákyně plní přirozené důsledky, které vyplývají z jeho chování. Učitel poskytl informaci, která seznamuje žáka s tím, že toto je důsledek, který se stane, když bude v nekázni pokračovat. (sociálně vyjednané)

Kategorie	Kód	Definice
Fyzické zakročení	FYZ	Učitel fyzicky reaguje na chování žáka.
Podpora	POD	Žák/žákyně dostává speciální formu individuální podpory, např. skrze asistenta nebo IVP.

Poznámka. Přepsáno z interního kódovacího stromu první etapy (list Řešení situací).

Poznámka ke kategorii Proaktivní řešení. Ve verzi V1 byla „Proaktivní řešení“ samostatnou kategorií s definicí (doslovně): „Učitel volí strategie, kterými předchází dalšímu potenciálnímu náročnému chování žáků a které vrací pozornost žáků směrem k výuce.“; ve verzi V2 byla přesunuta mezi podřazené kódy a číselná řada kategorií po ní nese mezeru. Do klasifikačního promptu jazykového modelu (příloha B) přesto vstoupila jako samostatná položka s vlastní definicí, a proto ji model v korpusu přiřazuje (kapitola 6). V lidském kódování první etapy ji jako samostatnou kategorii zaznamenala jediná anotátorka, u níž se do výběrového seznamu řešení omylem dostala namísto kategorie „Fyzické zakročení“; v korpusové deskriptivě (kapitola 5) ji proto mezi lidské kategorie řešení nezařazujeme (kmenová sada řešení má 11 položek), zatímco v porovnání s modelem (kapitola 6) ji ponecháváme jako kategorii predikovanou modelem. V datech se ojediněle vyskytují i štítky mimo strom (například „humor“) a překlepové varianty; deskriptivní analýzy je normalizují na kanonické znění (kapitola 5).

Tabulka A.3. Kategorie dopadu řešení (finální verze V2; definice doslovně).

Kategorie	Kód	Definice
Neúspěch	NEU	Chování žáka nebo daná situace se nijak nezměnila. Nebo učitel použil k vyřešení situace neakceptovatelné a nevhodné způsoby (fyzické násilí, psychické násilí, nerespektující strategie) - ne v souladu s hodnotami chováním učitele.
Částečný úspěch	CU	Chování žáka nebo daná situace se změnila jen částečně.
Krátkodobý úspěch	KU	Situace se změnila pouze na krátkou dobu a poté se chování začalo opět opakovat.
Dlouhodobý úspěch	DU	Situaci se podařilo vyřešit v danou chvíli a chování/situace se již neopakovala.

Poznámka. Přepsáno z interního kódovacího stromu první etapy (list Dopad řešení). Zdroj u kategorie Částečný úspěch nese překlep „Částěčný“; analýzy jej normalizují (kapitola 5).

Historické definice jsou zachovány doslovně. NEU však spojuje popsané nezměněné chování s hodnotovým odmítnutím prostředku. Konečný štítek neumožňuje určit, který z těchto

důvodů rozhodl. Ani ve třetí etapě není plochost pouze technickou neúplností: zahrnuje také eticky nepřijatelné jednání. Tato konstrukční omezení zohledňují kapitoly 4, 5 a 8; chybějící důvod kódu se nedoplňuje odhadem.

A.2 Druhá etapa: manuál hodnocení kvality řešení

Manuál druhé etapy definuje pojmy tří bipolárních dimenzí, čtyři rámce opřené o důkazy a škálové body. Anotátorky hodnotily každé řešení (učitelské i generované, zaslepeně; kapitola 7) na čtyřech škálách a označovaly rozpoznané rámce.

Tabulka A.4. Vymezení pólů bipolárních dimenzí (definice doslovně).

Pojem	Definice
Reaktivní řešení	Okamžitá reakce na aktuální problém či konflikt ve třídě. Cílem je rychle obnovit řád a minimalizovat negativní dopady na průběh výuky.
Proaktivní řešení	Preventivní opatření a postupy, které předcházejí vzniku problémového chování či náročných situací. Učitel je plánuje a zavádí dopředu, aby žáky učil principy prosociálního chování a aby ve třídě vytvořil pozitivní prostředí a jasná pravidla.

Pojem	Definice
Systémové řešení	Komplexní rámec, který platí pro celou třídu nebo školu. Přináší jasně definované zásady, postupy a jednotné přístupy ke zvládání chování, na nichž se podílí vedení, učitelé i žáci (využívá další aktéry jako školní psycholog, metodik prevence, školní programy, rodiče...)
Situační řešení	Okamžitá a flexibilní reakce v rámci konkrétní situace. Učitel volí postup podle aktuálních podmínek a potřeb žáků s cílem minimalizovat narušení výuky a vyřešit konflikt nebo nežádoucí chování na místě.
Humanisticky orientované	V centru pozornosti je žák (jeho potřeby, motivace, emoční stav). Učitel buduje vztah založený na empatii, respektu a sebereflexi. Učitel vědomě pěstuje respektující a empatický přístup, dává žákovi prostor vyjádřit se, vede ho k uvědomění si dopadu svého chování a společně s ním hledá možná řešení.
Behaviorálně orientované	Vychází z behaviorálních teorií učení, kde se posiluje žádoucí chování nebo potlačuje nežádoucí chování pomocí odměn (pochval, výhod) či trestů (sankcí). Řešení je jasně nastavené (učitel se rozhodnul a řešení nastavil), nebere ohledy na pocity/potřeby žáků, je direktivní směrem od učitele.

Poznámka. Přepsáno z interního kódovacího manuálu druhé etapy (list Popis definic).

Škály. Celková vhodnost byla ve formuláři zadávána jako pětibodová (1 – Zcela nevhodné, 2 – Spíše nevhodné, 3 – Vyvážené, 4 – Spíše vhodné, 5 – Zcela vhodné); v analyzovaném souboru je lineárně překódována na –2 až +2 jako ostatní dimenze (kapitola 7). Tři bipolární dimenze užívají pětibodovou škálu –2 až +2, jejíž krajní a střední body zdroj definuje takto (výběr; plné znění všech bodů ve zdrojovém souboru):

Reaktivní vs. Proaktivní

- 2 – Čistě reaktivní: „Řešení se zaměřuje výhradně na okamžitou reakci na vzniklý problém či konflikt, aniž by zahrnovalo preventivní opatření či dlouhodobou vizi.“
- 0 – Vyvážené: „Řešení kombinuje okamžitou reakci s preventivními kroky...”
- +2 – Čistě proaktivní: „Řešení je plně orientované na prevenci – učitel plánuje a zavádí opatření před vznikem problému...”

Systémové vs. Situační (konverzační)

- 2 – Plně systémové: „Řešení vychází z jednotného, jasně definovaného rámce a pravidel, platných pro celou třídu nebo školu...”
- +2 – Plně situační (konverzační): „Řešení je zcela situační a flexibilní, přizpůsobuje se okamžitým potřebám a podmínkám, aniž by se opíralo o přísně daný systém.”

Humanisticky vs. Behaviorálně orientované

- 2 – Plně humanisticky orientované: „Řešení se zcela soustředí na individuální potřeby, motivaci a emoční stav žáků...”
- +2 – Plně behaviorálně orientované: „Řešení je zcela orientované na behaviorální techniky, využívá jasně definovaných odměn a sankcí...”

Poznámka. Přepsáno z interního kódovacího manuálu druhé etapy (list se škálami, aktuální

znění). Orientace pólů (záporný pól = reaktivní/systémové/humanistické) odpovídá znaménkům výsledků v kapitole 7.

Rámce. Manuál definuje čtyři přístupy opřené o důkazy, které anotátorky rozpoznávaly ve znění řešení: PBIS (pozitivní behaviorální intervence a podpora; systémový přístup s jasnými pravidly, konzistentní pozitivní zpětnou vazbou a předem určenými kroky při porušení pravidel), SEL (sociálně-emoční učení; dlouhodobý rozvoj emočních a vztahových dovedností, seberegulace a odpovědného rozhodování), NVC (nenásilná komunikace; respektující dialog ve čtyřech krocích pozorování, pocity, potřeby, prosba) a restorativní praxe (náprava škody a obnovení vztahů namísto trestu). Plné znění definic s příklady z praxe uvádí list „Popis definic“ zdrojového souboru; teoretické ukotvení rámců podává kapitola 2.

A.3 Třetí etapa: operacionalizace kvality kazuistik

Třetí etapa posuzovala kvalitu kazuistiky, dopad řešení a vhodnost řešení. Nástroje byly definovány takto (definice doslovně):

Tabulka A.5. Kvalita kazuistiky (binární posouzení).

Kategorie	Definice
Plochá (nepoužitelná)	Kazuistika neposkytuje dostatek informací pro pochopení situace ani pro interpretaci řešení. Nebo učitel použil k vyřešení situace neakceptovatelné a nevhodné způsoby (fyzické násilí, psychické násilí, vysoce nerespektující strategie) - ne v souladu s hodnotami chováním učitele a právy dítěte.
Použitelná (dostatečná - skvělá)	Kazuistika poskytuje dostatek informací pro základní pochopení situace a pro interpretaci řešení.

Poznámka. Přepsáno z interního kódovacího manuálu třetí etapy; z definice kategorie Plochá byla vypuštěna editorská instrukce předlohy („+ PŘIDAT KOMENTÁŘ K PLOCHOSTI“). V anotačních datech je kladná kategorie zapisována štítkem „Plná“; kniha obě označení ztotožňuje a v próze i analýzách používá znění z dat (plná, plochá).

Dopad řešení je ve třetí etapě tříkategorální: Neúspěch (NEU), Krátkodobý/částečný úspěch (KU) a Dlouhodobý úspěch (DU). Oproti první etapě jsou tedy kategorie Částečný a Krátkodobý úspěch sloučeny; dopady z obou etap proto nelze přímo slučovat bez explicitního převodu (kapitola 4). **Vhodnost řešení** je čtyřbodová bez středního bodu (1 – Zcela nevhodné, 2 – Spíše nevhodné, 3 – Spíše vhodné, 4 – Zcela vhodné); s pětibodovou vhodností druhé etapy se nesměšuje (kapitola 4). Vedle kategorií anotátorky vyplňovaly tři textové komentáře (jazykový komentář, komentář k plochosti s povinným zdůvodněním, další komentář).

Postup etapy a pilotní shoda. Zdrojový soubor dokumentuje zamýšlený postup etapy a shodu z pilotáže na padesáti kazuistikách doslovně takto:

Budeme kódovat takto:

- děláme zaškolení na 5-10 kazuistikách (jen vysvětlení pojmů, nácvik kódování)
- poté budou anotátorky kódovat 20 kazuistik. Projdeme společně každou z nich a nesrovnalosti vyjasníme a dle toho upravíme kódovací manuál (viz operacionalizace pojmů výše)
- poté budou anotátorky kódovat 50 kazuistik - spočte se shoda [...]. Shoda vyšla ve všech případech nad 80%, někde i nad 90% [...]
- kóduje se 1950 kazuistik, z toho 695 je překryv pro výpočet shody
- poté se opět spočte shoda [...]

Shoda z pilotáže je ve zdroji zapsána slovensky, doslovně takto:

1. Sloupec: Kvalita kazuistiky:

Zhoda: 97.96%

Cohen's kappa: nedefinována: jedna z anotatorií neoznačila ani jednu kazuistiku za "plochu".

2. Sloupec: Dopad řešení:

Zhoda: 93.88%

Cohen's kappa: 0.8960

3. Sloupec: Vhodnost:

Zhoda: 89.80%

Cohen's kappa: 0.8131

Poznámka. Přepsáno z interního kódovacího manuálu třetí etapy. Výpustky vyznačeny [...]; vypuštěny pouze zmínky o členech týmu (anonymizace). Jde o pilotní hodnoty z podkladu etapy; shodu na finálních datech uvádí Studie 4 (kapitola 8).

Příloha B. Prompty jazykových modelů

Tato příloha dokládá doslovné znění promptů, jimiž jazykové modely vstupovaly do vzniku a analýzy dat knihy. Prompty jsou citovány přesně tak, jak běžely (včetně stylistických nedokonalostí originálu), protože doslovnost je podmínkou reprodukovatelnosti. U každého promptu je uveden model, parametry a zdrojový soubor v archivu projektu. Příloha obsahuje pouze prompty, jejichž znění je v archivu doloženo; co doloženo není, je označeno výslovně.

Tabulka B.1. Přehled dokladovaných promptů.

Krok zpracování	Model	Zdroj znění	Oddíl
Extrakce a strukturace kazuistik	gpt-4o (Batch API; dříve gpt-4-1106-preview)	interní extrakční notebook projektu	B.1
Anonymizace (třetí stupeň)	součást promptu extrakce	tamtéž	B.2
Klasifikace řešení (model v roli anotátora)	gpt-4o, finální běh	interní klasifikační notebook projektu	B.3
Generace srovnávacího řešení (druhá etapa)	gpt-4o	rukopis článku o srovnání řešení a návrh studie	B.4

Krok zpracování	Model	Zdroj znění	Oddíl
Rámcovaná řešení platformy	(produkční kód platformy)	v archivu nedoloženo	B.5

B.1 Extrakce a strukturace kazuistik

Odevzdané texty dělí do čtyř sekcí strukturační prompt, který zároveň provádí třetí stupeň anonymizace (oddíl B.2). Finální běh: gpt-4o přes Batch API, teplota nula; totéž znění běželo dříve na modelu gpt-4-1106-preview s pojistkou opakování (tři pokusy, práh délky výstupu, mírné zvýšení teploty). Vstupem je text po strojové anonymizaci (sloupec anonymized_content).

System:

- Jsi expert na univerzitě, který má za úkol detailně přepsat slovo od slova a následně upravit texty (kazuistiky) popisující problémové chování žáků na škole.
- Uživatel (User) ti poskytne celý text kazuistiky.

User:

- Doslovně transkribuj tento vstupní text "{text}" kazuistiky tak, aby odpovídal původnímu obsahu co nejpřesněji, a poté tento text rozděl do čtyř specifických sekcí podle následujících kritérií:
 - V sekci 'description' umístí text od začátku 'Podrobného popisu (vzniku) situace' až do 'Anamnéza'.
 - V sekci 'anamnesis' umístí text od 'Anamnéza' až do 'popis řešení'.
 - V sekci 'solution' umístí text popisující řešení situace, začínající od 'popis řešení' až do 'Výsledek'.
 - V sekci 'outcome' umístí text popisující dlouhodobý výsledek od

'Výsledek' až do konce narativního popisu situace.

- Pokud vstupní text kazuistiky neobsahuje rozdělení na Podrobný popis (vzniku) situace, Anamnéza a podobně, pak veškerý vstupní text pouze rozděl podle svého nejlepšího uvážení do jednotlivých sekcí.
- V sekcích odstraň úvodní zadání jako: "Podrobný popis (vzniku) situace na úrovni chování", "Anamnéza žáka/žáků nebo třídy (max. 2 normostrany, chronologicky)", "Podrobný popis řešení problematického chování", "Výsledek řešení (krátkodobě-jak to probíhalo hned po incidentu a dlouhodobě-zda se to nějak odrazilo v dalších hodinách, chronologicky, max. 2 normostrany)".
- Každou sekci začni smysluplným slovem, kterým obvykle začínají věty v českém jazyce, například jako "Žák", "Učitel", "Žáci", "Situace" a podobně.
- Ve výstupu v sekcích použij maximum doslovných citací ze vstupního textu kazuistiky.
- Zkontroluj, že jsi transkriboval (transcribe) veškerý vstupní text kazuistiky, pokud ne, tak jej doplň o chybějící části textu.
- Celkově by měly mít všechny sekce dohromady stejný počet tokenů jako vstupní text kazuistiky.
- Svůj výstup poskytni v tomto formátu: ("description": "", "anamnesis": "", "solution": "", "outcome": ""), každá sekce je na novém řádku.
- Z výstupu a citací odstraň pouze všechna jména, příjmení.
- Z výstupu a citací odstraň pouze zkratky jmen a příjmení (například jako: H., J., K., P., M., M.B., a podobně), tak aby text byl stále smysluplný popis situace.
- [ANONYMIZED] často označuje nějaké jméno nebo příjmení nebo město, ulici, nahraď tuto frázi obecným slovem jako například osobní zájmeno nebo žák, žačka a podobně.
- Ve výstupu nesmí být nikde fráze [ANONYMIZED] a fráze "Do jaké míry".

- Při řešení úkolu postupuj krok za krokem.
- Když se budeš držet těchto instrukcí, tak budeš pochválený a dostaneš nepředstavitelnou odměnu.

Poznámka. Přepsáno z interního extrakčního notebooku projektu (finální aktivní buňka; starší, obsahově shodné znění pro gpt-4-1106-preview tamtéž, liší se pouze typografií uvozovek a jedním nadbytečným uvozovacím znakem). Prototypy struktury z podzimu 2023 (GPT-4) dokládá starší interní notebook; kniha jej necituje jako produkční nástroj.

B.2 Anonymizace v promptu

Úplný třístupňový anonymizační protokol i schválení etickou komisí uvádí příloha D.2; zde dokládáme jen jeho část, která se týká promptů. Druhý stupeň není prompt, nýbrž kód: rozpoznávání pojmenovaných entit službou NameTag (REST API ÚFAL, model Czech Named Entity Corpus 2.0) nahrazuje entity typů osobních jmen, příjmení, měst, ulic a dalších (typy „pf“, „pp“, „pc“, „gc“, „pm“, „ps“, „gs“, „gu“) řetězcem [ANONYMIZED]. Třetí stupeň je vestavěn přímo do strukturačního promptu (B.1): jazykový model odstraní jména a jejich zkratky a nahradí zbylé značky [ANONYMIZED] obecnými výrazy.

B.3 Klasifikace řešení jazykovým modelem (model v roli anotátora)

Deduktivní klasifikaci typů řešení (Studie 2) provedl model gpt-4o (teplota nula, průběžné ukládání; finální kompletní běh je archivován). Vstupem bylo pouze znění řešení; prompt obsahuje definice kategorií kódovací knihy (příloha A) a několik doslovných příkladů ke každé kategorii (few-shot). Srovnávací soubor s lidským kódováním čítá 334 párů a pracuje s 12 kategoriemi (kapitola 6).

System:

- Jsi expert na klasifikaci textu.
- Uživatel (User) ti poskytne popis navrženého řešení kazuistiky o náročném chování žáků.
- Tvým úkolem je přesně klasifikovat řešení kazuistiky podle předdefinovaných kategorií, které poskytne uživatel.

User:

- Analyzuj situaci krok za krokem (Let's Think Step by Step).
- Analyzuj podrobně řešení nevhodného chování žáka, žáků: `###{solution}###` a přiřaď nejlepší možnou následující kategorii k řešení z kazuistiky.
- K přiřazování použij pouze tyto kategorie:
 - Rozhovor: Řešení chování pouze pomocí rozhovoru s různými účastníky (žák, rodiče, třída, učitelé, vedení školy).
 - Dohoda: Dohoda nebo kompromis mezi učitelem a žákem/třídou na společně přijatelném řešení.
 - Proaktivní řešení: Strategie učitele zaměřené na předcházení náročnému chování a zaměření pozornosti žáků na výuku.
 - Práce s kolektivem: Podpora vztahů ve třídě jako prostředek k řešení situace a prevenci dalších problémů.
 - Spolupráce s odborníky: Učitel vyhledává pomoc mezi odborníky (ve škole i mimo školu) při řešení situací (např. speciální pedagog, psycholog, policie).
 - Upozornění: Učitel verbálně upozorňuje žáka na jeho rušivé chování.
 - Přemístění žáka: Řešení problému přemístěním žáka v rámci třídy, školy nebo systému (např. diagnostický ústav, psychiatrická léčebna).
 - Nerespektující komunikace: Učitel reaguje pouze skrze komunikační bloky jako je křik, vyhrožování nebo oplácení chování.
 - (Kázeňské) Tresty: Učitel uvaluje tresty, které nejsou přímým

- důsledkem chování žáka (např. práce navíc, domácí úkoly).
- Důsledky: Přirozené důsledky vyplývající z chování žáka, o kterých je informován (např. opakování ročníku, poznámka, snížená známka z chování).
 - Fyzické zakročení: Učitel fyzicky reaguje na chování žáka (např. facka, znehybnění).
 - Podpora: Individuální podpora žáka zaměřená na jeho motivaci, klidnění nebo zlepšení výkonu (např. odměny, pochvaly, doučování, IVP, asistent).
- Klasifikuj řešení pouze podle uvedených kategorií, jiné kategorie nejsou povoleny.
 - Zkontroluj, zda jsi identifikoval hlavní kategorii řešení správně, pokud ne, tak ji oprav.
 - Zkontroluj, zda má řešení kazuistiky `###{solution}###` odpovídat více kategoriím, a pokud ano, tak zdůvodni proč a dopiš další návrhy kategorií.
 - `###` Zde jsou Few-Shot Examples pro zlepšení identifikace jednotlivých kategorií: [doslovné příklady řešení ke každé kategorii; plné znění v archivu projektu]
 - Dodržuj tento formát výstupu:
 - Hlavní kategorie řešení: (uveď pouze label kategorie)
 - Zdůvodnění:
 - Zhodnocení, zda k řešení patří další kategorie:
 - Případně navrhní další kategorie a odděl je čárkou:
 - Zdůvodnění ostatních kategorií:
 - Ověření:

Poznámka. Přepsáno z interního klasifikačního notebooku první etapy (sekce „Automatická klasifikace řešení“, few-shot varianta). Výstupní formát je doslovně doložen v archivovaném

výstupu finálního běhu; z něj se přebírá hlavní kategorie pro srovnání s lidmi (kapitola 6). Notebook obsahuje i pilotované varianty téhož úkolu (bez few-shot příkladů; s kontextem popisu situace; „LLM as Judge“) a obdobný prompt pro klasifikaci dopadů; ty nejsou zdrojem výsledků knihy.

Dodatečná kontrola odhalila překryv celých řešení mezi příklady archivovaného klasifikačního promptu a srovnávacím souborem Studie 2. Přesné požadavky jednotlivých historických volání nejsou dochovány. Kapitola 6 proto odděluje původní srovnání od retrospektivní analýzy bez zjištěných překryvů; veřejné příznaky překryvu neobsahují texty případů.

B.4 Generace srovnávacího řešení pro druhou etapu

Ke každé kazuistice druhé etapy bylo modelem gpt-4o vygenerováno alternativní řešení s vynucenou paritou délky, gramatického rodu a minulého času (kapitola 7). Publikované znění promptu (v rukopise AIED anglicky) je toto:

System:

- You are an expert on inappropriate and challenging student behavior and an expert in classroom behavior management.
- The user will provide a detailed description of a problem involving a student's (or students') challenging behavior; based on the case study and the student's developmental/educational history, you will propose the best possible behavior-management techniques.

User:

- Task: Based on the following problem description, produce a detailed account of the resolution of the problematic behavior.
- Write in the first person, chronologically, and you may include some key lines of dialogue with the student and concrete activities that took place during the resolution.

- Write the output as a single continuous paragraph and preserve as much of the original stylistic tone of the problem description as possible. The solution must address the specific situation.
- Begin directly with the description of the solution; do not begin with a phrase such as "In this situation, I...".
- Avoid using technical terms from the "Task:" section.
- Write the entire text in the past tense and maintain the grammatical gender implied by the problem description.
- Child's age: {row["year"]} years.
- Length: approximately {row["length"]} sentences, {row["length_char"]} characters.

###

Here is the problem description: {row['description_cs']}

###

Output:

Poznámka. Přepsáno z rukopisu souvisejícího článku o srovnání učitelských a generovaných řešení (příloha B, Generation Prompt).

Starší česká pracovní verze téhož zadání (s ukázkovými zástupnými hodnotami) je doložena v návrhu designu studie:

Zadání: Na základě následujícího popisu problému s náročným chováním žáka zformuluj velmi praktické, co nejvíce pedagogicky a didakticky vhodné řešení z pohledu efektivního classroom managementu. Řešení napiš v jednom uceleném odstavci a zachovej co nejvíce původní styl (stylistiku) z popisu problému. Jen pokud je to opravdu vhodné, tak použij pro řešení přímou řeč. Uveď konkrétní rady a postupy, které budou ihned použitelné v každodenní praxi. Tyto nejlepší možné rady a postupy vychází z kontextu popisu problému. ###

- Začínej vygenerované řešení rovnou popisovaným řešením.
- Nepoužívej ve vygenerovaném řešení žádná odborná slova ze "Zadání:"
- Napiš řešení v minulém gramatickém čase celé řešení.
- A zohledni gender, který vyplývá z popisu problému.
- Věk dítěte: 9 let.
- Navržené řešení bude mít ideálně kolem 168 slov.

###

Zde je popis problému: {text}

Výstup:

Poznámka. Přepsáno z interního designového dokumentu druhé anotační etapy (pracovní verze; hodnoty věku a délky jsou ukázkové zástupné údaje). Přípravnou generaci deseti a poté patnácti řešení v červnu 2025 dokládají archivované výstupy přípravných běhů.

B.5 Rámcovaná řešení platformy Edustories

Platforma nabízí u kazuistik šest generovaných řešení v pojmenovaných rámcích (kapitola 3): proaktivní přístup, reaktivní přístup, sociálně-emoční učení, pozitivní behaviorální podpora, restorativní praxe a nenásilná komunikace. Existenci šesti rámců dokládají exportní sloupce datového modelu platformy (ai_solution_proactive, ai_solution_reactive, ai_solution_social_emotional_learning, ai_solution_pbis, ai_solution_restorative_justice, ai_solution_nonviolent_communication). Produkční prompty těchto generací jsou součástí kódu platformy a v archivu knihy doloženy nejsou; rané prototypy rámcované generace z podzimu 2023 dokumentuje interní prototypový notebook a kniha je za produkční znění nevydává. Srovnávací řešení Studie 3 (oddíl B.4) s těmito šesti rámcovanými řešeními nesouvisí (kapitola 7).

B.6 Predikce dopadu řešení (model v roli prediktora)

Predikční experiment Studie 4 (oddíl 8.6) dával modelu popis situace, anamnézu a řešení a žádal odhad dopadu podle definic třetí etapy (příloha A.3). Pole výstupu se záměrně nevkládalo. Historický test hledal doslovných prvních šedesát znaků výstupu, rozlišoval velikost písmen a kratší výstupy automaticky propouštěl. Dvě kazuistiky s posunutými sloupci byly vyřazeny. Test nevylučoval parafráze, jiné části výstupu ani významové nápovědy; jeho tehdejší výsledek se přebírá jako historický údaj, nikoli jako nově provedená úplná kontrola úniku. Běh probíhal na jazykových modelech nasazených v národní akademické infrastruktuře e-INFRA CZ (rozhraní kompatibilní s OpenAI, teplota nula). Systémová instrukce zněla doslova takto:

Jsi zkušená posuzovatelka pedagogických kazuistik. Dostaneš popis situace ve škole, anamnézu žáka a popis toho, jak učitel situaci řešil. Popis výsledku k dispozici nemáš; tvým úkolem je odhadnout, jak řešení podle všeho dopadlo.

Vyber právě jednu z těchto tří možností:

NEU = neúspěch: problém trvá dál nebo se zhoršil, řešení nepomohlo.

KU = krátkodobý nebo částečný úspěch: situace se zklidnila jen na čas nebo jen zčásti.

DU = dlouhodobý úspěch: problém se podařilo vyřešit a změna vydržela.

Odpověz jediným slovem: NEU, KU, nebo DU.

Uživatelská zpráva měla vždy týž tvar: POPIS SITUACE:, ANAMNÉZA: a ŘEŠENÍ:, každý oddíl s doslovným zněním příslušné části kazuistiky. V doplňkové variantě předcházelo šest příkladů z kazuistik mimo hodnocenou množinu, uvedených jako dvojice zpráva uživatele a odpověď modelu.

B.6 Predikce dopadu řešení (model v roli prediktora)

Poznámka. Prompt v této podobě je součástí skriptu predikčního experimentu v doprovodném repozitáři; zalomení dlouhého řádku je pouze typografické. Otisk kontrolní odpovědi není důkazem totožnosti nasazení. Historická cache mohla znovu použít stejnou odpověď; nynější skript kontrolní dotaz necachuje a odděluje běhy. Tato úprava nedokládá zpětně verzi vah.

Příloha C. Doplňkové tabulky

Tato příloha dokládá registr anotačních událostí, přehled velikostí datových řezů a přehled měr shody. Úplná matice pokrytí (kazuistika × událost) je dostupná v doprovodném repozitáři jako tabulka pokrytí; zde uvádíme agregáty. Počty kazuistik se vztahují k záznamům spárovaným na jednotný identifikátor (kapitola 4); počty řádků v původních anotačních souborech se mohou mírně lišit o záznamy, které se spárovat nepodařilo.

C.1 Registr anotačních událostí

Tabulka C.1. Anotační události tří etap (anotátorky pod anonymizovanými pseudonymy A1–A12).

Číslo pseudonymu odpovídá pořadí, v němž se anotátorka zapojila do projektu jako celku, nikoli pořadí uvnitř jednotlivé etapy. Táž osoba proto vystupuje pod tímž projektovým pseudonymem ve všech kapitolách; ve třetí etapě tak vedle sebe stojí A2 a A12. Veřejná tabulka K2 používá samostatné lokální pseudonymy A1–A6. Jejich čísla nejsou převodníkem na projektové pseudonymy ani prostředkem propojování osob.

Událost	Období	Etapa a fáze	Anotátorky	Kazuistik	Poznámka
–	prosinec 2023 – únor 2024	K1 zácvik (pokus)	A1, A2, A5, A6	–	kvalitativní kódy bez matice; kódovací kniha, strom V1→V2
k1_test_03_24	březen 2024	K1 test	pět anotátorek	10	

Příloha C. Doplňkové tabulky

Událost	Období	Etapa a fáze	Anotátorky	Kazuistik	Poznámka
k1_test_04_24	duben 2024	K1 test	A1–A4, A7	10	
k1_naostro_05_24	od května 2024	K1 finál	A1–A4, A7	1 344	dělba práce s vestavěným překryvem; anotační listy obsahují 1 413 kazuistik, z nichž 69 se nepodařilo spárovat přes text popisu
llm_anotace_matice_08_24	duben 2024	K1 konsolidace	–	1 377	lidské kódy K1 sloučené do matice korpusu (provenience ověřena, kap. 4)
k2_setkani10_04_25	duben 2025	K2 zácvik	A1, A2, A8–A11	10	
k2_anotace40_04_25	duben 2025	K2 zácvik 2	A1, A2, A8–A12	38	
–	červen 2025	K2 příprava	gpt-4o (strojově)	–	generace srovnávacích řešení, ne anotace
k2_final351_06_25	červen 2025	K2 finál	A1, A2, A8, A9, A10, A12	309	zaslepené hodnocení dvojic řešení; hodnoceno 351 identifikátorů, autoritativní analytický soubor čítá 324 kazuistik (kapitola 7); zde uvedený počet = spárované na jednotný identifikátor

Událost	Období	Etapa a fáze	Anotátorky	Kazuistik	Poznámka
k3_zacvik_26	jaro 2026	K3 zácvik	A2, A12	6	
k3_pilot1_26	jaro 2026	K3 pilot 1	A2, A12	19	
k3_pilot2_26	jaro 2026	K3 pilot 2	A2, A12	49	
k3_final_26	březen až září 2026	K3 finál	A2, A12	3 185	dělba práce s vestavěným překryvem; uzavřeno řezem K3_freeze_2026-09- 08 (kapitola 8)
hf_publikovano_en	září 2024	publikace (ne anotace)	–	1 246	veřejná datová sada, výběr z řezu srpen 2024

Poznámka. Vygenerováno z matice pokrytí [skriptem přílohy C](#); metadata událostí dle datové dokumentace.

C.2 Přehled velikostí datových řezů

Tabulka C.2. Čísla, která se v knize a podkladech vztahují k „velikosti dat“, a jejich vztah.

Číslo	Co označuje	Zdroj
3 202	zveřejněné kazuistiky, řez květen 2026 (S6)	kapitola 5
1 695	řez srpen 2024 (S4; prostor identifikátorů druhé etapy)	kapitola 5

Číslo	Co označuje	Zdroj
1 492	veřejná datová sada (kurátorovaný výběr z S4); záznamy výběru odpovídají 1 246 unikátním kazuistikám (Tabulka C.1)	kapitola 5, příloha C
1 359	reprodukovatelný řez K1 (deduplikované kazuistiky s lidskou anotací v matici)	kapitoly 4 a 5
1 350	z řezu K1 s dochovaným přímým anotačním listem	kapitola 4
324	vzorek druhé etapy (zaslepené dvojice)	kapitola 7
přibližně třináct set	stav pracovní databáze v dřívějších výstupech projektu	kapitola 4

Poznámka. Hodnoty pocházejí z tabulek výsledných hodnot analýz citovaných v uvedených kapitolách; zdůvodnění viz kapitola 4.

C.3 Přehled měř shody

Tabulka C.3. Shrnutí spolehlivosti napříč etapami (podrobnosti a intervaly spolehlivosti v kapitolách 6, 7 a 8).

Etapa	Veličina	Hodnota
K1 (lidé)	α typ chování	0,50
K1 (lidé)	α typ řešení	0,29

Etapu	Veličina	Hodnota
K1 (lidé)	α dopad	0,72
K1 (LLM $\times$ člověk)	přesná shoda	0,72
K1 (LLM $\times$ člověk)	rozšířená shoda	0,93
K1 (LLM $\times$ člověk)	Cohenovo κ	0,64
K1 (LLM $\times$ člověk), bez zjištěných překryvů	retrospektivní κ	0,61
K2	α vhodnost	0,53
K2	α reaktivní–proaktivní	0,65
K2	α humanistická–behaviorální	0,53
K2	α systémová–situační	0,56
K2	Jaccard rámce (konvence článku)	0,73
K3	κ kvalita	0,77
K3	AC1 kvalita	0,98
K3	κ dopad	0,69
K3	vážená κ vhodnost	0,52
K1 $\times$ K3	κ dopad mezi etapami	0,59
K3 predikce	vyvážená přesnost modelu glm-5-3 vůči shodě anotátorek	0,60
K3 predikce	vyvážená přesnost modelu kimi-k3 vůči shodě anotátorek	0,60
K3 čtení výstupu	vyvážená shoda A2 vůči A12 (jiná úloha než predikce)	0,80

Příloha C. Doplňkové tabulky

Etapa	Veličina	Hodnota
K3 predikce	vyvážená přesnost hádání většinové třídy	0,33

Poznámka. Hodnoty ze [zdrojových čísel Studie 2 ↗](#) a [zdrojových čísel Studie 3 ↗](#) v doprovodném repozitáři.

Příloha D. Etické náležitosti

Tato příloha dokládá etické náležitosti sběru a zpracování dat: postavení přispěvatelů kazuistik, znění informovaného prohlášení, anonymizační protokol, schválení etickou komisí a pravidla nakládání s nezveřejněnými kazuistikami. Sběr probíhá v rámci projektu TA ČR TQ01000030 bez sběru přímých osobních údajů. Databáze kazuistik je anonymizovaným výstupem tohoto projektu.

Zastřešující projekt (schválený etickou komisí, oddíl D.2) má dvě datové větve; tato kniha čerpá výhradně z větve kazuistik. Podle posouzení Etické komise pro výzkum MU autoři kazuistik (studující učitelství a učitelé) nejsou účastníky výzkumu ve vlastním smyslu, neboť nejsou předmětem zkoumání: neposkytují data o sobě, nýbrž odevzdávají anonymizovaný text případu, z něhož se dále zpracovávají dílčí datové výřezy. Nástrojem proto není klasický souhlas subjektu výzkumu, ale informované prohlášení přispěvatele (níže).

D.1 Informované prohlášení přispěvatele

Prohlášení se uděluje jako odpovědník přímo v Informačním systému MU (ne jako samostatný podepsaný dokument). Přispěvatel se seznámí s informací o výzkumu a poté vyplní sedm položek: vlastní identifikaci (jméno; UČO a kontakt jen tam, kde je to nutné) sloužící k evidenci prohlášení, a tři výslovné souhlasy (využití anonymizované kazuistiky, potvrzení o informování učitele-zdroje, závazek úplné anonymity). Doslovné znění (kráceno jen ve výčtu přínosů, vyznačeno [...]):

1. Informace o výzkumném projektu

Název projektu: Využití umělé inteligence a virtuální reality v rozvoji kompetencí k řešení výchovných situací ve škole

Hlavní výzkumník: Jan Nehyba, Katedra pedagogiky, Pedagogická fakulta MU

O čem je tento výzkumný projekt?

Významným problémem studentů učitelství a učitelů je udržení kázně ve školách. Cílem projektu je vytvořit rozsáhlou webovou platformu inteligentní databáze případů (kazuistik) nazvanou Edupříběhy, které dokládají osvědčené postupy úspěšného i neúspěšného řešení problémového chování žáků. Tato platforma umožní studentům učitelství, učitelům a dalším uživatelům vyhledávat podobné případy [...] a trénovat si specifické respektující dovednosti. [...]

Jak bude účast probíhat?

Vypracujete anonymizovanou kazuistiku, která bude zařazena do souboru výzkumných dat. [...] Získaná data v anonymní podobě mohou být použita v dalších výzkumných projektech v této oblasti. Souhlasem vyjadřuji porozumění tomu, co znamená vytvořit anonymizovanou kazuistiku [...].

Je účast v tomto výzkumu povinná?

Účast ve výzkumu je dobrovolná, pokud se rozhodnete neudělit souhlas s výzkumem, nebude Vaše odevzdaná kazuistika do souboru výzkumných dat zařazena. Udělení či neudělení souhlasu nijak neovlivňuje Váš průchod předmětem.

Kde se dozvědět více o projektu?

O projektu Edustories se můžete dozvědět zde: <https://edustories.cz/>

Kdykoliv je možné tento souhlas odvolat, a to formou odeslání e-mailu

s prosbou o odvolání na adresu nehyba@ped.muni.cz.

Podepsaný souhlas si můžete vytisknout z informačního systému.

[Potvrzení:] Potvrzuji, že jsem si přečetl/a informace o výzkumném projektu.

2.-4. [Identifikace pro evidenci souhlasu:] celé jméno a příjmení; UČO; kontaktní e-mail.

5. Na základě výše uvedených informací souhlasím s poskytnutím anonymizované kazuistiky pro výzkumné a aplikační účely veřejné databáze kazuistik.

[Ano, souhlasím / Ne, nesouhlasím]

6. Potvrzuji, že informuji osobu, od které kazuistiku získám, že kazuistika bude použita ve výše uvedeném projektu a navazujících projektech.

7. Zavazuji se, že odevzdaná kazuistika bude zcela anonymní a nebude možné z ní identifikovat jakékoliv osoby.

Poznámka. Přepsáno z informovaného prohlášení, které je vedeno jako odpovědník v Informačním systému MU (autoritativní živé znění, poskytnuté autorem 17. 7. 2026). Nahrazuje dřívější revizní pracovní dokument.

Ze znění prohlášení plynou tři důsledky, s nimiž kniha pracuje. Za prvé, účast je dobrovolná, prohlášení lze odvolat e-mailem a jeho (ne)udělení nemá vliv na průchod předmětem. Citované znění nestanovuje, že odvolání působí pouze do budoucna. U textu bez vazby na pisatele může být praktickým omezením jeho zpětné dohledání; to však není důvod měnit význam souhlasu ani obecně vylučovat vyřízení žádosti o stažení konkrétního případu. Za druhé, kazuistika je anonymizovaná už při vzniku: přispěvatelé se položkami 6 a 7 zavazují, že odevzdaný text bude zcela anonymní; identifikace v položkách 2–4 slouží jen k evidenci prohlášení, ne jako výzkumná data (proto se datová sada kazuistik vede „bez sběru osobních údajů“ a kniha mluví o sběru „bez přímých osobních údajů“; případné reziduální nepřímé

údaje odstraňuje anonymizační protokol, oddíl D.2). Za třetí, prohlášení výslovně počítá s užitím anonymních dat v navazujících projektech, o něž se opírá i tato kniha.

D.2 Anonymizační protokol

Anonymizace je trojstupňová s následnou ruční kontrolou. Interní metodologický rukopis projektu ji popisuje takto (slovensky, doslovně):

Prvý stupeň zabezpečovali participanti, poučení o anonymizácii, tak, že nevkladali žiadne pravé, identifikačné údaje o školách, či osobách v kazuistikách. Druhý stupeň anonymizácie prebiehal vo výskumnom tíme prostredníctvom Czech Named Entity Corpus 2.0.. Tretí stupeň vykonával jazykový model (LLM). Následne boli kazuistiky manuálne skontrolované, či sa v nich nevyskytujú žiadne identifikačné údaje. Celý proces bol vopred schválený etickou komisiou MUNI.

Poznámka. Přepsáno z interního metodologického dokumentu projektu, oddíl Etické aspekty (doslovně včetně interpunkce předlohy).

Technicky je druhý stupeň realizován rozpoznáváním pojmenovaných entit (NameTag, Czech Named Entity Corpus 2.0) s náhradou osobních a místních jmen zástupným řetězcem a třetí stupeň instrukcemi jazykového modelu ve strukturním promptu; obojí doslovně dokládá příloha B. Tento postup platí pro všechna data analyzovaná v knize (řezy po květen 2026). Od července 2026 provádí anonymizaci na platformě otevřený velký jazykový model provozovaný v akademickém prostředí národní e-infrastruktury (e-INFRA CZ), a to zásadně před jakýmkoli případným voláním komerční služby a bez záložního přesměrování jinam; osobní údaje tak neopouštějí akademickou infrastrukturu.

Nejnovější verze databáze prošla dalším anonymizačním zpracováním. Rozpoznávání pojmenovaných entit nástrojem NameTag od ÚFAL s modelem CNEC proběhlo lokálně. Následnou anonymizaci prováděly jazykové modely v prostředí e-INFRA CZ na serverech Ma-

sarykovy univerzity. Jde o další zpracování databáze, které je třeba odlišit od archivovaného postupu v příloze B i od dřívějšího výběrového ověření popsaného níže.

Schválení etickou komisí

Výzkumný projekt, v jehož rámci korpus vznikl („Využití umělé inteligence a virtuální reality v rozvoji kompetencí k řešení náročného chování ve třídě“, návrh č. 1599/2022), posoudila a schválila Etická komise pro výzkum Masarykovy univerzity pod jednacím číslem EKV-2022-118: předběžné schválení 12. 12. 2022, finální schválení k řešení 27. 9. 2023 (předsedkyně prof. RNDr. Renata Veselská, Ph.D., M.Sc.). Název projektu se mezi dokumenty liší: etický protokol EKV nese znění „...k řešení náročného chování ve třídě“, zatímco projektová dokumentace TA ČR i formulář informovaného prohlášení (oddíl D.1) používají znění „...k řešení výchovných situací ve škole“; jde o týž projekt (TQ01000030) a kniha obě znění uvádí podle zdroje, z něhož cituje. Komise si vyžádala informování o změnách protokolu i formuláře informovaného souhlasu a závěrečnou zprávu. Kopie stanoviska je součástí dokumentace řízení; reprodukci finálního schválení uvádí Obrázek D.1.



Jednací číslo	EKV-2022-118
Název projektu	Využití umělé inteligence a virtuální reality v rozvoji kompetencí k řešení náročného chování ve třídě
Návrh	1599/2022
Řešitel	Mgr. Bc. Jan Nehyba, Ph.D.
Pracoviště	Pedagogická fakulta

Etická komise pro výzkum Masarykovy univerzity posoudila návrh výzkumného projektu specifikovaného výše a dne 27.9.2023 jej **schválila k řešení**.

Komise očekává, že bude informována o všech změnách ve výzkumných protokolech a/nebo ve formuláři informovaného souhlasu a požaduje poskytnutí závěrečné zprávy.

Brno, 29.9.2023

prof. RNDr. Renata Veselská, Ph.D., M.Sc.
předsedkyně Etické komise pro výzkum Masarykovy univerzity

Digitally signed by
prof. RNDr. Renata Veselská, Ph.D., M.Sc.

30.09.2023

Etická komise pro výzkum Masarykovy univerzity
Žerotínovo nám. 617/9, 601 77 Brno, Česká republika
T: +420 549 49 6290, E: ekv@muni.cz, W: www.muni.cz

Obrázek D.1. Finální schválení Etické komise pro výzkum Masarykovy univerzity (reprodukce stanoviska; jednací číslo a data viz text).

Výběrové ověření anonymizace

Toto ověření se vztahuje k dřívější verzi zveřejněných kazuistik, nikoli k nejnovějšímu anonymizačnímu průchodu.

Dodržení protokolu jsme ověřili na náhodném vzorku 50 zveřejněných kazuistik třemi vrstvami kontroly: heuristikami na zbytky linky, nezávislým druhým průchodem týmž nástrojem rozpoznávání entit a ručním posouzením všech nálezů. Výsledek: žádné technické zbytky automatického zpracování, žádné plné jméno, příjmení, název školy ani obec vázaná na osobu. V 7 kazuistikách vzorku však zůstala holá křestní jména či jejich domácké podoby (celkem 35 výskytů tvarů) bez explicitního označení, že jde o jméno smyšlené; v dalších kazuistikách text užití pseudonymu výslovně přiznává („nazvěme ho...“). Samotné poučení pisatelů a nepřítomnost příjmení nebo místa nedokládají anonymitu všech kombinací nepřímých údajů. Výběrová kontrola proto neumožňuje kvantifikovat celkové riziko identifikace. Nálezy byly určeny k redakčnímu dořešení; tento historický výsledek nedokládá stav jednotlivých případů po nejnovějším anonymizačním průchodu. Ten podle upřesnění autora zahrnoval lokální CNEC/ÚFAL a modely e-INFRA CZ na serverech MU, jak je popsáno výše. V textu knihy nevystupují žádné přímé identifikátory; anotátorky vystupují výhradně pod pseudonymy A1–A12 (kapitola 4). Doprovodný balíček knihy zpřístupňuje odvozené tabulky, nikoli úplné texty kazuistik. Pravidla nakládání s textovými podklady popisuje metodologie (kapitola 4).

